

TECH FORCE: GALACTIC
ARCHITECTURE

ARQUITETURA DE COMPUTADORES



2

LISTA DE FIGURAS

Figura 1 - Ábaco.....	7
Figura 2 - Mecanismo de Antikythera.....	8
Figura 3 - Pascalina	9
Figura 4 - Calculadora de Leibniz	10
Figura 5 - Tear de Jacquard.....	11
Figura 6 - Máquina analítica de Babbage.....	13
Figura 7 - Máquina de Hollerith	14
Figura 8 - Replica do Z1 de Konrad Zuse	16
Figura 9 - Atanasoff.....	16
Figura 10 - Stibitz Model I CNC.....	17
Figura 11 – Parte do Mark I.....	17
Figura 12 – ENIAC	19
Figura 13 – Transistores do TX.....	23
Figura 14 – Lei de Moore	33
Figura 15 – RFID.....	34
Figura 16 – Microcontroladores.....	35
Figura 17 – Organização de um computador simples.....	50
Figura 18 – Caminho de dados de uma máquina von Neumann	51
Figura 19 – Conversão do número 25.....	60
Figura 20 – Três maneiras de organizar uma memória de 96 bits	62
Figura 21 – <i>Big-endian, little-endian</i>	63
Figura 22 – Memória cache.....	65
Figura 23 – DIMM.....	66
Figura 24 – Hierarquia da memória.....	67
Figura 25 – Composição de um disco óptico	69
Figura 26 – Célula de memória flash.....	74
Figura 27 – Célula de memória flash.....	76
Figura 28 – Estrutura lógica de um computador	79
Figura 29 – Configuração típica usando PCI.....	82
Figura 30 – Tabela ASCII.....	94

LISTA DE TABELAS

Tabela 1 – Unidades 1	48
Tabela 2 – Unidades 2	49
Tabela 3 – Pipeline.....	54
Tabela 4 – Conversão de binários	59
Tabela 5 – Aritmética binária.....	61
Tabela 6 – UFT-8	96

EMSE

SUMÁRIO

ARQUITETURA DE COMPUTADORES	6
1 INTRODUÇÃO	6
2 BREVE HISTÓRIA DOS COMPUTADORES	7
2.1 Geração zero – computadores mecânicos	7
2.1.1 Ábaco (2.400 a.C. – 3.000 a.C.)	7
2.1.2 Mecanismo de Antikythera (aproximadamente 100 a.C.)	8
2.1.3 Calculadora de Wilhelm Schickard (1623)	9
2.1.4 Pascalina (1642)	9
2.1.5 Calculadora de Leibniz (1673)	10
2.1.6 Tear de Jacquard (1804)	11
2.1.7 Máquina analítica de Babbage (1834)	13
2.1.8 Máquina de Hollerith (1890)	14
2.1.9 Zuse, Atanasoff, Stibitz e Mark I (1936 - 1944)	15
2.2 Primeira geração - válvulas (1945 - 1955)	18
2.2.1 Colossus e ENIAC (1943-1946)	18
2.2.2 EDSAC (1949)	19
2.2.3 Whirlwind I (1951)	20
2.2.4 Máquina IAS (1952)	21
2.2.5 Computação clássica	21
2.3 Segunda geração - transistores (1955-1965)	22
2.3.1 PDP-1 (1960)	23
2.3.2 IBM 7090 e 7094 (1959 e 1962)	24
2.3.3 B5000 (1963)	25
2.3.4 CDC 6600 (1964)	26
2.3.5 PDP-8 (1965)	26
2.4 Terceira geração - circuitos integrados (1965-1980)	27
2.4.1 IBM System/360 (1964)	28
2.4.2 PDP-11 (1970)	28
2.5 Quarta geração (1980-?)	29
2.6 Quinta geração - computadores de baixa potência e invisíveis	31
3 COMPUTAÇÃO MODERNA	32
3.1 Tipos de computadores	33
3.1.1 Computadores descartáveis	34
3.1.2 Microcontroladores	35
3.1.3 Computadores móveis e de jogos	36
3.1.4 Computadores pessoais	37
3.1.5 Servidores	38
3.1.6 <i>Edge computing</i>	39
3.1.7 Mainframes	40
4 PRINCIPAIS ARQUITETURAS	41
4.1 Arquitetura x86	41
4.2 Arquitetura ARM	44
4.3 Arquitetura AVR	46
4.4 Unidades	48

5 ORGANIZAÇÃO DE COMPUTADORES	49
5.1 Processador	49
5.1.1 Organização da CPU	51
5.1.2 Execução de instrução	52
5.1.3 Paralelismo e <i>pipelining</i>	52
5.1.4 Pipelining (paralelismo nível de instrução)	53
5.1.5 Paralelismo nível de processador	55
5.2 Memória primária	57
5.2.1 Bits	58
5.2.2 Conversão de uma base para outra	59
5.2.3 Números binários negativos	60
5.2.4 Endereço de memória	61
5.2.5 Ordenação de bytes	63
5.2.6 Memória cache	64
5.2.7 Empacotamento de memória	65
5.3 Memória secundária	66
5.3.1 Hierarquia das memórias	66
5.3.2 Disco magnéticos	68
5.3.3 Fitas magnéticas	70
5.3.4 Discos IDE	71
5.3.5 Disco SCSI	72
5.3.6 Disco em estado sólido	73
5.3.7 CD-ROMs	74
5.3.8 DVDs	76
5.3.9 Blu-ray	78
5.4 Entrada/saída (I/O)	78
5.4.1 Barramento	78
5.4.2 PCI e PCIe	81
5.4.3 Terminais	83
5.4.4 Teclados	83
5.4.5 Touchscreen	84
5.4.6 Monitores de tela plana	85
5.4.7 RAM de vídeos	88
5.4.8 Mouses	89
5.5 Impressoras	90
5.5.1 Impressoras a laser	90
5.5.2 Impressora jato de tinta	91
5.6 Código de caracteres	93
5.6.1 ASCII	93
5.6.2 Unicode	94
5.6.3 UTF-8	95
CONCLUSÃO	96
REFERÊNCIAS	98

ARQUITETURA DE COMPUTADORES

1 INTRODUÇÃO

Neste capítulo, mergulharemos nas profundezas da evolução dos computadores, desde as suas origens mais humildes até as incríveis máquinas que conhecemos hoje. O estudo da história dos computadores não é apenas um exercício nostálgico, mas também uma maneira valiosa de entender como os princípios fundamentais da ciência da computação e da engenharia têm moldado a tecnologia ao longo do tempo. Este conhecimento proporciona uma compreensão mais profunda da natureza inerentemente iterativa da inovação tecnológica, ilustrando como cada geração de computadores se baseia nos sucessos e aprendizados das gerações anteriores.

No entanto, além de compreender a história, é crucial entender também a organização estruturada dos computadores - a espinha dorsal que dá forma à maneira como os computadores funcionam. Esta parte abordará os componentes chave dos sistemas de computação modernos, desde o hardware central, como o processador e a memória, até os sistemas de entrada e saída que permitem a interação do computador com o mundo exterior. Ao explorar os detalhes da organização estruturada do computador, ganhamos uma compreensão mais completa de como as peças individuais se unem para criar um sistema capaz de realizar tarefas incrivelmente complexas.

Ao concluir este capítulo, você terá uma compreensão sólida e bem-arredondada tanto da história dos computadores quanto da sua organização estruturada. Essa compreensão permitirá que você aprecie não apenas a complexidade e o poder dos computadores modernos, mas também os caminhos inovadores que nos trouxeram até aqui e a estrutura fundamental que possibilita essa inovação contínua.

Prepare-se para uma viagem no tempo e um mergulho profundo na engenhosidade humana, pois exploramos a história fascinante e a organização intrincada do computador.

2 BREVE HISTÓRIA DOS COMPUTADORES

2.1 Geração zero – computadores mecânicos

2.1.1 Ábaco (2.400 a.C. – 3.000 a.C.)



Figura 1 - Ábaco
Fonte: Google Imagens (2023)

Segundo Ifrah (2001), o primeiro dispositivo usado para auxiliar nos cálculos de que se tem notícia é o ábaco. Encontrado em diferentes formatos nas civilizações da Mesopotâmia, do Egito Antigo e da China, esse instrumento simples, mas notavelmente poderoso, composto por uma série de hastes ou fios paralelos sobre os quais são colocadas contas móveis, foi projetado para fazer cálculos rápidos e precisos, representando números diferentes pela posição das contas. Por sua vez, as contas são movidas para frente e para trás em suas hastes para realizar cálculos como adição, subtração, multiplicação e divisão.

Além disso, o ábaco serviu como uma ponte crucial entre o mundo da matemática abstrata e a realidade concreta. Ao proporcionar uma representação física e manipulável dos números e das operações matemáticas, o ábaco ajudou a desmistificar a matemática e torná-la mais acessível. Portanto, embora o ábaco possa parecer primitivo para os padrões modernos, seu papel na história da computação e da matemática é inegavelmente significativo.

2.1.2 Mecanismo de Antikythera (aproximadamente 100 a.C.)



Figura 2 - Mecanismo de Antikythera
Fonte: Wikicommons (2023)

Esse mecanismo foi descoberto no fundo do mar perto da ilha de Antikythera, na Grécia, e é descrito por Freeth et al. (2006) como um dispositivo composto de engrenagens de bronze interligadas operado por uma manivela. À medida que a manivela era girada, as engrenagens moviam-se em uma dança meticulosamente calculada que modelava o movimento dos corpos celestes. Esse mecanismo não apenas previa as posições de planetas e estrelas, mas também era capaz de acompanhar os ciclos lunares e prever eclipses solares e lunares com precisão impressionante.

O Mecanismo de Antikythera é um testemunho do conhecimento científico e habilidade tecnológica dos antigos, servindo como um lembrete impressionante de que a busca humana para compreender e modelar o universo é um esforço que se estende por milênios. Ele foi, de fato, um dos primeiros dispositivos a marcar a transição da computação manual para a mecânica, estabelecendo um precedente para os futuros desenvolvimentos na ciência e tecnologia da computação.

2.1.3 Calculadora de Wilhelm Schickard (1623)

Apesar de muitos autores não levarem em consideração a máquina de calcular de Schickard, pois ela supostamente fora destruída em um incêndio e só se sabe da sua existência graças a cartas que Schickard enviou ao seu amigo, o astrônomo Johannes Kepler, ela pode ser considerada por alguns historiadores o primeiro mecanismo de cálculo automático.

Segundo as cartas, o dispositivo consistia em uma série de rodas dentadas que podiam ser giradas manualmente para realizar cálculos. Com este mecanismo, era possível executar adições e subtrações, bem como multiplicação e divisão por meio de uma série de adições ou subtrações.

Em uma carta para Kepler, Schickard descreveu a máquina como "capaz de realizar cálculos sozinha", uma descrição que destaca a notável inovação que o dispositivo representava para a época. De fato, a calculadora era capaz de fazer mais do que apenas auxiliar nos cálculos - ela podia executá-los automaticamente, uma vez que o usuário inserisse os números.

Embora a máquina de Schickard tenha sido destruída e sua existência permanecesse em grande parte desconhecida por séculos, ela ainda serve como um marco notável no desenvolvimento dos computadores. Essa invenção precoce lançou as bases para a criação de dispositivos de cálculo mecânico mais avançados, pavimentando o caminho para a invenção dos modernos computadores que conhecemos hoje.

2.1.4 Pascalina (1642)




Figura 3 - Pascalina
Fonte: Wikicommons (2023)

A Pascalina, ou Máquina de Pascal, é um marco importante na história da computação. Blaise Pascal, um renomado matemático e filósofo francês, desenvolveu o dispositivo para ajudar seu pai, que era um coletor de impostos, a realizar cálculos rotineiros mais facilmente.

O dispositivo é composto por uma série de rodas dentadas, cada uma representando um dígito em uma coluna decimal. Quando uma roda completava uma volta de dez dígitos, acionava a roda à sua esquerda para avançar um dígito, permitindo assim a "carregação" de um dígito para a próxima coluna decimal. Esse princípio básico é similar ao utilizado em muitos dispositivos de contagem mecânicos até o século XX.

Apesar de suas limitações - como a incapacidade de realizar diretamente operações além de adições e subtrações - a Pascalina foi uma conquista impressionante para a sua época. Foi o primeiro dispositivo mecânico de cálculo a ser produzido e vendido comercialmente, fazendo de Pascal o pioneiro da indústria de computação.

O legado da Pascalina perdura até hoje, não apenas como um dos primeiros computadores mecânicos, mas também como prova do potencial da máquina para ampliar as capacidades humanas. Este foi um passo crucial que preparou o terreno para o desenvolvimento de máquinas de calcular cada vez mais sofisticadas, culminando na invenção dos modernos computadores digitais.

2.1.5 Calculadora de Leibniz (1673)



Figura 4 - Calculadora de Leibniz
Fonte: Google Imagens (2023)

Por mais imponente que a Pascalina fora para a época, o dispositivo conseguia apenas fazer cálculos de adição e subtração. No entanto, 30 anos após a criação de Pascal, o filósofo e matemático alemão Gottfried Wilhelm von Leibniz (mais conhecido

por seu desenvolvimento simultâneo e independente do cálculo infinitesimal) desenvolveu uma das primeiras calculadoras mecânicas que possuía a capacidade de dividir e multiplicar.

Conhecida como a "Máquina de Calcular de Leibniz" ou a "Roda de Leibniz", a invenção de Leibniz melhorou significativamente o design da Pascalina, permitindo não apenas a adição e subtração, mas também a multiplicação e divisão de maneira muito mais direta e eficiente.

A inovação-chave da calculadora de Leibniz foi a introdução de uma engrenagem escalonada - um tipo especial de engrenagem que permitiu cálculos mais complexos. Este avanço na tecnologia de engrenagens permitiu à calculadora realizar operações de multiplicação e divisão muito mais facilmente do que a Pascalina.

Apesar de sua máquina nunca ter sido produzida em larga escala devido a limitações tecnológicas da época, as inovações de Leibniz tiveram um impacto duradouro. Seu trabalho no desenvolvimento de uma calculadora mecânica avançada estabeleceu um caminho que foi seguido por muitos inventores subsequentes na busca por dispositivos de cálculo automáticos mais eficientes e precisos.

2.1.6 Tear de Jacquard (1804)



Figura 5 - Tear de Jacquard
Fonte: Wikicommons (2023)

Durante os próximos 150 anos nada importante aconteceu, contudo é importante destacar a invenção de Jacquard e como ela ajudou na ideia da criação de cartões perfurados nas operações dos primeiros computadores.

Inventado por Joseph Marie Jacquard, um tecelão e comerciante francês, o tear de Jacquard revolucionou a indústria têxtil no início do século 19. Este dispositivo, uma melhoria significativa em relação aos teares anteriores, usava uma série de cartões perfurados para controlar o padrão do tecido produzido.

Cada cartão perfurado do tear correspondia a uma linha no padrão do tecido. Os buracos nos cartões permitiam que os fios de urdume (os fios verticais em um tecido) passassem, enquanto os lugares onde não havia buracos impediam a passagem dos fios. Ao organizar os cartões em uma sequência específica, os tecelões podiam programar o tear para produzir padrões complexos automaticamente.

Esta inovação foi fundamental para a história da computação porque introduziu a ideia de usar cartões perfurados para controlar uma máquina, uma forma primitiva de programação. A ideia de usar cartões perfurados para representar instruções foi adotada posteriormente por Charles Babbage em suas máquinas analíticas, que são consideradas precursoras dos computadores modernos.

Os cartões perfurados do tear de Jacquard foram a inspiração para os primeiros métodos de entrada de dados em computadores, e esta técnica foi amplamente utilizada durante a maior parte do século 20. Assim, o tear de Jacquard é frequentemente visto como um marco importante na história da computação, ilustrando como a tecnologia mecânica pode ser programada para realizar tarefas complexas.

2.1.7 Máquina analítica de Babbage (1834)




Figura 6 - Máquina analítica de Babbage
Fonte: Wikicommons (2023)

Somente em 1834, o professor de matemática da Universidade de Cambridge, Charles Babbage, o inventor do velocímetro, projetou e construiu sua primeira máquina diferencial. Apesar do projeto representar um marco na evolução dos dispositivos mecânicos, assim como o de Pascal, ele só podia somar e subtrair, e fora desenvolvido para executar um único algoritmo, o método de diferenças finitas que usava polinômios. No entanto, um ponto interessante dessa primeira máquina é sua saída: ela perfurava seus resultados sobre uma chapa de gravação de cobre com uma punção de aço, prenunciando futuros meios de escrita única com cartões perfurados e CD-ROMs.

Babbage logo se cansou dessa máquina que só podia executar um único algoritmo e começou a desenvolver uma sucessora apelidada de máquina analítica.

A máquina analítica foi projetada para ser uma máquina de propósito geral, capaz de executar qualquer tipo de cálculo matemático. Ela era composta de duas partes principais: o "moinho", que era responsável por realizar os cálculos, e o "depósito", que armazenava dados. Esta divisão entre processamento e armazenamento de dados é uma característica fundamental da arquitetura dos computadores modernos.

Aqui cabe ressaltar o trabalho de Ada Lovelace, matemática e escritora britânica, que é frequentemente creditada como a primeira programadora de computadores devido ao seu trabalho com Babbage. Ela entendeu profundamente o potencial da máquina analítica e, em suas notas sobre a máquina, ela descreveu um método para

calcular números de Bernoulli, que é considerado o primeiro algoritmo destinado a ser processado por uma máquina - no caso, a Máquina Analítica de Babbage.

Embora a máquina analítica de Babbage nunca tenha sido construída durante sua vida, sua concepção do dispositivo e a colaboração com Lovelace foram extremamente influentes para o desenvolvimento da computação moderna. De fato, muitos dos conceitos e estruturas fundamentais de computadores modernos, como a separação entre unidade de cálculo e armazenamento de dados, e o uso de programação por meio de linguagem simbólica, podem ser rastreados até a Máquina Analítica de Babbage.

2.1.8 Máquina de Hollerith (1890)



Figura 7 - Máquina de Hollerith
Fonte: Wikicommons (2023)

A invenção de Herman Hollerith marcou uma etapa crucial na evolução da computação. Hollerith, um engenheiro e estatístico americano, desenvolveu uma máquina de tabulação eletromecânica para acelerar o processo de tabulação dos dados do censo dos Estados Unidos. Sua máquina utilizava cartões perfurados para registrar e armazenar informações, um conceito inspirado pela máquina analítica de Babbage e pelo tear de Jacquard.

A máquina de Hollerith podia ler automaticamente os cartões perfurados, que eram alimentados na máquina e cujos furos representavam diferentes tipos de dados. Os dados eram então contados ou tabulados de acordo com a programação da máquina. A máquina de Hollerith aumentou enormemente a eficiência do processo de

tabulação de dados, permitindo que o censo de 1890 nos Estados Unidos fosse concluído em muito menos tempo do que os métodos manuais permitiriam.

A invenção de Hollerith teve um impacto significativo e duradouro na computação. Em 1896, Hollerith fundou a Tabulating Machine Company, que depois se tornou parte da International Business Machines (IBM), uma das maiores e mais influentes empresas de tecnologia do mundo. A ideia de usar cartões perfurados para entrada de dados persistiu bem no século XX, sendo usada em muitos sistemas de computadores iniciais.

Além disso, a máquina de Hollerith introduziu o conceito de processamento automático de dados, uma ideia central na computação moderna. Através de sua máquina de tabulação, Hollerith estabeleceu as bases para o desenvolvimento de máquinas automáticas de processamento de dados, pavimentando o caminho para a criação dos primeiros computadores digitais.

2.1.9 Zuse, Atanasoff, Stibbitz e Mark I (1936 - 1944)

O avanço seguinte de destaque surgiu no final dos anos 1930, graças ao engenheiro alemão Konrad Zuse. Zuse criou uma série de máquinas calculadoras automáticas utilizando relés eletromagnéticos. No entanto, ao eclodir a guerra, Zuse não conseguiu obter financiamento governamental; os oficiais do governo acreditavam que a guerra terminaria antes que a máquina estivesse pronta.

Sem conhecimento das contribuições de Babbage, e com suas inovações destruídas pelos bombardeios aliados em Berlim em 1944, o trabalho de Zuse não influenciou diretamente as máquinas subsequentes. Contudo, ele permanece como uma figura pioneira na história da computação.




Figura 8 - Replica do Z1 de Konrad Zuse
Fonte: Wikicommons (2023)

No mesmo período, nos Estados Unidos, John Atanasoff do Iowa State College e George Stibbitz do Bell Labs também estavam projetando suas próprias calculadoras. A máquina de Atanasoff era notavelmente avançada para a época. Ela empregava aritmética binária e a memória consistia de capacitores periodicamente recarregados para prevenir a perda de carga, processo que ele chamou de "refrescar a memória". Esse princípio é o mesmo utilizado nos atuais chips de memória dinâmica (DRAM). Infelizmente, sua máquina nunca se tornou completamente operacional. Atanasoff pode ser comparado a Babbage: um visionário limitado pela tecnologia de hardware disponível em sua época.




Figura 9 - Atanasoff
Fonte: Wikicommons (2023)

A criação de Stibbitz, embora mais rudimentar que a de Atanasoff, estava de fato em funcionamento. Stibbitz apresentou sua máquina ao público em uma conferência no Dartmouth College em 1940.



Figura 10 - Stibitz Model I CNC
Fonte: Wikicommons (2023)

Paralelamente ao trabalho de Zuse, Stibitz e Atanasoff, Howard Aiken, um jovem pesquisador, executava cansativos cálculos numéricos à mão para a sua pesquisa de doutorado em Harvard. Ao concluir o doutorado, Aiken percebeu a importância de realizar cálculos por meio de máquinas. Ele encontrou o trabalho de Babbage em uma biblioteca e decidiu construir o computador de uso geral que Babbage não pôde concretizar.




Figura 11 – Parte do Mark I
Fonte: Wikicommons (2023)

A primeira máquina de Aiken, a Mark I, foi finalizada em Harvard em 1944. A Mark I possuía 72 palavras de 23 dígitos decimais cada e um tempo de instrução de 6 segundos, com entrada e saída de dados feitas por fita de papel perfurada. Quando Aiken concluiu a sucessora da Mark I, a Mark II, a era dos computadores a relé já havia

terminado. A era eletrônica havia começado marcando a primeira geração de computadores.

2.2 Primeira geração - válvulas (1945 - 1955)

2.2.1 Colossus e ENIAC (1943-1946)

A Segunda Guerra Mundial foi o catalisador para o desenvolvimento do computador eletrônico. Na fase inicial do conflito, submarinos alemães estavam causando grande devastação nos navios britânicos. Os comandos dos almirantes sediados em Berlim eram transmitidos aos submarinos via rádio e, apesar de serem interceptados pelos britânicos, as mensagens estavam criptografadas por um dispositivo conhecido como Enigma. Contrariamente ao que foi mencionado, este dispositivo não possui ligação com o inventor e ex-presidente dos Estados Unidos, Thomas Jefferson.

No início da guerra, a inteligência britânica obteve uma máquina Enigma, graças à inteligência polonesa que havia roubado dos alemães. Entretanto, decifrar uma mensagem codificada exigia cálculos extensos, e para que as informações fossem úteis, era necessário concluir tais cálculos pouco tempo após a interceptação da mensagem. Para lidar com essa tarefa, o governo britânico estabeleceu um laboratório ultrassecreto responsável pela construção de um computador eletrônico chamado Colossus. O renomado matemático britânico Alan Turing desempenhou um papel significativo no projeto deste computador. Operando desde 1943, o Colossus é mencionado principalmente por ser o primeiro computador digital eletrônico do mundo, ainda que a sua existência tenha sido mantida em segredo por décadas, tornando-o uma via sem continuidade na história da computação.

A guerra, além de destruir as máquinas de Zuse e incentivar a construção do Colossus, também impactou o campo da computação nos Estados Unidos. O exército necessitava de tabelas de alcance para sua artilharia pesada e contratou centenas de mulheres para realizar os cálculos necessários com calculadoras manuais. No entanto, o processo era lento e propenso a erros.

John Mauchly, familiarizado com os trabalhos de Atanasoff e Stibbitz, sabia do interesse do exército em calculadoras mecânicas. Como muitos cientistas da

computação que o seguiram, Mauchly apresentou uma proposta ao exército para financiar a construção de um computador eletrônico. Sua proposta foi aceita em 1943, e ele e seu aluno de pós-graduação, J. Presper Eckert, começaram a construir um computador eletrônico, batizado de ENIAC (Electronic Numerical Integrator And Computer).

O ENIAC, composto por 18 mil válvulas e 1.500 relés, pesava 30 toneladas e consumia 140 kW de energia. Arquitetonicamente, a máquina possuía 20 registradores, cada um capaz de armazenar um número decimal de 10 dígitos. O ENIAC era programado ajustando até 6 mil interruptores multiposição e conectando inúmeros soquetes com uma infinidade de cabos de interligação. A construção da máquina só foi finalizada em 1946, o que a tornou tardia para cumprir seu propósito original na guerra. No entanto, com o término do conflito, Mauchley e Eckert obtiveram permissão para organizar um curso de verão, onde apresentaram seu trabalho aos colegas cientistas. Esse curso de verão marcou o início de um intenso interesse no desenvolvimento de computadores digitais de grande escala.



Figura 12 – ENIAC
Fonte: Wikicommons (2023)

A partir desse curso de verão, diversos pesquisadores foram estimulados a construir seus próprios computadores eletrônicos.

2.2.2 EDSAC (1949)

Projetado e construído na Universidade de Cambridge, Inglaterra, o EDSAC foi o primeiro computador eletrônico de uso geral totalmente operacional do mundo que implementou um conjunto arquitetônico de instruções armazenadas, conhecido hoje

como modelo de programação von Neumann. Foi desenvolvido por Maurice Wilkes e sua equipe, com o principal objetivo de atender às necessidades de computação dos pesquisadores universitários.

O EDSAC incorporou muitas ideias inovadoras que se tornaram padrões na computação moderna. A mais importante delas era o conceito de programa armazenado, onde tanto os dados quanto as instruções do programa são mantidos na memória do computador. Isso permitia que os programas fossem lidos e modificados pelo próprio computador, abrindo caminho para a programação de alto nível e os sistemas operacionais.

Este computador era uma máquina de grande porte que utilizava válvulas de vácuo para processamento e memória de linha de atraso de mercúrio para armazenamento. Embora seu design seja obsoleto hoje, o EDSAC deixou um legado duradouro: suas arquiteturas e princípios de design formam a base da maioria dos computadores modernos.

2.2.3 Whirlwind I (1951)

Desenvolvido no Massachusetts Institute of Technology (MIT) sob a liderança de Jay Forrester, o Whirlwind I foi um marco importante no avanço da computação de tempo real. Originalmente concebido para ser um simulador de voo para a Marinha dos Estados Unidos, o Whirlwind I acabou se transformando em um dos primeiros computadores digitais de uso geral e de alta velocidade.

O Whirlwind I foi pioneiro na computação de tempo real, um sistema no qual as informações são processadas tão rapidamente que os resultados estão disponíveis instantaneamente e podem influenciar eventos em curso. Este foi um avanço significativo, já que os computadores anteriores processavam tarefas em lotes e não podiam responder a entradas em tempo real.

Outra contribuição importante do Whirlwind I foi a introdução do primeiro monitor de vídeo de raios catódicos para computadores. Esta inovação transformou a forma como os computadores eram operados, permitindo uma interação em tempo real entre o usuário e a máquina, em vez da entrada e saída de dados por meio de cartões perfurados ou fitas magnéticas.

Assim, o Whirlwind I estabeleceu o caminho para a computação de tempo real, que é crucial para muitas das aplicações modernas de computação que vão desde sistemas de controle de processos industriais e sistemas de reserva de companhias aéreas até simuladores de voo e videogames interativos.

2.2.4 Máquina IAS (1952)

Concebida sob a supervisão do matemático e físico John von Neumann no Instituto de Estudos Avançados (IAS) em Princeton, a máquina IAS teve um impacto duradouro no campo da computação. Embora o computador IAS não tenha sido o primeiro a ser construído, ele influenciou o design de muitos dos computadores subsequentes.

John von Neumann, uma das mentes mais brilhantes do século XX, fez contribuições significativas para a arquitetura dos computadores modernos. Ele é mais conhecido por desenvolver o conceito de arquitetura de von Neumann, que se tornou o modelo padrão para a construção de computadores.

A arquitetura de von Neumann é baseada no princípio de que um computador tem uma unidade central de processamento (CPU) para executar instruções, uma memória para armazenar tanto as instruções quanto os dados, e dispositivos de entrada e saída. Importante ainda é a ideia de que o computador deveria ser capaz de armazenar em sua memória não apenas dados, mas também o programa de instruções, possibilitando que o computador execute qualquer tipo de tarefa sem precisar ser fisicamente reconfigurado. Este princípio de armazenamento e execução de programas é a pedra angular da computação digital moderna. Falaremos mais sobre ela na seção sobre organização dos computadores.

A máquina IAS, embora nunca tenha sido comercialmente produzida, foi usada como modelo para a construção de uma série de computadores nas décadas de 1950 e 1960. O design influente da Máquina IAS e a arquitetura de von Neumann continuam a moldar o campo da ciência da computação até hoje.

2.2.5 Computação clássica

- **UNIVAC (1951):** O UNIVAC I (UNIVersal Automatic Computer I) foi o primeiro computador comercial produzido nos Estados Unidos. Foi projetado e construído pela empresa que se tornaria a Unisys. UNIVAC foi notável por ser o primeiro computador a ser produzido em série e por seu uso na contagem dos votos durante a eleição presidencial dos EUA em 1952, em que previu corretamente a vitória de Eisenhower. Utilizando tecnologia de válvulas a vácuo, o UNIVAC I, apesar de seu tamanho e custo, sinalizou o início da era da computação comercial.
- **IBM 701 (1952):** O IBM 701, também conhecido como Defense Calculator, foi o primeiro computador produzido em larga escala pela IBM. Concebido principalmente para aplicações militares e científicas, o 701 fez uso de válvulas a vácuo e tinha uma memória de núcleo magnético. Seu alto custo e tamanho maciço limitavam sua adoção, no entanto, o 701 marcou a entrada da IBM no campo da computação de grande porte, estabelecendo as bases para o seu domínio subsequente na indústria de computadores.

Esses computadores, e outros da mesma época, foram construídos com válvulas a vácuo e usavam memória de núcleo magnético. Apesar de serem relativamente lentos e propensos a superaquecimento, esses primeiros computadores estabeleceram as bases para a arquitetura de computadores moderna. No entanto, os avanços na tecnologia dos transistores, que foram introduzidos no final dos anos 1950, logo tornaram esses primeiros computadores obsoletos, abrindo caminho para uma nova geração de computadores mais eficientes e confiáveis.

2.3 Segunda geração - transistores (1955-1965)

A invenção do transistor ocorreu no Bell Labs em 1948, obra de John Bardeen, Walter Brattain e William Shockley, que receberam o Prêmio Nobel de Física em 1956 por esta inovação. Dentro de uma década, o transistor revolucionou a computação e, até o final dos anos 1950, os computadores baseados em válvulas tornaram-se obsoletos.

O primeiro computador transistornado foi construído no Lincoln Laboratory do MIT, uma máquina de 16 bits que seguia a filosofia de projeto do Whirlwind I. Foi

denominado TX-0, e sua função principal era servir como um dispositivo de teste para o muito mais avançado TX-2.

MIT TX-0 Transistorized Computer Built in 1955, Operational in 1956




Figura 13 – Transistores do TX
Fonte: Google Imagens (2023)

Infelizmente, o TX-2 não obteve o sucesso esperado. No entanto, um dos engenheiros do laboratório, Kenneth Olsen, fundou uma empresa, a Digital Equipment Corporation (DEC), em 1957, com a intenção de fabricar uma máquina comercial similar ao TX-0. No entanto, demorou quatro anos até que esta máquina, o PDP-1, fosse lançada. Essa demora se deu, principalmente, porque os investidores iniciais da DEC estavam convencidos de que não havia um mercado substancial para computadores na época.

2.3.1 PDP-1 (1960)

O PDP-1 (Programmed Data Processor-1), produzido pela Digital Equipment Corporation (DEC), representou um marco importante na história da computação. Lançado em 1960, foi o primeiro computador interativo e relativamente acessível no mercado, permitindo aos usuários a oportunidade de interagir diretamente com a máquina através de um monitor e um teclado, o que representava uma grande inovação em relação aos gigantes mainframes da época que usavam cartões perfurados e fitas magnéticas.

O dispositivo era uma máquina de 18 bits, capaz de realizar até 100.000 operações por segundo. Embora não fosse tão poderoso quanto alguns dos grandes mainframes da época, suas capacidades interativas e preço relativamente acessível (comparado aos mainframes) fizeram dele uma escolha popular para laboratórios de pesquisa e universidades.

Adicionalmente, ele também é notável por ser o computador onde o primeiro videogame conhecido, chamado "Spacewar!", foi programado por Steve Russell, Martin Graetz e Wayne Wiitanen em 1962. Este jogo espacial permitia que duas pessoas controlassem espaçonaves em uma tela gráfica e é frequentemente creditado como uma influência seminal na indústria de videogames.

Em resumo, o PDP-1 foi um marco na história da computação, pois representou uma grande evolução no sentido da interação em tempo real com os computadores, democratizando o acesso à tecnologia e abrindo caminho para o surgimento da indústria de videogames.

2.3.2 IBM 7090 e 7094 (1959 e 1962)

Os computadores IBM 7090 e 7094, lançados em 1959 e 1962 respectivamente, tiveram um papel significativo na evolução da computação, marcando a transição da tecnologia de válvulas para transistores, o que permitiu maior velocidade de processamento e confiabilidade.

O IBM 7090 foi um dos primeiros computadores totalmente transistorizados de grande porte produzidos pela IBM. Com uma arquitetura de 36 bits, o 7090 foi projetado para manipular grandes volumes de dados científicos e de engenharia. Ele foi amplamente utilizado na NASA durante o projeto Apollo e desempenhou um papel vital na realização da primeira aterrissagem na lua. Além disso, o 7090 também foi o coração do sistema de reservas aéreas SABRE, que revolucionou a indústria de viagens.

A máquina sucessora, o IBM 7094, oferecia o dobro da velocidade de processamento do 7090 e maior capacidade de memória. Semelhante ao seu predecessor, o 7094 foi projetado para uso em aplicações científicas e de engenharia. O 7094 foi fundamental na evolução dos sistemas operacionais, pois foi usado para desenvolver e executar o CTSS (Compatible Time-Sharing System) no MIT, um dos primeiros sistemas operacionais de compartilhamento de tempo.

Essa inovação permitiu que vários usuários acessassem o computador simultaneamente, estabelecendo um marco importante na evolução dos sistemas de computação modernos.

Em suma, o IBM 7090 e 7094 foram máquinas significativas na história da computação, pois ajudaram a inaugurar a era dos transistores, permitiram avanços na ciência e na indústria, e deram contribuições substanciais para o desenvolvimento de sistemas operacionais modernos.

2.3.3 B5000 (1963)

O Burroughs B5000, lançado em 1963, é considerado uma máquina pioneira na história da computação. Projetado por Robert S. Barton, o B5000 introduziu muitas inovações que influenciaram as arquiteturas de computadores subsequentes, sendo uma das primeiras máquinas projetadas levando em consideração as necessidades de linguagens de alto nível e técnicas de programação modernas.

Uma das características mais notáveis do B5000 foi sua ênfase na programação em linguagens de alto nível. Foi uma das primeiras máquinas a ser projetada explicitamente para o uso de uma linguagem de alto nível, neste caso o ALGOL 60, uma das primeiras linguagens de programação blocada. Isso contrastava com a maioria das outras máquinas da época, que eram frequentemente programadas em linguagem de máquina ou em montador.

O B5000 também foi inovador na sua abordagem de segurança e confiabilidade. Ele introduziu o conceito de um ambiente protegido de memória para cada processo, o que significa que cada processo tinha seu próprio espaço de memória privado, o qual outros processos não podiam acessar. Isso ajudou a evitar muitos problemas comuns, como a corrupção de dados por processos que sobrescreviam acidentalmente a memória de outro processo.

Além disso, o B5000 também foi uma das primeiras máquinas a usar a arquitetura de pilha, que se tornou a base para muitas arquiteturas de computadores posteriores. Ao invés de usar registradores gerais, as operações eram executadas diretamente na pilha, facilitando a implementação de chamadas de função e retorno em linguagens de alto nível.

No geral, a influência do B5000 na computação moderna é ampla. Muitos dos conceitos que ele introduziu, incluindo o foco em linguagens de alto nível, o uso de espaços de memória protegidos e a arquitetura baseada em pilha, se tornaram pedras angulares da arquitetura de computadores modernos.

2.3.4 CDC 6600 (1964)

O CDC 6600, lançado em 1964, representa um marco importante na história da computação, já que foi considerado o primeiro supercomputador do mundo. Projetado por Seymour Cray na Control Data Corporation (CDC), o CDC 6600 definiu novos padrões de desempenho, sendo significativamente mais rápido que qualquer outro sistema disponível na época.

O CDC 6600 era conhecido pela sua arquitetura inovadora e, principalmente, pela sua velocidade incrível. Era capaz de realizar até 3 milhões de instruções por segundo, cerca de três vezes mais rápido que o IBM 7030 "Stretch", que era, até então, um dos computadores mais rápidos existentes.

O CDC 6600 introduziu um conceito inovador conhecido como processamento periférico, em que dez unidades de processamento mais simples, chamadas Periféricos de Processamento (Peripheral Processing Units, PPU's), lidavam com tarefas de entrada/saída e operações de sistema, liberando a unidade central de processamento (CPU) para se concentrar exclusivamente em cálculos de alta velocidade. Essa abordagem ajudou a maximizar a utilização da CPU e aumentar o desempenho geral do sistema.

Outro aspecto notável do CDC 6600 foi o seu sistema de refrigeração. Para lidar com o calor gerado pelos seus mais de 400.000 transistores, o sistema utilizava um sistema de refrigeração líquida, outra inovação introduzida por Cray.

O CDC 6600 não apenas estabeleceu novos padrões de desempenho, mas também influenciou o design de supercomputadores subsequentes. Seymour Cray continuou a sua inovação no campo dos supercomputadores, levando ao desenvolvimento do CDC 7600 e, mais tarde, da série Cray-1, ambos descendentes diretos do CDC 6600.

Portanto, o CDC 6600 tem uma relevância imensa para a evolução da computação, especificamente no que diz respeito à computação de alto desempenho, com seu foco em velocidade e eficiência operacional, que continua sendo crucial no design de supercomputadores modernos.

2.3.5 PDP-8 (1965)

O PDP-8, lançado em 1965 pela Digital Equipment Corporation (DEC), representa um ponto de inflexão significativo na história da computação por ser o primeiro computador minúsculo bem-sucedido comercialmente. Considerado por muitos como o precursor do computador pessoal, o PDP-8 tornou a computação acessível a mais pessoas e instituições do que nunca, graças ao seu tamanho compacto e preço acessível.

Uma inovação-chave do PDP-8 foi a introdução do "Omnibus", um barramento de expansão que permitia a adição de dispositivos periféricos e outros hardware ao sistema principal. Este barramento era essencialmente um conector que permitia que várias placas de circuito fossem conectadas ao sistema, permitindo a expansão de capacidades e flexibilidade no uso do computador.

A adoção do Omnibus foi um passo significativo no desenvolvimento de uma arquitetura de computador modular, onde diferentes componentes de hardware poderiam ser facilmente adicionados ou removidos.

O Omnibus permitiu que os usuários do PDP-8 personalizassem suas máquinas para atender a uma variedade de necessidades, desde processamento de dados até controle de instrumentos. Este conceito de extensibilidade, possibilitado pelo Omnibus, influenciou fortemente o design de computadores subsequentes, incluindo a arquitetura de slots de expansão encontrada nos primeiros PCs da IBM.

Portanto, o PDP-8 e o seu Omnibus têm uma relevância crucial para a evolução da computação, ao introduzirem a ideia de computadores compactos e customizáveis. O conceito de um barramento de expansão, como o Omnibus, continuou a ser uma característica padrão em muitos sistemas de computação posteriores, permitindo uma maior flexibilidade e capacidade de personalização dos sistemas de computador.

2.4 Terceira geração - circuitos integrados (1965-1980)

A invenção do circuito integrado de silício por Jack Kilby e Robert Noyce (trabalhando independentemente) em 1958 permitiu que dezenas de transistores fossem colocados em um único chip. Esse empacotamento possibilitava a construção de computadores menores, mais rápidos e mais baratos do que seus precursores transistorizados. Alguns dos computadores mais significativos são descritos a seguir.

2.4.1 IBM System/360 (1964)

O IBM System/360, introduzido em 1964, representa um marco fundamental na evolução da computação, não apenas pelo seu poder computacional, mas também pela abordagem revolucionária na maneira como as organizações percebiam e investiam em hardware de computador.

Antes do System/360, os computadores eram essencialmente produtos individuais e autônomos. Quando uma empresa precisava atualizar para uma máquina mais poderosa, isso geralmente significava comprar um sistema completamente novo, reescrever o software e treinar novamente o pessoal. A IBM mudou essa realidade com a introdução do conceito de "família de computadores" no System/360.

A "família" referia-se a uma gama de modelos de computadores que, apesar de diferentes em termos de desempenho e preço, usavam a mesma arquitetura básica e eram compatíveis entre si a nível de software. Isso significava que as organizações podiam começar com um modelo menor e, à medida que suas necessidades de computação crescessem, podiam atualizar para um modelo maior sem a necessidade de reescrever o software existente ou de requalificar seu pessoal.

O System/360 também foi pioneiro em várias outras inovações técnicas, como a adoção de circuitos de semicondutores e a introdução do conceito de arquitetura de computadores com base em microprogramação. Essa arquitetura deu aos computadores a flexibilidade para emular outras máquinas ou adotar novas instruções conforme necessário.

Assim, a importância do IBM System/360 para a evolução da computação é indiscutível. Seu modelo de "família de computadores" permitiu a padronização e a compatibilidade de software em diferentes modelos de hardware, um princípio que permaneceu em vigor na indústria de computadores até hoje. Além disso, suas inovações técnicas ajudaram a moldar o futuro do design de computadores.

2.4.2 PDP-11 (1970)

O PDP-11, lançado pela Digital Equipment Corporation (DEC) em 1970, é uma figura histórica significativa no desenvolvimento da computação, contribuindo amplamente para as concepções modernas de hardware e sistemas operacionais.

A primeira grande inovação que o PDP-11 trouxe foi a arquitetura de conjunto de instruções uniformemente endereçável (Unibus), que simplificava e agilizava a comunicação entre os diferentes componentes do computador. Isso ajudou a tornar o PDP-11 um sistema de computador mais eficiente e fácil de programar, comparado aos seus antecessores.

No entanto, talvez a contribuição mais notável do PDP-11 para a computação seja sua influência no desenvolvimento de sistemas operacionais. O PDP-11 foi a máquina original em que o Unix, um dos sistemas operacionais mais influentes da história da computação, foi escrito. O Unix não apenas trouxe inovações significativas em termos de multitarefa e portabilidade, mas também foi a base para muitos sistemas operacionais modernos, incluindo o Linux e o BSD.

Além disso, o PDP-11 também é notável por seu impacto na formação de linguagens de programação modernas. A linguagem C, por exemplo, foi originalmente desenvolvida para a programação do sistema operacional Unix no PDP-11. A linguagem C tornou-se uma das linguagens de programação mais usadas e influenciou o desenvolvimento de várias outras linguagens, como C++, C#, Java e Python.

2.5 Quarta geração (1980-?)

Na década de 1980, a integração em larga escala (VLSI) permitiu a compactação de milhões de transistores em um único chip, gerando computadores mais compactos, rápidos e acessíveis. Isso inaugurou a era do computador pessoal, com aplicativos voltados para processamento de texto, criação de planilhas e jogos.

Os primeiros computadores pessoais vinham em forma de kits para montagem, cujo software precisava ser criado pelo usuário, até que o sistema operacional CP/M se popularizou. Apple e IBM, posteriormente, se destacaram no mercado de computadores pessoais com seus modelos Apple II e IBM Personal Computer, respectivamente. A IBM, além de produzir computadores pessoais, também incentivou o desenvolvimento de hardware por terceiros ao tornar público o projeto do seu computador. Isso estimulou a criação de clones de PCs, gerando uma nova indústria.

Com o advento do Macintosh da Apple, a interface gráfica do usuário se popularizou, o que, somado à demanda por mobilidade, impulsionou o surgimento dos

computadores portáteis, destacando-se os modelos Osborne-1 e o portátil da Compaq, clone do IBM PC.

Na mesma época, a Microsoft fornecia o sistema operacional MS-DOS para o IBM PC. Embora a IBM e a Microsoft tenham trabalhado juntas no desenvolvimento do OS/2, a Microsoft também desenvolveu o seu próprio sistema operacional, o Windows, que se tornou um grande sucesso.

Ao mesmo tempo, a Intel continuou a evoluir seus processadores, destacando-se o 80486 e, posteriormente, a linha Pentium e Core, amplamente usados nos PCs modernos, consolidando a arquitetura x86.

Na metade dos anos 1980, a arquitetura RISC ganhou espaço, sendo seguida pelo advento das CPUs superescalares na década de 1990, que permitiam a execução de várias instruções simultaneamente.

No campo de hardware, o FPGA (Field-Programmable Gate Array), desenvolvido por Ross Freeman e seus colegas na Xilinx, proporcionou flexibilidade de projeto e viabilizou a montagem de sistemas computacionais especializados para aplicações específicas.

Até 1992, a maioria dos computadores pessoais utilizava sistemas de 8, 16 ou 32 bits. Nesse ano, a DEC introduziu o Alpha de 64 bits, um dispositivo RISC revolucionário que superava significativamente outros computadores pessoais em desempenho. Contudo, só aproximadamente uma década depois é que as máquinas de 64 bits começaram a ganhar destaque, principalmente como servidores de alto desempenho.

Na década de 1990, os computadores se tornavam cada vez mais rápidos através de melhorias microarquitetônicas. Isso incentivava os usuários a atualizarem seus sistemas, pois cada novo equipamento processava programas com maior velocidade que o anterior. Entretanto, no final da década, a velocidade de melhoria começou a diminuir devido aos desafios no design dos computadores. Os arquitetos estavam esgotando as possibilidades para aumentar a velocidade dos programas e os processadores estavam se tornando mais difíceis e caros para resfriar.

Neste contexto, muitas empresas de computação passaram a explorar arquiteturas paralelas como uma maneira de melhorar o desempenho dos seus chips.

Em 2001, a IBM introduziu a arquitetura dual core POWER4, marcando a primeira vez que uma CPU importante incluía dois processadores no mesmo substrato. Hoje, a maioria dos processadores para desktops, servidores e até mesmo alguns processadores integrados, incorporam múltiplos processadores no mesmo chip.

2.6 Quinta geração - computadores de baixa potência e invisíveis

A transição inesperada para a quinta geração de computadores ocorreu quando esses dispositivos começaram a diminuir de tamanho. Em 1989, a Grid Systems introduziu o primeiro tablet, o GridPad, que permitia aos usuários controlar o sistema por meio de uma caneta especial em uma tela sensível ao toque. Este e outros sistemas semelhantes demonstraram que os computadores não precisavam ser restritos a mesas ou salas de servidores; eles poderiam ser compactos, portáteis e mais valiosos com telas sensíveis ao toque e reconhecimento de escrita à mão.

Em 1993, a Apple lançou o Newton, um computador não maior que um tocador de fitas cassete portátil. Apesar de o reconhecimento de escrita à mão ter sido um desafio, dispositivos posteriores, agora chamados de PDAs (Assistentes Digitais Pessoais), aprimoraram as interfaces de usuário e se tornaram extremamente populares, dando origem aos smartphones de hoje.

Jeff Hawkins, o criador da Palm, aperfeiçoou a interface de escrita dos PDAs, desenvolvendo uma técnica chamada Graffiti. Isso demonstrou a capacidade de melhorar o reconhecimento de escrita à mão ao treinar os usuários a escreverem de uma maneira mais adequada para os computadores.

Quando os celulares ganharam popularidade no início dos anos 90, a IBM desenvolveu o primeiro smartphone, o Simon, combinando a funcionalidade de um PDA com as de um telefone celular, além de jogos e e-mail. A miniaturização dos componentes e a redução dos custos abriram caminho para a popularização dos smartphones, representados pelas plataformas iPhone da Apple e Android do Google.

No entanto, a verdadeira revolução pode estar nos chamados computadores invisíveis, incorporados em aparelhos domésticos, relógios, cartões bancários e outros dispositivos. A presença desses processadores em uma variedade de aplicações permite funcionalidades adicionais e redução de custos. Embora sua classificação como uma nova geração de computadores seja questionável, não se pode negar seu

impacto na transformação de inúmeros aparelhos e dispositivos. Uma peculiaridade desses computadores embutidos é que o hardware e o software são frequentemente projetados simultaneamente.

Andrew Tanenbaum e Todd Austin previram em seu livro *Organização Estruturada de Computadores* (2013) que os computadores embutidos se tornariam parte integral da vida cotidiana, controlando funções como abrir portas, acender luzes e disponibilizar dinheiro em caixas eletrônicos, entre outras funções. Essa previsão se concretizou nos dispositivos da Internet das Coisas (IoT), como a Alexa, que podem controlar vários aspectos da casa por comando de voz.

3 COMPUTAÇÃO MODERNA

O setor da computação está progredindo em um ritmo sem precedentes, e a principal força impulsionadora é a habilidade dos fabricantes de chips de aumentar o número de transistores embalados em cada chip a cada ano. Os transistores, que são minúsculos interruptores eletrônicos, permitem o aumento da capacidade de armazenamento e o desenvolvimento de processadores mais poderosos.

Durante a preparação de uma palestra para um grupo do setor, Gordon Moore observou que uma nova geração de chips de memória estava sendo lançada aproximadamente a cada três anos, e cada geração possuía quatro vezes mais memória do que sua antecessora. Ele percebeu que o número de transistores em um chip estava crescendo em uma taxa constante e previu que esse crescimento continuaria nas próximas décadas. Essa observação ficou conhecida como Lei de Moore.

Atualmente, a Lei de Moore é frequentemente expressa como o número de transistores dobrando a cada 18 meses. Vale ressaltar que isso equivale a um aumento de cerca de 60% no número de transistores por ano. A figura abaixo mostra o número de transistores e as datas de lançamento para cada chip.




Figura 14 – Lei de Moore
Fonte: Google Imagens (2023)

A Lei de Moore estabeleceu o que os economistas chamam de círculo virtuoso. Avanços na tecnologia resultam em produtos melhores e preços mais baixos. Preços mais baixos, por sua vez, impulsionam novas aplicações. Um exemplo disso é que, enquanto os computadores custavam milhões de dólares, as empresas de jogos de computador não existiam.

Essas novas aplicações levam à criação de novos mercados e empresas emergentes que aproveitam as vantagens desses mercados. A existência dessas empresas gera concorrência, que, por sua vez, impulsiona a demanda por melhores tecnologias, substituindo as anteriores. Assim, o círculo virtuoso completa uma volta.

Outro fator que impulsionou o avanço tecnológico foi a primeira lei do software, formulada por Nathan: "O software é como um gás. Ele se expande para preencher o recipiente que o contém". Na década de 1980, o processamento de texto era realizado por programas como o troff, que ocupava quilobytes de memória. Os modernos processadores de texto ocupam megabytes de memória, e os futuros certamente exigirão gigabytes de memória.

Consequentemente, o software continua adquirindo novas funcionalidades, criando uma demanda constante por processadores mais rápidos, memórias maiores e maior capacidade de E/S.

3.1 Tipos de computadores

De acordo com Tanenbaum e Austin (2013), os benefícios proporcionados pela Lei de Moore são explorados de diversas maneiras pelos fabricantes de chips. Um deles é a construção de computadores cada vez mais poderosos a um preço constante. Outra abordagem consiste em construir o mesmo computador por um custo monetário cada vez menor a cada ano. A indústria tem adotado ambas as estratégias e muito mais, resultando em uma ampla variedade de computadores, como veremos a seguir.

3.1.1 Computadores descartáveis



Figura 15 – RFID
Fonte: Google Imagens (2023)

Os computadores descartáveis são uma forma de tecnologia projetada para ser usada uma única vez e depois descartada. Isso pode parecer um desperdício, mas em muitos casos, esses dispositivos oferecem maneiras econômicas e eficientes de coletar e transmitir dados em situações onde um dispositivo reutilizável não seria prático ou até mesmo possível. Um exemplo proeminente de computadores descartáveis é a tecnologia de identificação por radiofrequência (RFID).

RFID é um sistema que utiliza ondas de rádio para identificar e rastrear objetos. Cada etiqueta RFID contém um pequeno chip e uma antena de rádio. O chip armazena dados como um número de identificação único ou outras informações específicas. Essas informações podem ser lidas por um leitor de RFID quando está dentro do alcance da etiqueta.

Existem dois tipos principais de etiquetas RFID: passivas e ativas. As etiquetas RFID passivas não possuem uma fonte de energia interna e dependem do leitor de RFID para fornecer a energia necessária para transmitir suas informações. Isso geralmente é feito por meio de um campo eletromagnético que o leitor gera. Devido à sua simplicidade e à falta de necessidade de uma fonte de energia, as etiquetas

passivas são geralmente mais baratas e menores, tornando-as ideais para uma ampla variedade de aplicações, incluindo rastreamento de produtos, controle de acesso, identificação de animais e muito mais.

Por outro lado, as etiquetas RFID ativas possuem uma fonte de energia interna, que pode ser uma bateria pequena. Isso permite que eles transmitam dados a distâncias muito maiores do que as etiquetas passivas, tornando-os úteis para rastreamento de veículos, monitoramento de ativos valiosos e outros usos que requerem leitura a longas distâncias.

Embora o termo "computadores descartáveis" possa levar algumas pessoas a pensar em dispositivos eletrônicos de curta duração ou de baixa qualidade, o uso de RFID e tecnologias semelhantes mostra que esses dispositivos podem desempenhar um papel importante na coleta de dados e na comunicação em nossa sociedade moderna.

3.1.2 Microcontroladores




Figura 16 – Microcontroladores
Fonte: Wikicommons (2023)

Os microcontroladores são sistemas compactos que incorporam um processador, memória e interfaces de entrada/saída em um único chip. São essencialmente pequenos computadores que podem ser programados para controlar uma variedade de funções e dispositivos. Devido ao seu tamanho compacto, baixo custo e alta versatilidade, os microcontroladores são uma parte fundamental de muitos dispositivos eletrônicos que usamos diariamente. Aqui estão alguns exemplos de como eles são utilizados:

- **Eletrodomésticos:** Microcontroladores são usados para controlar várias funções em dispositivos como fornos de micro-ondas, máquinas de lavar roupa, geladeiras e aspiradores de pó. Eles podem ser programados para gerenciar ciclos de lavagem, controlar a temperatura, monitorar sensores e muito mais.
- **Aparelhos de Comunicação:** Dispositivos como telefones celulares, walkie-talkies e modems usam microcontroladores para gerenciar a comunicação de dados, codificar e decodificar sinais e controlar interfaces de usuário.
- **Periféricos de Computadores:** Mouses, teclados, impressoras e outros periféricos de computador frequentemente incorporam microcontroladores. Eles são usados para interpretar entradas de usuário, gerenciar a comunicação com o computador principal e executar outras tarefas específicas do dispositivo.
- **Equipamento de Entretenimento:** Dispositivos como TVs, sistemas de som e consoles de videogame usam microcontroladores para processar entradas de usuário, gerenciar a exibição de gráficos, controlar o som e realizar muitas outras tarefas.
- **Aparelhos de Reprodução de Imagens:** Câmeras digitais, scanners e impressoras fotográficas utilizam microcontroladores para controlar sensores de imagem, gerenciar o processamento de imagem e controlar mecanismos físicos como lentes de câmera ou cabeças de impressão.

Além desses exemplos, os microcontroladores também são usados em uma ampla variedade de outras aplicações, incluindo controle de sistemas automotivos, automação industrial, robótica, sistemas médicos e muito mais. De fato, é difícil encontrar um dispositivo eletrônico moderno que não inclua pelo menos um microcontrolador.

3.1.3 Computadores móveis e de jogos

Os computadores móveis, como smartphones e tablets, revolucionaram a maneira como interagimos com a tecnologia e nos comunicamos uns com os outros. Esses dispositivos são caracterizados pela portabilidade, conectividade sem fio e

capacidade de executar uma ampla gama de aplicativos. Eles combinam funcionalidades de computação, comunicação e entretenimento em um único dispositivo pequeno o suficiente para ser transportado facilmente. Diferentemente de RFID e microcontroladores, que são geralmente componentes em sistemas maiores, computadores móveis são sistemas completos capazes de execução independente de uma variedade de tarefas.

Os computadores de jogos são máquinas de alto desempenho, especificamente projetadas para rodar jogos de vídeo com gráficos pesados e processamento intensivo. Esses computadores são equipados com hardware potente, como CPUs de alta velocidade, grandes quantidades de memória RAM (*Random Access Memory*) e unidades de processamentos gráficos (GPUs) avançadas, para proporcionar experiências de jogo suaves e visuais impressionantes. Além disso, eles podem incluir recursos específicos para jogos, como iluminação RGB (*Red/Green/Blue*, ou em português, vermelho/verde/azul), resfriamento líquido e design de gabinete personalizado. Eles diferem de servidores e mainframes, que são projetados para gerenciar grandes quantidades de dados, executar tarefas complexas e servir múltiplos usuários simultaneamente, em vez de otimizar a experiência de um único usuário.

3.1.4 Computadores pessoais

Os computadores pessoais, também conhecidos como PCs, são sistemas de computador projetados para serem usados por um indivíduo de cada vez. Desde sua popularização nas décadas de 1970 e 1980, eles se tornaram uma parte essencial de nossas vidas pessoais e profissionais.

Um PC típico inclui uma unidade central de processamento (CPU) para executar programas, memória para armazenar dados, uma variedade de dispositivos de entrada e saída (como teclado, mouse e monitor) e um sistema operacional que gerencia e coordena todas essas funções. Os PCs podem ser tanto desktops, que são projetados para serem colocados em uma mesa ou similar, ou laptops, que são portáteis e podem ser facilmente transportados.

Os computadores pessoais diferem significativamente de outros tipos de computadores em termos de finalidade, custo, tamanho e poder de processamento. Por exemplo, ao contrário dos mainframes e servidores, que são projetados para lidar

com tarefas complexas e servir a muitos usuários simultaneamente, os PCs são projetados principalmente para atender às necessidades de um único usuário de cada vez.

Além disso, ao contrário de dispositivos como microcontroladores e RFIDs, que são normalmente componentes de sistemas maiores e servem a funções muito específicas, os PCs são sistemas completos e versáteis capazes de executar uma ampla gama de tarefas, desde navegar na web e escrever documentos até jogar videogames e editar vídeos.

Os PCs também diferem dos computadores móveis, como smartphones e tablets, em termos de formato, capacidades de entrada e saída e, frequentemente, em termos de desempenho e capacidade de armazenamento. Embora os computadores móveis sejam excelentes para tarefas em movimento e tenham capacidades de conectividade sem fio, os PCs, com seus teclados maiores, monitores e hardware mais poderoso, geralmente oferecem uma experiência de usuário mais confortável e produtiva para tarefas intensivas ou de longa duração.

3.1.5 Servidores

Os servidores são sistemas de computador poderosos e robustos que fornecem recursos, dados ou serviços para outros computadores, conhecidos como clientes, em uma rede. Embora se pareçam com computadores pessoais em termos de componentes básicos, como CPU, memória e dispositivos de armazenamento, eles diferem em termos de finalidade, desempenho, confiabilidade e capacidade de gerenciamento.

A principal diferença entre servidores e outros tipos de computadores, como PCs, é que os servidores são projetados para processar e gerenciar grandes volumes de dados, atender a múltiplas solicitações simultâneas de usuários e operar 24 horas por dia, 7 dias por semana. Além disso, eles possuem recursos redundantes para garantir a continuidade do serviço em caso de falhas, e têm maior capacidade de processamento e armazenamento em comparação com um PC comum.

Dentro das categorias de servidores existem os clusters de computadores, que são conjuntos de servidores conectados que trabalham juntos, de modo que, em muitos aspectos, eles funcionam como um único sistema. Esse arranjo oferece alta

disponibilidade, pois se um servidor falhar, os outros podem assumir suas tarefas. Além disso, os clusters podem oferecer melhor desempenho, pois as tarefas são divididas entre vários servidores, e a capacidade do sistema pode ser aumentada simplesmente adicionando mais servidores ao cluster.

Ainda em servidores podemos falar de computação em nuvem, que é um modelo de prestação de serviços de computação que utiliza servidores remotos hospedados na Internet para armazenar, gerenciar e processar dados, em vez de um servidor local ou um PC pessoal. A computação em nuvem oferece benefícios como escalabilidade, custo-benefício e acesso a dados em qualquer lugar com conexão à internet. Essa tecnologia depende de data centers de grande escala, que são enormes coleções de servidores que fornecem a infraestrutura necessária para suportar a computação em nuvem.

Tanenbaum e Austin (2013) já previram um possível gargalo para a popularização da computação em nuvem, na qual a infraestrutura para a comunicação com toda essa tecnologia começasse a limitar o modelo. Uma das soluções para esse problema foi o *edge computing*.

3.1.6 Edge computing

Edge computing, ou computação de borda, é um modelo de computação distribuída que traz o processamento de dados para mais perto da fonte dos dados, ou "borda" da rede. Essa abordagem busca reduzir a latência, melhorar a eficiência e permitir aplicações em tempo real que requerem respostas rápidas.

A ideia básica por trás da computação de borda é processar os dados onde eles são gerados, em vez de enviá-los para um data center ou nuvem centralizada para processamento. Isso é especialmente benéfico em cenários onde a latência é um problema, ou onde a transmissão de grandes volumes de dados para a nuvem não é prática ou custo-efetiva.

Um exemplo de aplicação da computação de borda é a Internet das Coisas (IoT). Os dispositivos IoT, como sensores e câmeras, geram enormes quantidades de dados. Ao processar esses dados localmente, a computação de borda pode proporcionar insights em tempo real, economizar largura de banda e aumentar a privacidade, pois menos dados sensíveis são enviados através da rede.

A computação de borda é complementar à computação em nuvem, não a substitui. Enquanto a computação em nuvem é ideal para tarefas que requerem grande poder de processamento e armazenamento, mas não são sensíveis à latência, a computação de borda é mais adequada para tarefas que requerem respostas rápidas ou operam em locais com conectividade limitada.

3.1.7 Mainframes

Os mainframes são computadores de grande porte, poderosos e confiáveis, projetados para processar grandes volumes de dados e realizar tarefas computacionais intensivas. Eles desempenham um papel crucial em muitas indústrias, incluindo finanças, saúde e telecomunicações, onde suportam milhares de usuários simultâneos e processam transações massivas, como processamento de cartões de crédito e operações bancárias online.

Um aspecto chave que distingue os mainframes de outros tipos de computadores é sua alta confiabilidade e disponibilidade. Os mainframes são projetados para funcionar 24 horas por dia, 7 dias por semana, com pouquíssimo tempo de inatividade. Eles possuem recursos redundantes, como múltiplas CPUs, discos rígidos e fontes de alimentação, para garantir a continuidade do serviço mesmo em caso de falha de um componente.

Outra característica importante dos mainframes é sua capacidade de processamento paralelo, que permite que eles executem várias tarefas ao mesmo tempo. Isso, juntamente com a sua capacidade de gerenciar grandes volumes de dados e usuários simultâneos, torna os mainframes particularmente adequados para aplicações que requerem alto desempenho e disponibilidade.

Os mainframes também se destacam na segurança e integridade dos dados. Eles oferecem vários níveis de segurança, incluindo controle de acesso, criptografia de dados e auditorias de segurança, para proteger contra acessos não autorizados e garantir a privacidade dos dados.

Apesar da ascensão da computação em nuvem e servidores baseados em x86, os mainframes continuam a ser uma parte essencial da infraestrutura de TI de muitas organizações. Eles têm evoluído ao longo do tempo para suportar modernos sistemas

operacionais, linguagens de programação e protocolos de rede, tornando-os um componente flexível e contemporâneo do ecossistema de TI.

Dessa forma, os mainframes são sistemas de computador de alto desempenho, confiáveis e seguros que fornecem a espinha dorsal para muitas das aplicações de missão crítica em nosso mundo digital. Sua capacidade de processar grandes volumes de dados e transações, juntamente com sua confiabilidade e recursos de segurança robustos, garantem que eles continuarão a desempenhar um papel importante na infraestrutura de TI por muitos anos.

4 PRINCIPAIS ARQUITETURAS

Durante esta seção vamos falar sobre três arquiteturas de conjunto de instruções (*Instruction Set Architecture* -ISAs) mais populares: x86, ARM (*Advanced RISC Machine*, ou em português, máquina RISC avançada) e AVR (*Advanced Video Coding*, ou em português, codificação de vídeo avançada).

A x86 é encontrada em quase todos os sistemas de computadores pessoais, incluindo Windows, Linux e Macs (os mais antigos) e servidores. Por sua vez, a arquitetura ARM domina o mercado dos smartphones e dispositivos móveis. A maioria dos smartphones, computadores tablets e os macs mais novos é baseada em processadores ARM. Já a arquitetura AVR, é empregada em microcontroladores de muito baixo custo, encontrados em muitas aplicações de computação embutidas.

4.1 Arquitetura x86

A Intel Corporation foi estabelecida em 1968 com o objetivo de produzir chips de memória. O primeiro chip, chamado de 4004, foi desenvolvido para ser utilizado em uma calculadora fabricada pela empresa Busicom. Assim, surgiu a primeira CPU de um único chip contendo 2.300 transistores (TANENBAUM; AUSTIN, 2013).

A segunda versão desse chip foi lançada em 1972, apresentando 16 KB de memória e 3.500 transistores, com uma velocidade de clock de 0,108 MHz. Esse projeto despertou grande interesse em várias empresas e impulsionou o desenvolvimento do 8080, que alcançou a venda de milhões de unidades com seus 2

MHz de clock, 6 mil transistores e 64 KB de memória. A Intel continuou a desenvolver outros chips, como o 8086 e o 8088. Este último foi escolhido pela IBM para seus computadores pessoais, o que o tornou um padrão no mercado.

Conforme a demanda por maior capacidade de processamento crescia, a Intel expandia a capacidade de seus chips, aumentando a memória, o número de transistores e o clock de cada um. Destacam-se o 80286, que introduziu a proteção de memória, o 80386, que foi a primeira CPU de 32 bits, e o 80486, que apresentava 8 KB de memória cache embutida no chip. A memória cache é utilizada para armazenar as palavras de memória mais frequentemente acessadas pela CPU, evitando a necessidade de acessar a memória principal, o que tornava todo o processo mais lento.

Outra característica importante do 80486 era o suporte a multiprocessamento, permitindo que os fabricantes construíssem sistemas com várias CPUs que compartilhavam uma memória em comum. O 80486 foi seguido pelo Pentium, que possuía duas *pipelines* (segmentação de instruções).

Posteriormente, a Intel acrescentou à sua linha de produção as instruções MMX (*MultiMedia eXtension*, ou em português, extensão multimídia), que tinham como objetivo acelerar os cálculos necessários para processar áudio e vídeo, eliminando a necessidade de adicionar coprocessadores especiais de multimídia.

A próxima geração introduziu o Pentium Pro, que reestruturou internamente o chip, permitindo a execução de cinco instruções simultâneas e apresentando memória cache de dois níveis. Pouco depois, foram desenvolvidos chips com instruções multimídia adicionais, conhecidos como SSE (*Streaming SIMD Extensions*). O Pentium III possuía esse recurso, embora essa fosse sua única vantagem em relação ao Pentium II.

Em 2000, a Intel lançou o Pentium 4, que trouxe a capacidade de hiperprocessamento, um recurso que permitia que programas dividissem suas tarefas em dois threads de controle que o Pentium 4 podia executar em paralelo, acelerando a execução. Além disso, foram adicionadas novas instruções SSE para aumentar ainda mais o processamento de áudio e vídeo.

Em 2006, a Intel mudou a marca Pentium para Core e lançou o chip dual core Core 2 Duo. Quando a Intel decidiu oferecer uma versão mais barata de seu processador com apenas um núcleo, ela optou por vender o Core 2 Duo com um dos

núcleos desabilitados. Isso se deve ao fato de ser mais econômico desperdiçar um núcleo em um chip já fabricado do que incorrer nos altos custos de projetar e testar um novo chip do zero. A linha Core continuou a evoluir com os modelos i3, i5, i7 e i9, que se tornaram variantes populares para computadores de desempenho baixo, médio e alto.

Além das CPUs de uso geral para desktop discutidas anteriormente, a Intel também produziu variantes de alguns dos chips Pentium para mercados específicos. No início de 1998, a empresa lançou uma linha de produtos chamada Celeron, que era uma versão de baixo custo e desempenho reduzido do Pentium II, voltada para computadores de nível básico. Em junho de 1998, introduziu uma versão especial do Pentium II para o segmento mais avançado do mercado, conhecida como Xeon. Esse processador apresentava uma cache maior, barramento mais rápido e melhor suporte para sistemas de múltiplos processadores.

Em 2003, a Intel lançou o Pentium M (Mobile), um chip projetado para notebooks. Esse chip fazia parte da arquitetura Centrino, que tinha como objetivos reduzir o consumo de energia para aumentar a vida útil da bateria, criar computadores menores e mais leves e oferecer conectividade sem fio embutida usando o padrão IEEE 802.11 (WiFi).

O Pentium M consumia consideravelmente menos energia e era fisicamente menor que o Pentium 4, características que logo permitiram que ele substituísse a microarquitetura do Pentium 4 em produtos futuros da Intel.

No entanto, à medida que os processadores avançavam em capacidade de processamento a cada geração, um problema começou a surgir: o superaquecimento. Com a redução do tamanho dos transistores, era possível operar em frequências de clock mais altas, mas isso exigia o uso de uma voltagem maior. O consumo de energia e o calor dissipado são diretamente proporcionais ao quadrado da voltagem elétrica, o que significa que um processamento mais rápido resulta em um aumento significativo do calor gerado.

Em 2004, a Intel cancelou o lançamento do Pentium 4 de 4 GHz devido a problemas de dissipação de calor. Como consequência, o avanço do clock dos processadores pode ter alcançado um limite, pelo menos até que os engenheiros da Intel encontrem soluções eficientes para o gerenciamento de calor. Em vez disso, as

fabricantes de chips atualmente estão direcionando seus esforços para colocar duas ou mais CPUs em um único chip, juntamente com uma grande cache compartilhada.

4.2 Arquitetura ARM

A arquitetura ARM foi concebida pela empresa Acorn Computer como uma resposta ao recém-lançado IBM PC, no entanto, eles reconheceram que não conseguiriam competir com o poderoso processador de 16 bits 8086 da IBM. Inspirados pelo projeto RISC da Berkeley, que tinha desenvolvido um processador notavelmente rápido, a Acorn decidiu criar sua própria CPU, conhecida como Acorn RISC Machine (ARM). O projeto foi concluído em 1985 e contava com instruções e dados de 32 bits, um espaço de endereçamento de 26 bits e foi fabricado pela VLSI Technology.

De acordo com Tanenbaum e Austin (2013), a primeira iteração da arquitetura ARM, chamada de ARM2, foi utilizada no computador pessoal Acorn Archimedes. O Archimedes era uma máquina rápida e acessível para a época, atingindo até 2 MIPS (milhões de instruções por segundo) e sendo vendida por apenas 899 libras esterlinas no seu lançamento. Essa máquina tornou-se especialmente popular no Reino Unido, Irlanda, Austrália e Nova Zelândia, principalmente em ambientes educacionais.

Com base no sucesso do Archimedes, a Apple entrou em contato com a Acorn para desenvolver um processador ARM para o seu próximo projeto, o Apple Newton, o primeiro computador palmtop. Para se concentrar totalmente nesse novo empreendimento, a equipe de arquitetura ARM deixou a Acorn e fundou uma nova empresa chamada Advanced RISC Machines (ARM).

O processador resultante, chamado de ARM 610, foi usado no Apple Newton quando foi lançado em 1993. Ao contrário do projeto ARM original, esse novo processador ARM incorporava uma cache de 4KB, o que significativamente melhorou o desempenho do projeto.

Na metade da década de 1990, a ARM colaborou com a Digital Equipment Corporation para desenvolver uma versão de alta velocidade e baixo consumo de energia do processador ARM, voltada para aplicações móveis com recursos limitados de energia, como PDAs. Esse projeto resultou no StrongARM, que causou grande impacto na indústria devido à sua alta velocidade e baixo consumo de energia. Ele alcançou eficiência por meio de um design simples e limpo, que incluía duas caches de

16 KB para instruções e dados. O StrongARM e suas variantes foram moderadamente bem-sucedidos no mercado, sendo utilizados em diversos PDAs, dispositivos de mídia, transdutores de TV e roteadores.

Uma das arquiteturas ARM mais amplamente adotadas é o projeto ARM7, lançado inicialmente pela ARM em 1994 e ainda amplamente utilizado nos dias de hoje. Esse projeto incluía caches separadas para instruções e dados, e também incorporava o conjunto de instruções Thumb de 16 bits.

O conjunto de instruções Thumb é uma versão reduzida do conjunto de instruções completo de 32 bits do ARM, que permite aos programadores codificar operações comuns em instruções menores de 16 bits, reduzindo significativamente a quantidade de memória de programa necessária.

O processador ARM7 foi bem-sucedido em uma ampla variedade de aplicações embarcadas, de nível básico a avançado, incluindo aparelhos como torradeiras, controle de motores e até mesmo o console de jogos portátil Game Boy Advance da Nintendo.

Diferentemente de muitas empresas de computadores, a ARM não fabrica microprocessadores. Em vez disso, ela desenvolve projetos, ferramentas e bibliotecas baseados na arquitetura ARM, licenciando-os para projetistas de sistemas e fabricantes de chips. Por exemplo, o processador usado no tablet Samsung Galaxy Tab, baseado no sistema operacional Android, é um processador ARM licenciado.

Os primeiros modelos do Samsung Galaxy Tab vinham equipados com um processador Tegra 2, uma solução integrada (SoC) que incluía dois núcleos de processamento ARM Cortex-A9 e uma unidade de processamento gráfico Nvidia GeForce. Os núcleos do Tegra 2 foram desenhados pela ARM, integrados em um design SoC pela Nvidia e produzidos pela Taiwan Semiconductor Manufacturing Company (TSMC).

O Tegra 2 da Nvidia incorporava três processadores ARM: dois núcleos ARM Cortex-A9 de 1.2 GHz, além de um núcleo ARM7. Os núcleos Cortex-A9 são núcleos de emissão dual fora de ordem e possuem uma cache de L2 de 1MB, com suporte para multiprocessamento em memória compartilhada. Essas características tornavam o design extremamente rápido para a época. O núcleo ARM7, um núcleo ARM mais antigo e menor, era usado para configuração de sistema e gestão de energia. O design

incluía ainda uma GPU GeForce de 333 MHz, otimizada para operação de baixa potência.

O chip Apple A14 Bionic, introduzido em 2020, é um dos exemplos mais notáveis. Ele alimenta a série iPhone 12 e o iPad Air (4ª geração). Este chip usa a arquitetura ARMv8.4-A e é fabricado usando o processo de 5 nanômetros da TSMC. É composto por seis núcleos de CPU, incluindo dois núcleos de alto desempenho e quatro núcleos de eficiência energética, além de quatro núcleos de GPU e uma unidade de aprendizado de máquina de 16 núcleos. O A14 Bionic é amplamente reconhecido por seu desempenho superior e eficiência energética.

Outro exemplo é o Qualcomm Snapdragon 888, também lançado em 2020. Este chip, com arquitetura ARMv8.2-A, foi projetado para alimentar smartphones Android de última geração. Ele inclui oito núcleos de CPU - um núcleo Kryo 680 Prime, três núcleos Kryo 680 Performance e quatro núcleos Kryo 680 Efficiency. O Snapdragon 888 também inclui uma GPU Adreno 660 e um módulo de aprendizado de máquina Hexagon 780.

Além disso, a Apple lançou o chip M1 em 2020, que é usado em sua linha de computadores Mac. Este chip, que também usa a arquitetura ARM, inclui oito núcleos de CPU (quatro de alto desempenho e quatro de eficiência energética), oito núcleos de GPU e 16 núcleos para sua unidade de aprendizado de máquina. A Apple afirma que o M1 oferece desempenho de CPU líder de classe e eficiência energética superior aos chips Intel que foram usados em Macs anteriores.

4.3 Arquitetura AVR

O terceiro exemplo trata da arquitetura AVR, amplamente aplicada em sistemas embarcados de baixo nível. A criação do AVR remonta a 1996, no Norwegian Institute of Technology, onde Alf-Egil Bogen e Vegard Wollan, então estudantes, projetaram uma CPU RISC de 8 bits batizada de AVR. Em 1997, o AT90S1200 foi lançado. A fim de facilitar sua incorporação pelos designers de sistemas, seus criadores mantiveram a mesma pinagem do Intel 8051, um dos microcontroladores mais populares da época. Atualmente, a arquitetura AVR desperta grande interesse, pois é o cerne da plataforma de controle embarcado Arduino, de código aberto.

A arquitetura AVR é implementada em três categorias de microcontroladores. A primeira, denominada tiny AVR, foi desenvolvida para aplicações limitadas em termos de superfície, energia e custo. Inclui uma CPU de 8 bits, suporte básico para entrada/saída (I/O) digital e suporte para entrada analógica. O tinyAVR é tão compacto que seus pinos desempenham múltiplas funções, podendo ser reprogramados em tempo real para qualquer uma das funções digitais ou analógicas que o microcontrolador suporta. O megaAVR, encontrado no popular Arduino de código aberto, adiciona suporte para I/O serial, clocks internos e saídas analógicas programáveis. Já o topo de linha na série de baixo custo é o microcontrolador AVR XMEGA, que também incorpora um acelerador para operações criptográficas e suporte adicional para interfaces USB.

Além de vários periféricos adicionais, cada classe de processador AVR apresenta recursos adicionais de memória. Os microcontroladores geralmente possuem três tipos de memória no chip: flash, EEPROM e RAM. A memória flash é programável por meio de uma interface externa e altas tensões, e é usada para armazenar código de programa e dados.

A memória flash é não volátil, de modo que, mesmo que o sistema perca energia, a memória flash preservará os dados armazenados. A EEPROM, semelhante a flash, também é não volátil, porém, ao contrário da memória flash, pode ser alterada pelo programa enquanto está em execução. Esta é a memória onde um sistema embarcado guardaria informações de configuração do usuário, como se o relógio deve exibir a hora no formato de 12 ou 24 horas.

Por fim, a RAM é onde as variáveis do programa são armazenadas durante a execução do programa. Esta memória é volátil, então quaisquer dados armazenados nela serão perdidos quando o sistema perder energia.

De acordo com Tanenbaum e Austin (2013), o segredo do sucesso na indústria de microcontroladores é integrar no chip todos os recursos possivelmente necessários, embalando-o de maneira compacta e acessível, com um número mínimo de pinos. O microcontrolador Atmel ATmega168 AVR exemplifica bem essa estratégia. Ele apresenta três temporizadores, um relógio de tempo real com oscilador, seis canais para modulação de largura de pulso (usados para controlar a intensidade da luz), oito canais de conversão analógico-digital, um transceptor serial, uma interface serial I2C,

um temporizador de vigia, um comparador analógico no chip, um detector de falha de energia e um oscilador de clock interno programável.

A capacidade de ter tantas funcionalidades embutidas em um único chip pequeno e de baixo custo torna a arquitetura AVR uma opção atrativa para os designers de sistemas embarcados. Este modelo, juntamente com a disponibilidade de ferramentas de código aberto como o Arduino, ajudou a popularizar o uso de microcontroladores AVR em uma variedade de aplicações, desde hobbyismo a projetos de desenvolvimento profissional. Portanto, a arquitetura AVR se destaca como uma opção poderosa e versátil para projetos de sistemas embarcados.

4.4 Unidades

Para encerrarmos a seção vamos falar um pouco sobre as unidades métrica usadas na computação.

Os prefixos de cada unidade são abreviados por suas primeiras letras, sendo a unidade maior do que 1 em maiúsculas.

Exponente	Explícito	Prefixo
10^{-3}	0,001	milli
10^{-6}	0,000001	micro
10^{-9}	0,000000001	nano
10^{-12}	0,000000000001	pico
10^{-15}	0,000000000000001	femto
10^{-18}	0,000000000000000001	ato
10^{-21}	0,000000000000000000001	zepto
10^{-24}	0,000000000000000000000001	yocto

Tabela 1 – Unidades 1
Fonte: Elaborada pelo autor (2023)

Exponente	Explícito	Prefixo
10^3	1000	kilo
10^6	1000000	mega
10^9	1000000000	giga
10^{12}	1000000000000	Terá
10^{15}	1000000000000000	peta
10^{18}	1000000000000000000	exa
10^{21}	1000000000000000000000	zeta
10^{24}	1000000000000000000000000	íota

Tabela 2 – Unidades 2
Fonte: Elaborada pelo autor (2023)

Outro detalhe que é importante lembrar é a questão de que o tamanho de memórias, discos, arquivos e bancos de dados, têm um significado um pouco diferente. Kilo, significa 2¹⁰ seria (1024) em vez de 10³ (1000), porque as memórias são sempre uma potência de dois. Assim um 1 KB contém 1024 bytes.

Um aspecto crucial a se recordar é que as medidas de tamanho para memória, discos, arquivos e bancos de dados possuem um significado um pouco distinto. Aqui, o termo "kilo" refere-se a 2¹⁰ (ou seja, 1024), e não a 10³ (ou seja, 1000), já que as capacidades de memória sempre seguem potências de dois. Portanto, 1KB corresponde a 1024 bytes.

5 ORGANIZAÇÃO DE COMPUTADORES

Cada computador digital consiste de alguns componentes que, segundo Tanenbaum e Austin (2013), são um sistema interconectado de processadores, memória e dispositivos de entrada/saída (E/S ou I/O). Vamos começar analisando o primeiro deles, o processador.

5.1 Processador

Para entender a fundo a organização de um computador vamos ver um exemplo na figura abaixo de uma máquina simples composta de uma CPU, Memória e dois dispositivos de E/S.




Figura 17 – Organização de um computador simples
Fonte: Google Imagens (2023)

A Unidade Central de Processamento (CPU) pode ser considerada o "cérebro" do computador, pois é responsável por executar os programas armazenados na memória principal, analisando e executando suas instruções de forma sequencial. Os diferentes componentes da CPU são interligados por um conjunto de fios paralelos conhecidos como barramento, que permitem a transmissão de endereços, dados e sinais de controle. Esses barramentos podem estar fora da CPU, ligando-a à memória e aos dispositivos de entrada e saída, mas também podem estar internamente na CPU.

A CPU é formada por várias partes, incluindo a unidade de controle, que busca instruções na memória principal e determina seu tipo, e a Unidade Lógica e Aritmética (ULA), que realiza operações como adição e AND booleano para executar as instruções. Também há uma memória pequena e rápida, composta de vários registradores, usada para armazenar resultados temporários e para controlar certas informações. Cada registrador tem uma função e um tamanho específicos e pode conter um número até um limite definido por seu tamanho. Os registradores podem ser lidos e escritos rapidamente, pois estão localizados internamente na CPU.

O Contador de Programa (PC - Program Counter), que aponta para a próxima instrução a ser executada, é um dos registradores mais importantes. Vale ressaltar também o Registrador de Instrução (IR - Instruction Register), que mantém a instrução

atualmente em execução. A maioria dos computadores possui ainda outros registradores, alguns de uso geral e outros de uso específico.

5.1.1 Organização da CPU

A estrutura interna de uma seção típica de uma CPU baseada na arquitetura de von Neumann é mais detalhadamente ilustrada na Figura 5-2. Essa seção é chamada de "caminho de dados" e consiste em registradores, a Unidade Lógica e Aritmética (ULA) e vários barramentos que interconectam esses componentes. Os registradores fornecem dados para dois registradores de entrada na ULA, que são representados como A e B na figura mencionada. Estes mantêm as entradas da ULA enquanto esta realiza uma operação computacional.




Figura 18 – Caminho de dados de uma máquina von Neumann
Fonte: TANENBAUM; AUSTIN (2013)

A unidade lógica e aritmética (ULA) realiza operações simples como adição e subtração em suas entradas, gerando um resultado que é colocado em um registrador de saída. Este resultado pode ser armazenado em um registrador e, posteriormente, gravado na memória, caso necessário. Note que nem todos os designs de CPU possuem registradores A, B e de saída. No exemplo citado, é ilustrada uma operação de adição entre dois valores (A e B).

Muitas instruções podem ser classificadas em duas categorias principais: instruções de registrador-memória e instruções de registrador-registrador. As instruções de registrador-memória permitem que dados da memória sejam transferidos para os registradores, onde podem ser utilizados como entradas da ULA em instruções

subsequentes. Aqui, as "palavras" são as unidades de dados que são movimentadas entre a memória e os registradores (uma palavra pode ser, por exemplo, um número inteiro).

O outro tipo, instruções de registrador-registrador, envolve a busca de dois operandos nos registradores, sua transferência para os registradores de entrada da ULA, a realização de uma operação com eles, e o armazenamento do resultado nos registradores. Esse processo de passar dois operandos pela ULA e armazenar o resultado é chamado de ciclo do caminho de dados e é fundamental na operação da maioria das CPUs.

De fato, ele tem um papel significativo na definição do que a máquina pode fazer. Quanto mais rápido for o ciclo do caminho de dados, mais rápida será a operação da máquina.

5.1.2 Execução de instrução

Segundo Tanenbaum e Austin (2013), a CPU executa cada instrução em uma série de pequenas etapas. Em termos simples, as etapas são as seguintes:

- 1 Trazer a próxima instrução da memória até o registrador;
- 2 Alterar o contador de programa para que aponte para a próxima instrução;
- 3 Determinar o tipo de instrução trazida;
- 4 Se a instrução usar uma palavra na memória, determinar onde essa palavra está;
- 5 Trazer a palavra para dentro de um registrador da CPU, se necessário;
- 6 Executar a instrução;
- 7 Voltar à etapa 1.

Essa sequência de etapas costuma ser denominada ciclo buscar-decodificar-executar. É fundamental para operação de todos os computadores.

5.1.3 Paralelismo e *pipelining*

Os arquitetos de computação estão constantemente buscando maneiras de aprimorar o desempenho dos sistemas que criam. Aumentar a velocidade de clock dos chips é uma estratégia, porém, para cada nova inovação, existe um limite de quão longe

a força bruta pode levar em dado momento histórico. Assim, muitos desses arquitetos recorrem ao paralelismo (realizar duas ou mais tarefas simultaneamente) como uma forma de obter desempenho superior na mesma velocidade de clock.

O paralelismo pode ser dividido em duas categorias gerais: no nível de instrução e no nível de processador. No primeiro, o paralelismo é explorado dentro de instruções individuais para fazer com que o sistema execute mais instruções por segundo. No segundo, várias CPUs colaboram para resolver um mesmo problema. Cada método tem suas vantagens. Nesta seção, vamos analisar o paralelismo no nível de instrução; na próxima seção, focaremos no paralelismo no nível de processador.

5.1.4 Pipelining (paralelismo nível de instrução)

Um dos principais obstáculos para a velocidade de execução de instruções é o processo de recuperação de uma instrução da memória. Para superar essa barreira, desde 1959, foi desenvolvido o método de pré-busca de instruções da memória, garantindo que estariam disponíveis quando necessárias. Essas instruções eram armazenadas em um conjunto de registradores conhecidos como buffer de pré-busca. Assim, quando necessário, uma instrução poderia ser recuperada do buffer de pré-busca, evitando a espera pela conclusão de uma leitura de memória.

A pré-busca divide a execução da instrução em duas partes: a busca e a execução da instrução. O conceito de *pipeline* (paralelismo, canalização) expande ainda mais essa estratégia. Em vez de dividir a execução da instrução em apenas duas partes, muitas vezes ela é dividida em várias etapas, cada uma sendo gerenciada por uma parte dedicada do hardware, todas podendo ser executadas em paralelo.

Imagine, então, um pipeline com cinco unidades, também conhecidas como estágios. O estágio 1 (S1) busca a instrução na memória, o estágio 2 (S2) decodifica a instrução, determinando seu tipo e quais operandos são necessários. O estágio 3 (S3) localiza e busca os operandos, seja nos registradores ou na memória. O estágio 4 (S4) é responsável pela execução da instrução, fazendo os operandos percorrerem o caminho de dados. Finalmente, o estágio 5 (S5) grava o resultado de volta no registrador apropriado. A tabela abaixo oferece um exemplo visual desse processo.

S1:	1	2	3	4	5	6	7	8	9
S2:		1	2	3	4	5	6	7	8
S3:			1	2	3	4	5	6	7
S4:				1	2	3	4	5	6
S5:					1	2	3	4	5
Clock	1	2	3	4	5	6	7	8	9

Tabela 3 – Pipeline
Fonte: Elaborada pelo autor (2023)

Então, durante o primeiro ciclo, o estágio S1 está processando a instrução 1, buscando-a na memória. No segundo ciclo, o estágio S2 decodifica a instrução 1 e o estágio S1 busca a instrução 2 na memória. No terceiro ciclo, o estágio S3 busca os operandos da instrução 1, enquanto o estágio S1 busca a instrução 3. No quarto ciclo, o estágio S4 executa a instrução 1, S3 busca os operandos da instrução 2, S2 decodifica a instrução 3 e S1 busca a instrução 4 na memória. Finalmente, no quinto ciclo, S5 escreve o resultado da instrução 1 de volta ao registrador, enquanto os outros estágios processam as instruções subsequentes.

Suponha que o ciclo da máquina da tabela 3 seja de 2 nanossegundos (ns). Portanto, uma instrução leva 10 ns para atravessar todo o pipeline de cinco estágios. À primeira vista, como uma instrução demora 10 ns, pode parecer que a máquina funcionaria a 100 MIPS (milhões de instruções por segundo), mas na verdade, ela opera a uma velocidade muito mais alta. A cada ciclo de clock (2 ns), uma nova instrução é concluída, dessa maneira, a velocidade real de processamento é 500 MIPS, não 100 MIPS.

O *pipelining* permite um equilíbrio entre latência (o tempo necessário para executar uma instrução) e a largura de banda do processador (quantos MIPS a CPU pode processar). Com um tempo de ciclo de T ns e n estágios no pipeline, a latência é nT ns porque cada instrução passa por n estágios, cada um dos quais leva T ns.

Como uma instrução é concluída a cada ciclo de clock e há $10^9/T$ ciclos de clock por segundo, o número de instruções executadas por segundo é $10^9/T$. Por exemplo, se $T = 2$ ns, são executadas 500 milhões de instruções por segundo. Para

obter o número de MIPS, temos que dividir a taxa de execução de instrução por 1 milhão, resultando em $(10^9/T)/10^6 = 1000/T$ MIPS.

5.1.5 Paralelismo nível de processador

Paralelismo ao nível de instrução ajuda um pouco, entretanto *pipelining* raramente rende mais que um fator de 5 ou 10. Para obter ganhos de 50, 100 ou mais, a única maneira é projetar computadores com várias CPUs. Podemos fazer isso de algumas formas como veremos abaixo.

5.1.6 Computadores paralelos

Computadores paralelos de dados encontram muitas aplicações bem-sucedidas como consequência de sua notável eficiência. Eles são capazes de produzir poder de computação significativo com menos transistores do que os métodos alternativos. Os processadores paralelos de dados são um dos meios mais eficientes de espremer desempenho em chips. Como todos os processadores estão rodando a mesma instrução, o sistema só precisa de um “cérebro” controlando o computador. Em consequência, o processador só precisa de um estágio de busca, um estágio de decodificação e um conjunto de lógica de controle. Essa é uma enorme economia no silício, que dá aos computadores paralelos uma grande vantagem sobre outros processadores, desde que o software que eles estejam rodando seja altamente regular, com bastante paralelismo. Dois exemplos de métodos de paralelismo são SIMD e processadores vetoriais.

Um processador SIMD (*Single Instruction-stream Multiple Data-stream*, em português, fluxo único de instruções, fluxo múltiplo de dados) consiste em muitos processadores idênticos que efetuam a mesma sequência de instruções sobre diferentes conjuntos de dados.

As unidades de processamento gráficos (GPUs) contam bastante com o processamento SIMD para fornecer poder computacional maciço com poucos transistores. O processamento gráfico foi apropriado para processadores SIMD porque a maioria dos algoritmos é altamente regular, com operações repetidas sobre pixels, vértices, texturas e arestas.

Já um processador vetorial se parece muito com processador SIMD. Assim um processador SIMD, ele é muito eficiente para executar uma sequência de operações em pares de elementos de dados. Porém, diferente de um processador SIMD, todas as operações de adição são efetuadas em uma única unidade funcional, de alto grau de paralelismo.

Para entender de forma clara vamos a um exemplo:

Vamos imaginar que você está numa sala de aula e a professora te pediu para pintar vários desenhos iguais de um sol. Agora, imagine que você tem duas maneiras de fazer isso.

Na primeira maneira, você pega um desenho de cada vez, pinta e, depois que termina, passa para o próximo. Essa seria a maneira "normal" de pintar - é como os computadores costumam funcionar quando têm um processador tradicional.

Na segunda maneira, imaginamos que você de alguma forma conseguiu fazer uma pintura que, de uma vez só, pode pintar todos os desenhos iguais de uma vez. Isso seria muito mais rápido, certo?

Bem, é assim que um processador vetorial funciona. Em vez de fazer uma coisa de cada vez, como na primeira maneira, ele é capaz de fazer várias coisas iguais de uma vez. Isso pode ser muito útil para algumas tarefas, como jogar videojogos ou fazer certos tipos de cálculos, porque permite que o computador faça muito mais em menos tempo.

5.1.7 Multiprocessadores

Os processadores SIMD não são CPUs independentes, pois possuem uma única unidade de controle compartilhada entre eles. Um exemplo de sistema paralelo com CPUs desenvolvidas é o multiprocessador, que consiste em várias CPUs compartilhando uma memória em comum, semelhante a um grupo de pessoas em uma sala de aula compartilhando um quadro.

No entanto, para evitar conflitos, as CPUs devem coordenar suas ações por meio de software, garantindo que uma não interfira no trabalho da outra. Quando duas ou mais CPUs têm uma interação próxima, como é o caso dos multiprocessadores, elas são consideradas fortemente acopladas.

Os multiprocessadores possuem uma vantagem em relação a outros tipos de computadores paralelos: é mais fácil trabalhar com o modelo de programação de uma única memória compartilhada. Por exemplo, imagine um programa que busca células cancerosas em uma foto de tecido capturada por um microscópio. A imagem digitalizada pode ser armazenada na memória compartilhada, e cada processador pode ser designado para procurar essas células em uma determinada região. Como cada processador tem acesso à memória completa, não há problema em estudar uma célula que começa em uma região designada e atravessa a fronteira para a próxima região.

5.1.8 Multicomputadores

Embora seja relativamente fácil construir multiprocessadores com um número limitado de processadores, a construção de sistemas de grande escala é surpreendentemente desafiadora. A dificuldade reside na conexão de todos os processadores a uma única memória compartilhada. Para contornar esses problemas, muitos projetistas optaram por abandonar a ideia de ter uma memória compartilhada e passaram a construir sistemas conhecidos como multicomputadores. Esses sistemas consistem em um grande número de computadores interconectados, cada um com sua própria memória privada, sem compartilhar uma memória comum.

Os multicomputadores são projetados com CPUs fracamente acopladas, em contraste com as CPUs fortemente acopladas dos multiprocessadores. Para permitir a comunicação entre as CPUs, são utilizadas mensagens que são enviadas de um computador para outro, semelhante ao envio de e-mails, contudo em velocidades muito mais rápidas. Em sistemas de grande porte, não é prático ter cada computador conectado a todos os outros, então são empregadas topologias como malhas 2D e 3D, árvores e anéis. Isso significa que as mensagens de um computador para outro muitas vezes passam por um ou mais computadores ou switches intermediários para chegar ao destino. No entanto, é possível alcançar tempos de transmissão de mensagens da ordem de alguns microssegundos sem grandes dificuldades.

5.2 Memória primária

A memória desempenha um papel crucial no funcionamento dos computadores digitais. É onde programas e dados são armazenados de forma temporária ou

permanente. Sem uma memória adequada, os processadores não teriam acesso aos dados necessários para executar as instruções do programa.

A memória é organizada em diferentes níveis de hierarquia, sendo o principal deles a memória RAM, que fornece uma área de armazenamento volátil e de acesso rápido para os processadores. Nessa memória, os dados podem ser lidos e gravados de forma aleatória.

Além da memória RAM, existem outros tipos de memória, como a memória cache, que atua como uma camada intermediária entre a memória RAM e o processador, armazenando os dados e instruções mais frequentemente acessados para acelerar o desempenho do sistema.

A ausência de memória adequada limitaria significativamente a capacidade de um computador digital. Os programas seriam incapazes de serem executados, pois não haveria local para armazenar as instruções e os dados necessários. Portanto, a memória desempenha um papel fundamental na operação eficiente e correta dos computadores.

5.2.1 Bits

A unidade fundamental da memória é o bit, que é um dígito binário. Um bit pode assumir o valor 0 ou 1, sendo a menor unidade de informação.

Nosso sistema numérico decimal, comumente utilizado, consiste em uma sequência de dígitos decimais, juntamente com um ponto decimal quando necessário. Escolhemos a base 10 para representar números decimais, pois utilizamos 10 dígitos decimais. No entanto, quando se trata de computadores, muitas vezes é conveniente utilizar bases diferentes de 10. As bases mais importantes para computação são 2, 8 e 16, e os sistemas numéricos correspondentes são chamados de binário, octal e hexadecimal.

Em um sistema numérico de base k , são necessários k símbolos diferentes para representar os dígitos de 0 a $k-1$. No sistema decimal, usamos 10 dígitos decimais de 0 a 9. Em contraste, o sistema binário utiliza apenas os dois dígitos binários: 0 e 1. O sistema octal é formado por oito dígitos octais: 0 a 7. Já o sistema hexadecimal requer

16 dígitos, e após o 9, utilizamos as letras maiúsculas de A a F. Portanto, os dígitos hexadecimais são: 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, A, B, C, D, E e F.

A expressão "dígito binário" é geralmente utilizada para se referir a um 1 ou 0, e é mais comumente conhecida como bit.

5.2.2 Conversão de uma base para outra

A conversão de números octais ou hexadecimais para números binários é um processo relativamente simples. Para converter um número binário em octal, agrupamos os bits em conjuntos de 3, sendo que os 3 bits imediatamente à esquerda (ou à direita) do ponto decimal formam um grupo, e assim por diante. Cada grupo de 3 bits pode ser convertido diretamente em um único dígito octal, variando de 0 a 7, de acordo com as regras de conversão específicas.

Em alguns casos, pode ser necessário adicionar um ou dois zeros à esquerda ou à direita para preencher um grupo e garantir que tenhamos exatamente 3 bits. A conversão de octal para binário segue um processo similar, onde cada dígito octal é substituído pelo equivalente binário de 3 bits.

No caso da conversão de hexadecimal para binário, o procedimento é essencialmente o mesmo que a conversão de octal para binário, com a diferença de que cada dígito hexadecimal corresponde a um grupo de 4 bits, em vez de 3 bits.


Hexa	1	9	4	8	.	B	6		
Binário	0001	1001	1001	1000	.	1011	0110		
Octal	1	4	5	1	0	.	5	5	4
Binário	001	100	101	001	000	.	101	101	100

Tabela 4 – Conversão de binários
Fonte: Elaborada pelo autor (2023)

A conversão de números decimais para binários pode ser feita de duas maneiras diferentes. O primeiro método resulta diretamente da definição de números binários. A maior potência de 2 menor que o número é subtraída deste. Então, o processo é repetido na diferença. Quando o número tiver sido decomposto em potências de 2, o

número binário poderá ser montado com 1s nas posições de bit correspondente às potências de 2 usadas na decomposição e 0s em outros lugares.

Outro método consiste em dividir o número por 2. O quociente é escrito diretamente abaixo do número original e o resto, 0 ou 1, é escrito ao lado do quociente. Então, considera-se o quociente e o processo é repetido até chegar ao número 0. O resultado desse processo será duas colunas de números, os quocientes e os restos. O número binário agora pode ser lido diretamente da coluna do resto, começando por baixo.



5.2.3 Números binários negativos

Ao longo da história dos computadores digitais, foram utilizados quatro sistemas distintos para representar números negativos. O primeiro sistema é conhecido como magnitude com sinal. Nele, o bit mais à esquerda é utilizado como o bit de sinal, onde 0 representa números positivos e 1 representa números negativos. Os demais bits armazenam a magnitude absoluta do número.

O segundo sistema é chamado de complemento de um e também possui um bit de sinal. Nesse sistema, para representar um número negativo, substitui-se cada 1 por 0 e cada 0 por 1.

O terceiro sistema é conhecido como complemento de dois e também utiliza um bit de sinal para indicar o sinal do número. A negação de um número nesse sistema ocorre em duas etapas. Na primeira etapa, cada 1 é substituído por 0 e cada 0 é substituído por 1, assim como no complemento de um. Na segunda etapa, adiciona-se 1 ao resultado obtido na primeira etapa. A adição binária segue as mesmas regras da adição decimal, exceto que um *carry* (vai um) é gerado quando a soma é maior do que 1, em vez de ser maior do que 9.

O quarto sistema é chamado de excesso de $2^{(m-1)}$ para números com m bits. Nesse sistema, um número é representado armazenando-o como a soma dele próprio com $2^{(m-1)}$. Por exemplo, para números de 8 bits, onde $m = 8$, o sistema é denominado excesso 128. Dessa forma, o número -3 se torna $-3 + 128 = 125$, e -3 é representado pelo número binário de 8 bits, que é 01111101, equivalente a 125.

5.2.3 Aritmética Binária

A adição de dois números binários é realizada iniciando pelo bit mais à direita e somando os bits correspondentes em cada parcela. Caso haja um *carry* (vai-um) gerado durante a soma, ele é transportado uma posição para a esquerda, de forma semelhante à aritmética decimal. Abaixo está a tabela de adição para números binários:

Adendo	0	0	1	1
Augendo	+0	+1	+0	+1
Soma	0	1	1	0
Vai-um	0	0	0	1

Tabela 5 – Aritmética binária
Fonte: Elaborada pelo autor (2023)

5.2.4 Endereço de memória

As memórias são compostas por um conjunto de células ou locais, cada uma capaz de armazenar uma informação. Cada célula é identificada por um número único, chamado endereço, pelo qual os programas podem fazer referência a ela. Se uma memória contém um total de n células, seus endereços variam de 0 a $n-1$. Todas as células de uma memória possuem o mesmo número de bits.

Se cada célula consiste em k bits, ela pode armazenar qualquer uma das 2^k combinações diferentes de bits. A figura abaixo ilustra três organizações distintas para uma memória de 96 bits. É importante observar que as células adjacentes possuem endereços consecutivos, seguindo uma ordem sequencial.




Figura 20 – Três maneiras de organizar uma memória de 96 bits
 Fonte: Google Imagens (2023)

Os computadores que utilizam o sistema de números binários expressam os endereços de memória em formato binário. Se um endereço possui m bits, o número máximo de células endereçáveis será 2^m . Por exemplo, para referenciar a memória mostrada na figura “Três maneiras de organizar uma memória de 96 bits”, são necessários no mínimo 4 bits para abranger todos os números de 0 a 11.

No entanto, para a figura “Três maneiras de organizar uma memória de 96 bits”, um endereço de 3 bits é suficiente. O número de bits em um endereço determina a quantidade máxima de células que podem ser diretamente acessadas na memória, independentemente do número de bits por célula. Portanto, uma memória com 212 células de 8 bits cada e uma memória com 212 células de 64 bits cada requerem endereços de 12 bits.

A célula de memória é a menor unidade endereçável e sua importância é destacada. Há alguns anos, a maioria dos fabricantes padronizou as células de 8 bits, que são chamadas de bytes. O termo "octeto" também é usado para se referir a um byte. Os bytes são agrupados em palavras (*words*). Um computador com uma palavra

de 32 bits possui 4 bytes por palavra, enquanto um computador com uma palavra de 64 bits possui 8 bytes por palavra. A relevância de uma palavra é que muitas instruções operam com palavras inteiras, como a adição de duas palavras.

Assim sendo, uma máquina de 32 bits possui registradores de 32 bits e instruções para manipular palavras de 32 bits, enquanto uma máquina de 64 bits possui registradores de 64 bits e instruções para movimentar, somar, subtrair e geralmente manipular palavras de 64 bits.

5.2.5 Ordenação de bytes

Os bytes em uma palavra podem ser numerados da esquerda para a direita ou da direita para a esquerda. À primeira vista, essa opção pode parecer insignificante, mas, como veremos em breve, ela possui implicações consideráveis. A figura abaixo representa uma parte da memória de um computador de 32 bits, onde os bytes são numerados da esquerda para a direita.

Por outro lado, a figura “*Big-endian, little-endian*” ilustra um computador de 32 bits que utiliza a numeração da direita para a esquerda, como é o caso da família Intel. O primeiro sistema, onde a numeração começa pelo "grande" lado, ou seja, pela ordem mais alta, é conhecido como *big-endian*, ao contrário do sistema *little-endian* mostrado na figura abaixo.




Figura 21 – *Big-endian, little-endian*

Fonte: Google Imagens (2023)

É importante compreender que tanto no sistema *big-endian* quanto no *little-endian*, um número inteiro de 32 bits com um valor, por exemplo, 6, é representado pelos bits 110 nos três bits mais à direita (ordem baixa) de uma palavra, e os demais 29 bits são preenchidos com zeros. No esquema *big-endian*, os bits 110 estão no byte 3 (ou 7, ou 11, etc.), enquanto no esquema *little-endian* eles estão no byte 0 (ou 4, ou 8, etc.). Em ambos os casos, a palavra que contém esses inteiros tem o endereço 0.

5.2.6 Memória cache

A ideia fundamental de uma memória cache é bastante direta: as palavras de memória utilizadas mais frequentemente são armazenadas na cache. Quando a CPU precisa de uma palavra específica, ela verifica primeiramente na memória cache. Caso a palavra desejada não esteja presente na cache, a CPU então recorre à memória principal. Se uma quantidade significativa das palavras necessárias estiver na cache, o tempo médio de acesso pode ser consideravelmente reduzido.

Dessa maneira, o sucesso ou o fracasso da memória cache depende diretamente da proporção de palavras que estão armazenadas na cache. É bem conhecido há anos que os programas não acessam suas memórias de maneira totalmente aleatória. Se uma determinada referência de memória for para o endereço A, é provável que a referência subsequente esteja geralmente próxima de A. Um exemplo simples disso é o fluxo de execução de um programa. Exceto quando ocorrem desvios ou chamadas de procedimento, as instruções são buscadas em locais consecutivos da memória.

Além disso, uma parcela considerável do tempo de execução de um programa é dedicada a *loops* (instrução para o programa repetir tarefas), nos quais um conjunto de instruções é executado repetidamente. Da mesma forma, é provável que um programa que manipule matrizes fará várias referências à mesma matriz antes de mudar para outra tarefa.

A constatação de que as referências de memória feitas em um intervalo de tempo curto tendem a utilizar apenas uma pequena fração da memória total é denominada princípio da localidade. Esse princípio forma a base de todos os sistemas de cache. A ideia geral é que, quando uma palavra é referenciada, ela e algumas de suas vizinhas são transferidas da memória principal, que é mais lenta, para a memória cache. Assim,

na próxima vez em que essa palavra for utilizada, ela pode ser acessada rapidamente. Uma configuração comum envolvendo CPU, memória cache e memória principal pode ser observada na figura abaixo.



Figura 22 – Memória cache
Fonte: TANENBAUM; AUSTIN (2013)

5.2.7 Empacotamento de memória

Desde os primórdios da memória de semicondutor até o começo dos anos 90, a memória era produzida, comercializada e instalada em forma de chips individuais. As densidades dos chips variavam de 1 K bits até 1 M bits e além, porém, cada chip era comercializado como uma unidade distinta. Os primeiros computadores pessoais normalmente possuíam soquetes vazios onde chips de memória extras poderiam ser inseridos conforme a necessidade do usuário.

A partir dos anos 90, um novo formato foi adotado. Um conjunto de chips, geralmente 8 ou 16, era montado em uma pequena placa de circuito impresso e vendido como uma unidade única. Essa unidade é conhecida como SIMM (*Single Inline Memory Module*, em português, módulo de memória em linha único) ou DIMM (*Dual Inline Memory Module*, em português, módulo de memória em linha duplo), dependendo se possui uma fileira de conectores de um só lado ou em ambos os lados da placa.

Os SIMMs possuem um conector de borda com 72 contatos e transferem 32 bits por ciclo de clock. Já os DIMMs geralmente possuem conectores de borda com 120 contatos em cada lado da placa, totalizando 240 contatos, e transferem 64 bits por ciclo de clock. Atualmente, os mais utilizados são os DIMMs DDR4, embora os DDR5 já

estejam disponíveis no mercado, representando a quarta versão das memórias de taxa dupla.




Figura 23 – DIMM
Fonte: Google Imagens (2023)

Conforme pode ser visto na figura acima, um exemplo típico de DIMM, cada um dos chips contém 256 MB totalizando 8 chips para uma memória total de 2048 GB.

5.3 Memória secundária

Independentemente da capacidade da memória principal, ela sempre parece ser insuficiente. As pessoas sempre têm o desejo de armazenar mais informações do que a memória consegue acomodar. Por exemplo, considerando que as diretrizes orçamentárias do governo dos Estados Unidos incentivam as agências governamentais a gerar suas próprias receitas, podemos supor que a Biblioteca do Congresso decida digitalizar e comercializar todo o seu acervo. Com milhões de livros, cada um contendo aproximadamente 1 MB de texto e 1 MB de imagens comprimidas, seria necessária uma capacidade de armazenamento de 100 terabytes. E isso sem contar a necessidade de armazenamento para todos os filmes produzidos até a data atual. Este volume de informações não cabe na memória principal e provavelmente continuará assim por algumas décadas.

5.3.1 Hierarquia das memórias

A solução para armazenar grandes quantidades de dados é uma hierarquia de memória, como ilustrado na figura abaixo.




Figura 24 – Hierarquia da memória
Fonte: Google Imagens (2023)

No ápice da pirâmide de armazenamento, encontram-se os registradores da CPU, acessíveis à velocidade total de operação da CPU. Logo abaixo, temos a memória cache, cujo tamanho varia de 32 KB a alguns megabytes. Em seguida, vem a memória principal, que em sistemas básicos começa em 1 GB e pode alcançar centenas de gigabytes nos sistemas de alta capacidade. A seguir, temos a memória secundária composta por discos ópticos, magnéticos e de estado sólido. A base da pirâmide seria ocupada por soluções de armazenamento externas, como os serviços de armazenamento em nuvem.

Conforme descemos na hierarquia, três características se intensificam. Primeiramente, o tempo de acesso aumenta. Os registradores da CPU podem ser acessados em um nanossegundo ou menos. A memória cache requer um tempo ligeiramente superior ao dos registradores da CPU. Acessos à memória principal usualmente levam cerca de 10 nanossegundos. Após isso, existe uma grande disparidade, pois os tempos de acesso ao disco são, no mínimo, 10 vezes mais lentos para discos de estado sólido e centenas de vezes mais lentos para discos magnéticos. O acesso a fitas ou discos ópticos pode ser medido em segundos, especialmente se a mídia necessitar ser localizada e inserida no respectivo leitor.

Em segundo lugar, a capacidade de armazenamento se amplia conforme descemos na hierarquia. Os registradores da CPU comportam aproximadamente 128

bytes, as memórias cache podem armazenar algumas dezenas de megabytes, as memórias principais abrigam alguns gigabytes, os discos de estado sólido podem conter centenas de gigabytes e os discos magnéticos têm capacidade para terabytes. Fitas e discos ópticos normalmente são mantidos offline, portanto, sua capacidade de armazenamento é limitada apenas pelo orçamento do usuário.

Em terceiro lugar, a proporção de bits por dólar investido aumenta à medida que descemos a hierarquia. Embora os preços atuais estejam sempre em mudança, a memória principal é avaliada em termos de dólares por megabyte, o disco de estado sólido é medido em dólares por gigabyte e o armazenamento em disco magnético e fita é calculado em centavos por gigabyte.

5.3.2 Disco magnéticos

Os discos magnéticos são uma forma de armazenamento de dados que utiliza a magnetização para gravar informações binárias. Esses discos são geralmente usados em discos rígidos (HDDs), que são uma forma comum de armazenamento não volátil em computadores.

Um disco rígido é composto por um ou mais discos de metal (*platters*), revestidos com um material magnético. Estes discos giram em alta velocidade, proporcionando o acesso aos dados.

Cada um desses discos é dividido em trilhas concêntricas, que são os anéis nos quais os dados são armazenados. A largura da trilha se refere à largura física de cada um desses anéis.

Além disso, as trilhas são divididas em pequenos segmentos chamados setores, que são a unidade mínima de armazenamento em um disco. Normalmente, cada setor armazena um número fixo de bytes, comumente 512 bytes ou 4.096 bytes nos discos mais modernos. Um exemplo pode ser visualizado na figura abaixo.




Figura 25 – Composição de um disco óptico
Fonte: Google Imagens (2023)

Cada superfície do disco pode armazenar dados, portanto, um disco de duas faces terá duas vezes a capacidade de um disco de uma única face.

Os dados são lidos e escritos no disco por meio de cabeçotes de leitura/gravação. Cada superfície do disco tem o seu próprio cabeçote de leitura/gravação, que flutua sobre a superfície do disco sem tocá-la, a uma distância minúscula, enquanto o disco gira.

Esses cabeçotes estão montados em braços móveis que podem mover-se para dentro e para fora, permitindo que o cabeçote acesse todas as trilhas do disco. Este movimento é semelhante ao movimento do braço de uma vitrola, mas muito mais rápido.

O atuador é o componente que move esses braços. Em um disco rígido moderno, o atuador é normalmente um motor de bobina móvel, semelhante ao motor usado em alto-falantes. O atuador se move de maneira muito rápida e precisa para posicionar o cabeçote no local certo.

O controlador de disco é o hardware que gerencia a operação do disco rígido. Ele controla o movimento do atuador, lê os sinais dos cabeçotes de leitura e escreve nos cabeçotes de gravação. O controlador também gerencia a interface entre o disco rígido e o restante do sistema de computador.

A interface é a conexão física e lógica entre o disco rígido e o computador. Interfaces comuns incluem SATA (*Serial Advanced Technology Attachment*, em português, anexo de tecnologia avançada serial), mais usada em computadores pessoais e SAS (*Serial Attached SCSI* - SCSI anexo serial), utilizada em servidores empresariais. A interface controla como os dados são transferidos entre o disco rígido e o computador.

Por fim, o buffer de disco, também conhecido como cache de disco, é uma pequena quantidade de memória de alta velocidade (geralmente RAM) que é usada para armazenar temporariamente os dados que estão sendo lidos ou escritos. Isso pode melhorar o desempenho do disco rígido, pois permite que o controlador de disco leia ou escreva grandes quantidades de dados de uma só vez, e também pode reduzir o tempo de espera se os mesmos dados forem lidos várias vezes.

Os discos magnéticos têm sido a principal forma de armazenamento de dados por muitos anos devido ao seu baixo custo por bit e à sua durabilidade. No entanto, eles estão sendo gradualmente substituídos por armazenamentos de estado sólido (SSS), que são mais rápidos, mais silenciosos e mais resistentes a falhas, embora sejam mais caros por bit.

5.3.3 Fitas magnéticas

As fitas magnéticas são uma forma de armazenamento de dados que utiliza a magnetização, similar aos discos magnéticos, porém, em vez de utilizar discos para armazenar os dados, a fita magnética usa uma faixa estreita de material plástico revestida com um material que pode ser magnetizado.

Cada pedaço de informação é armazenado em um pequeno segmento da fita, que pode ser lido ou escrito mudando ou lendo a direção da magnetização. Diferentemente dos discos rígidos, que permitem acesso aleatório aos dados, as fitas magnéticas são um meio de armazenamento sequencial, o que significa que para acessar um ponto específico na fita, você deve passar por todos os pontos anteriores.

Isso torna as fitas magnéticas menos adequadas para muitas aplicações de uso geral, mas elas são muito eficientes para armazenamento de longo prazo e backup, porque são muito econômicas em relação à quantidade de dados que podem armazenar.

Na fita magnética, a informação é armazenada linearmente, ao longo da fita. Para aumentar a capacidade de armazenamento, as fitas modernas usam múltiplas faixas paralelas que percorrem o comprimento da fita. Cada faixa pode ser lida ou escrita independentemente.

Um drive de fita é usado para ler e escrever dados em uma fita magnética. Ele possui um ou mais cabeçotes, que são usados para ler e escrever dados na fita. O drive de fita também avança e rebobina a fita, permitindo que o cabeçote acesse diferentes partes da fita.

As fitas magnéticas são tipicamente armazenadas em carretéis ou em cartuchos ou cassetes, que protegem a fita e permitem que ela seja facilmente manipulada e armazenada.

Apesar de a fita magnética ser uma tecnologia bastante antiga, ela ainda é usada hoje em muitos sistemas de backup e arquivamento devido ao seu baixo custo por bit e sua durabilidade para armazenamento de longo prazo.

5.3.4 Discos IDE

IDE (*Integrated Drive Electronics*), também conhecido como ATA (*Advanced Technology Attachment*), é um tipo de interface de disco que foi amplamente usado na indústria de computadores a partir dos anos 80 até os primeiros anos de 2000. Esta interface foi uma das primeiras a integrar os controladores de disco diretamente na própria unidade de disco, daí o nome *Integrated Drive Electronics*.

A interface IDE permitia a conexão de até dois dispositivos de armazenamento em um único cabo, geralmente um disco rígido e um drive de CD ou DVD. Os dispositivos eram distinguidos como *master* e *slave*, e o sistema operacional conseguia diferenciar entre eles usando esse esquema.

As especificações IDE originais eram limitadas a discos rígidos de até 528 MB. No entanto, as revisões subsequentes, conhecidas como *Enhanced IDE* (EIDE), permitiram discos rígidos maiores, além de suporte para dispositivos adicionais, como CD-ROMs e fitas.

Os discos IDE usam um conector de 40 pinos e um cabo flat para se conectar à placa-mãe. Os 40 pinos incluem pinos para dados, controle e energia. No entanto, a

taxa de transferência de dados do IDE é limitada quando comparada a interfaces mais recentes como SATA (Serial ATA), que eventualmente substituiu o IDE na maioria dos computadores modernos.

Apesar da interface IDE não ser mais comumente usada em novos sistemas, ela ainda é encontrada em muitos sistemas mais antigos. Além disso, os princípios básicos de funcionamento das interfaces de disco rígido, tais como a integração do controlador com o disco e a separação dos dispositivos em *master* e *slave*, continuam relevantes até hoje.

5.3.5 Disco SCSI

SCSI (*Small Computer System Interface*) é um conjunto de padrões para a conexão física e transferência de dados entre computadores e dispositivos periféricos. A interface SCSI é comumente usada para discos rígidos, mas também pode ser usada para uma variedade de outros dispositivos, incluindo scanners e CD-ROMs.

Uma das principais características do SCSI é que ele é um barramento, permitindo que vários dispositivos (até 8 ou 16, dependendo da versão do SCSI) sejam conectados à mesma interface. Cada dispositivo na cadeia SCSI tem um ID único, que é usado para direcionar comandos e dados para o dispositivo correto.

Os discos rígidos SCSI têm uma reputação de serem mais rápidos e mais confiáveis do que as alternativas, como IDE e SATA. Isso ocorre em parte porque o SCSI suporta comandos em fila, o que permite que vários comandos sejam enviados a um dispositivo sem esperar que cada comando seja concluído. Isso pode levar a um desempenho muito melhor, especialmente em situações onde muitos comandos estão sendo enviados para o disco rígido ao mesmo tempo.

Outra vantagem dos discos rígidos SCSI é que eles normalmente têm seus próprios controladores de disco integrados, o que pode liberar a CPU do trabalho de gerenciar as transferências de dados. Isso pode levar a um desempenho geral melhor do sistema.

No entanto, os discos rígidos SCSI também tendem a ser mais caros do que as alternativas, e a necessidade de gerenciar IDs SCSI pode tornar o sistema mais complexo de configurar. Além disso, enquanto o SCSI ainda é usado em alguns

cenários, como servidores e armazenamento de rede, ele tem sido amplamente substituído por outras tecnologias como SATA e SAS em PCs e laptops.

5.3.6 Disco em estado sólido

Os discos construídos com memória flash não volátil, comumente conhecidos como discos de estado sólido (*Solid State Disks* - SSDs), estão se tornando cada vez mais populares como uma alternativa de alta velocidade para as tecnologias convencionais de disco magnético. Apesar da eletrônica moderna parecer extremamente confiável, a verdade é que os transistores se desgastam gradualmente com o uso. Cada vez que mudam de estado, desgastam-se um pouco, aproximando-se do ponto de falha.

Uma causa comum de falha em um transistor é a injeção de portadora quente, um mecanismo de falha que incorpora uma carga elétrica dentro do transistor operacional, deixando-o permanentemente ligado ou desligado. Embora geralmente isso signifique o fim para um transistor, Fujio Masuoka, enquanto trabalhava na Toshiba, descobriu uma forma de usar esse mecanismo de falha para criar um novo tipo de memória não volátil. No início dos anos 1980, ele inventou a primeira memória flash.

Os discos flash são compostos de várias células de memória flash em estado sólido. As células da memória flash são constituídas por um transistor flash especializado. Uma célula de memória flash pode ser observada na figura 5-11. Dentro do transistor, há uma porta flutuante que pode ser carregada e descarregada utilizando altas voltagens. Antes de ser programada, a porta flutuante não influencia a operação do transistor, funcionando como um isolador adicional entre a porta de controle e o canal do transistor. Quando testada, a célula flash funciona como um transistor convencional.




Figura 26 – Célula de memória flash
Fonte: TANENBAUM; AUSTIN (2013)

Para programar uma célula de memória flash, aplica-se uma tensão elevada, geralmente de 12 volts (que é considerada alta no contexto de computação), à porta de controle. Isso acelera o processo conhecido como "injeção de portadora quente" na porta flutuante. Neste processo, os elétrons são incorporados na porta flutuante, criando uma carga negativa dentro do transistor flash.

Essa carga negativa incorporada aumenta a tensão necessária para ativar o transistor flash. Ao verificar se o canal é ativado ou não por meio de uma tensão alta ou baixa, é possível determinar se a porta flutuante está carregada ou não. Este processo resulta em um valor binário, 0 ou 1, para cada célula flash.

A carga incorporada permanece dentro do transistor, mesmo quando a alimentação do sistema é interrompida. Isso faz com que a célula de memória flash seja não volátil, ou seja, ela mantém os dados mesmo sem energia elétrica.

5.3.7 CD-ROMs

Os CD-ROMs, ou discos compactos de memória somente de leitura, são uma forma popular de mídia de armazenamento que foi amplamente utilizada para distribuir software, dados e música digitalizada. O CD-ROM é uma tecnologia de disco óptico, o que significa que utiliza a luz para ler e escrever dados.

Um CD-ROM é composto por uma base de plástico policarbonato, que é gravada com dados e em seguida revestida com uma camada fina de alumínio para refletir a luz do laser. Por cima do alumínio, uma fina camada de laca é aplicada para prevenir a oxidação e, finalmente, a etiqueta é impressa por cima.

Os dados em um CD-ROM são armazenados em uma trilha em espiral, começando do centro do disco e indo para fora. Esta trilha é composta por uma série de pequenos *pits* (pequenos buracos) e *lands* (áreas planas) que são gravados na superfície do disco.

A gravação dos dados em um CD-ROM ocorre no processo de fabricação e não pode ser alterada. Uma máquina chamada estampadora cria um molde mestre que é usado para pressionar os pits na superfície do policarbonato. Durante a leitura, o laser do drive de CD é refletido de maneira diferente pelos *pits* e *lands*, o que permite ao drive decodificar essa variação de reflexão como uma série de zeros e uns, representando os dados digitais.

O CD-ROM normal tem uma capacidade de armazenamento de 650 a 700 megabytes, que é cerca de 74 a 80 minutos de áudio não comprimido.

Lembre-se que os CD-ROMs são diferentes dos CDs-R (*CD-Recordable*) e CDs-RW (*CD-Rewritable*). Os CDs-R permitem gravar dados uma única vez, enquanto os CDs-RW permitem gravar e apagar dados várias vezes.

Vale destacar que, devido à alta taxa de transferência de dados, os CD-ROMs são geralmente usados para armazenar grandes arquivos, como jogos, programas de software de alta capacidade, vídeos e áudios.

Vamos agora falar um pouco mais sobre como o CD é lido. Para fazer a leitura dos dados, o CD-ROM é girado por um motor dentro do drive de CD. Um dispositivo conhecido como cabeçote de leitura se move ao longo da espiral da trilha, de dentro para fora.

Dentro do cabeçote de leitura, um laser emite um feixe de luz que é focado na trilha do CD-ROM. Quando o feixe de laser atinge um "land", é refletido de volta para um sensor óptico no cabeçote de leitura. Quando o feixe de laser atinge um "pit", a luz é dispersa e não é refletida de volta para o sensor. A alternância entre a luz refletida e a luz não refletida à medida que o CD-ROM gira é interpretada como os bits de dados

que estão sendo lidos. A figura abaixo demonstra um exemplo de CD-ROM com sua composição de *pit* e *land*.




Figura 27 – Célula de memória flash
Fonte: HOW PRODUCTS ARE MADE (s.d.)

Lembre-se, porém, que embora os CD-ROMs tenham sido incrivelmente populares no passado, eles têm sido substituídos gradualmente por outras formas de mídia digital, como os DVDs e, mais recentemente, os drives flash USB e o armazenamento na nuvem. No entanto, ainda são um bom exemplo para entender as bases da tecnologia de armazenamento óptico.

5.3.8 DVDs

DVDs, ou discos versáteis digitais, são outra forma comum de armazenamento óptico, assim como os CDs. No entanto, os DVDs têm uma capacidade de armazenamento muito maior. Enquanto um CD típico pode armazenar cerca de 700MB de dados, um DVD pode armazenar de 4.7GB (DVD de camada única) a 8.5GB (DVD de camada dupla), que é cerca de 7-12 vezes a capacidade de um CD.

Os DVDs conseguem armazenar mais dados em parte devido ao uso de um laser de comprimento de onda menor. Isso permite que os *pits* e *lands* sejam feitos menores, o que, por sua vez, permite que mais dados sejam armazenados na mesma área. Um laser infravermelho é usado para CDs, enquanto um laser vermelho é usado para DVDs, que tem um comprimento de onda menor.

A estrutura física de um DVD é semelhante à de um CD. No entanto, os DVDs podem ter várias camadas de dados em cada lado. Um DVD de camada única tem uma única camada de dados, enquanto um DVD de camada dupla tem duas. Além disso,

um DVD pode ser de um único lado (com dados apenas em um lado) ou de dois lados (com dados em ambos os lados).

A gravação de dados em um DVD é semelhante ao processo para um CD. No caso de um DVD gravável, um laser de alta potência é usado para alterar a reflexividade de uma camada de material orgânico tingido, que, por sua vez, cria 'pits' e 'lands'. Nos DVDs regraváveis, uma camada de liga metálica que pode ser alternada entre estados cristalinos e amorfos é usada em vez disso.

Para ler os dados de um DVD, um feixe laser é focado na camada de dados do disco. A luz é refletida de volta para um sensor, que detecta as diferenças de reflexão causadas pelos *pits* e *lands*. Estas diferenças são então convertidas em uma sequência de bits que representam os dados originais.

Assim como os CDs, os DVDs usam um sistema de correção de erros sofisticado para corrigir quaisquer erros que possam ocorrer durante o processo de leitura.

Ao contrário dos CDs, os DVDs possuem uma característica chamada Modulação de 16 bits/8 bits (*16/8 Modulation*). Essa técnica permite que um sinal digital seja transmitido mais eficientemente através do uso de bits adicionais para garantir a confiabilidade da informação. Em um DVD, 16 bits de dados são codificados em um bloco de 8 bits para transmissão. Isso aumenta a robustez do sinal, ao mesmo tempo que permite que mais dados sejam armazenados no disco.

Os DVDs também possuem uma camada de proteção contra arranhões muito mais robusta em comparação com os CDs. Isso os torna mais resistentes a danos físicos e aumenta a vida útil dos dados armazenados.

Além disso, é importante destacar que existem diferentes tipos de DVDs, incluindo DVD-ROM, DVD-R/RW e DVD+R/RW. Os DVDs ROM são somente leitura, assim como os CDs ROM, enquanto os DVDs R/RW e +R/RW podem ser gravados e regravados.

Os DVDs também oferecem suporte a diferentes formatos de vídeo, como MPEG-2 e MPEG-4, tornando-os uma escolha popular para a distribuição de filmes e programas de televisão.

Por último, mas não menos importante, ao contrário dos CDs que usam um formato de áudio PCM sem compressão, os DVDs suportam formatos de áudio

comprimidos como Dolby Digital e DTS, permitindo um som de alta qualidade com menos uso de espaço de armazenamento.

5.3.9 Blu-ray

O Blu-ray, que sucede ao DVD, foi nomeado dessa maneira devido ao seu uso de um laser azul, em contraste com o laser vermelho utilizado nos DVDs. Como o laser azul possui um comprimento de onda mais curto, é possível um foco mais preciso, permitindo a criação de *lands* e *pits* menores. Os discos Blu-ray de uma única face podem armazenar aproximadamente 25 GB de dados, enquanto os discos de dupla face podem conter cerca de 50 GB. Eles possuem uma taxa de transferência de dados de cerca de 4.5 MB/s, o que é bastante adequado para um disco óptico, mas ainda fica aquém se comparado com os discos magnéticos.

5.4 Entrada/saída (I/O)

Um sistema de computador tem três componentes principais: a CPU, as memórias (primária e secundária) e os equipamentos de E/S (entrada e saída), ou I/O (Input/Output), como impressoras, scanners, modems, teclados, monitores, mouses etc.

5.4.1 Barramento

A configuração típica de muitos computadores pessoais e estações de trabalho consiste em um gabinete de metal que contém uma placa de circuito impresso de grande tamanho, conhecida como placa-mãe, localizada na parte inferior. A placa-mãe abriga o chip da CPU, vários slots para os módulos DIMM e diversos outros chips de suporte. Além disso, ela possui um barramento que se estende ao longo de sua extensão, juntamente com soquetes nos quais os conectores de borda das placas de E/S podem ser inseridos.

A estrutura lógica de um computador pessoal simples pode ser representada conforme ilustrado na figura abaixo. Esse computador possui um único barramento que conecta a CPU, a memória e os dispositivos de E/S, embora a maioria dos sistemas tenha dois ou mais barramentos. Cada dispositivo de E/S é composto por duas partes: uma delas é o controlador, que abriga a maior parte dos componentes eletrônicos, e a

outra parte é o próprio dispositivo de E/S, como um drive de disco. O controlador é geralmente colocado em uma placa que é conectada a um slot disponível.

Embora o monitor seja essencial, o controlador de vídeo às vezes é localizado em uma placa de expansão para permitir que o usuário escolha entre placas com aceleradores gráficos, memória adicional, etc. O controlador se conecta ao seu dispositivo por meio de um cabo que é conectado a um conector na parte traseira do gabinete.




Figura 28 – Estrutura lógica de um computador
Fonte: Google Imagens (2023)

O papel de um controlador é supervisionar o dispositivo de E/S e gerenciar seu acesso ao barramento. Por exemplo, quando um programa precisa de dados do disco, ele envia um comando ao controlador de disco, que por sua vez emite comandos de busca e outros comandos para o drive.

Uma vez que a trilha e o setor apropriados sejam localizados, o drive inicia a transferência de dados ao controlador como uma sequência contínua de bits. Cabe ao controlador dividir esse fluxo de bits em unidades e gravar cada uma delas na memória conforme são formadas. Uma unidade típica pode consistir em uma ou mais palavras. Quando um controlador lê ou escreve dados na memória sem a intervenção da CPU, isso é chamado de acesso direto à memória (DMA - *Direct Memory Access*).

Após a conclusão da transferência, o controlador geralmente gera uma interrupção, o que faz com que a CPU interrompa imediatamente o programa em execução e inicie um procedimento específico chamado rotina de interrupção. Essa rotina verifica erros, realiza ações necessárias e informa ao sistema operacional que a operação de E/S foi concluída. Após a conclusão da rotina de interrupção, a CPU retoma o programa que foi interrompido pela interrupção.

O barramento não é usado exclusivamente pelos controladores de E/S, mas também pela CPU para buscar instruções e dados. O que acontece quando a CPU e um controlador de E/S desejam usar o barramento simultaneamente? A resposta está em um chip chamado árbitro de barramento, que determina a prioridade entre eles. Geralmente, os dispositivos de E/S têm prioridade sobre a CPU, pois dispositivos como discos e outros em movimento não podem ser interrompidos e fazê-los esperar resultaria em perda de dados. Quando não há nenhuma operação de E/S em andamento, a CPU pode usar todos os ciclos do barramento para acessar a memória. No entanto, quando um dispositivo de E/S está em operação, ele solicitará e terá acesso ao barramento sempre que necessário. Esse processo é chamado de "roubo de ciclo" e pode reduzir a velocidade do computador.

Esse projeto funcionou bem para os primeiros computadores pessoais, pois todos os componentes estavam equilibrados. No entanto, à medida que as CPUs, memórias e dispositivos de E/S se tornaram mais rápidos, surgiu um problema: o barramento não conseguiu lidar com a carga apresentada. Em sistemas fechados, como estações de trabalho de engenharia, a solução foi projetar um novo barramento mais rápido para o próximo modelo. Como ninguém normalmente migrava dispositivos de E/S de um modelo antigo para um novo, essa abordagem funcionava bem.

No entanto, no mundo dos PCs, muitas pessoas que atualizavam para uma CPU mais potente também queriam levar seus dispositivos, como impressoras, scanners e modems, para o novo sistema. Além disso, uma indústria em expansão havia se desenvolvido para fornecer uma ampla variedade de dispositivos de E/S para o barramento do IBM PC, e essa indústria não estava disposta a perder todo o seu investimento e começar do zero.

A IBM aprendeu isso da maneira mais difícil quando lançou a linha PS/2, sucessora do IBM PC. O PS/2 apresentava um novo e mais rápido barramento, mas a

maioria dos fabricantes de clones continuou usando o antigo barramento do PC, conhecido como barramento ISA (Industry Standard Architecture).

A maioria dos fabricantes de discos e dispositivos de E/S continuou a produzir controladores para esse barramento, e a IBM se viu em uma situação peculiar, sendo a única fabricante de PCs que não era compatível com o PC da IBM. Com o tempo, a empresa foi forçada a dar suporte ao barramento ISA. Hoje em dia, o barramento ISA é usado apenas em sistemas legados e em museus de computadores, pois foi substituído por arquiteturas de barramento padrão mais novas e mais rápidas. Vale ressaltar que, no contexto de níveis de máquina, ISA significa Instruction Set Architecture, enquanto no contexto de barramentos, significa Industry Standard Architecture.

5.4.2 PCI e PCIe

Apesar da resistência do mercado em relação a mudanças, foi necessário abordar a questão da lentidão do antigo barramento. Isso levou outras empresas a desenvolver sistemas com múltiplos barramentos, incluindo o barramento ISA ou seu sucessor compatível, o EISA. Atualmente, o barramento PCI se tornou o mais popular, projetado pela Intel, que disponibilizou suas patentes para o domínio público, incentivando toda a indústria a adotá-lo, inclusive seus concorrentes.

O barramento PCI pode ser configurado de diferentes maneiras, como mostrado na figura “Configuração típica usando PCI”. Nessa configuração típica, a CPU se conecta a um controlador de memória através de uma conexão dedicada de alta velocidade. O controlador se comunica diretamente com a memória e o barramento PCI, evitando que o tráfego entre a CPU e a memória passe pelo barramento PCI. Outros periféricos podem ser conectados diretamente ao barramento PCI.

Uma máquina com esse design teria dois ou três slots PCI vazios, permitindo aos usuários adicionar placas de E/S PCI para conectar novos periféricos.

Apesar das críticas comuns à velocidade dos componentes de computação, o barramento PCI não foi exceção. Como resultado, ele está sendo gradualmente substituído pelo PCI Express (PCIe). A maioria dos computadores modernos já suporta o barramento PCIe, possibilitando que os usuários conectem dispositivos mais rápidos

a ele, enquanto dispositivos mais antigos e mais lentos ainda podem ser conectados ao barramento PCI.




Figura 29 – Configuração típica usando PCI
Fonte: TANENBAUM; AUSTIN (2013)

Existem várias características distintas do PCIe que se destacam imediatamente. Primeiro, as conexões entre dispositivos são seriais, ou seja, de 1 bit de largura em vez de 8, 16, 32 ou 64 bits. Embora seja natural pensar que uma conexão de 64 bits teria uma largura de banda maior do que uma conexão de 1 bit, na prática, as diferenças no tempo de propagação dos 64 bits, conhecido como distorção (*skew*), limitam o uso de velocidades mais altas. Com uma conexão serial, é possível utilizar velocidades muito mais altas, compensando a perda de paralelismo.

Enquanto os barramentos PCI trabalham com uma taxa de clock máxima de 66 MHz e uma taxa de dados de 528 MB/s com 64 bits transferidos por ciclo, o PCIe alcança uma taxa de dados de 1 GB/s com uma taxa de clock de 8 GHz, mesmo em transferência serial. Além disso, os dispositivos não são limitados a um único par de fios para se comunicarem com o complexo raiz ou um switch.

Um dispositivo PCIe pode ter até 32 pares de fios, chamados de lanes (pistas). Essas pistas não são síncronas, o que significa que a distorção não é um problema. A maioria das placas-mãe possui um slot de 16 pistas para a placa gráfica, proporcionando uma largura de banda de 16 GB/s no PCIe 3.0, cerca de 30 vezes mais

rápida do que uma placa gráfica PCI convencional. Essa largura de banda é necessária para atender às demandas cada vez maiores de aplicações gráficas em 3D.

Segundo, toda a comunicação no PCIe é ponto a ponto. Quando a CPU deseja se comunicar com um dispositivo, ela envia um pacote para ele e, em geral, recebe uma resposta posteriormente. O pacote passa pelo complexo raiz na placa-mãe e, em seguida, é encaminhado para o dispositivo, possivelmente através de um switch ou de uma ponte para PCI, caso o dispositivo seja um PCI. Essa evolução de um sistema em que todos os dispositivos ouviam o mesmo barramento para um sistema que utiliza comunicação ponto a ponto é semelhante ao desenvolvimento das redes Ethernet, que começaram com um canal de transmissão única (*broadcast*) e agora utilizam switches para permitir a comunicação ponto a ponto.

5.4.3 Terminais

Existem diversos tipos de dispositivos de E/S disponíveis, e a seguir serão discutidos alguns dos mais comuns. Os terminais de computador são compostos por duas partes: um teclado e um monitor. Nos mainframes, essas partes costumam estar integradas em um único dispositivo conectado ao computador principal por uma linha serial ou telefônica. Em setores como reservas de passagens aéreas, serviços bancários e outros que utilizam mainframes, esses dispositivos ainda são amplamente utilizados. Já nos computadores pessoais, o teclado e o monitor são dispositivos independentes. Independentemente do cenário, a tecnologia empregada nessas duas partes é a mesma.

5.4.4 Teclados

Os teclados de computador são dispositivos de entrada essenciais para a maioria das tarefas que realizamos em computadores. Eles são usados para inserir dados no computador, seja para escrever texto, inserir comandos, jogar jogos ou navegar na interface do usuário.

Um teclado de computador padrão geralmente possui cerca de 101 a 104 teclas, incluindo letras, números, teclas de função (F1, F2, etc.), teclas de controle (Ctrl, Alt, Shift, etc.), teclas de navegação (Setas, Home, End, etc.), e teclas especiais como Esc,

Enter, Backspace, e Spacebar. Além disso, muitos teclados incluem um teclado numérico dedicado à direita.

Em termos de funcionamento, quando você pressiona uma tecla no teclado, um sinal elétrico é enviado ao computador. Este sinal é chamado de "código de varredura" (*scan code*), que é uma combinação única de números que identifica a tecla específica que foi pressionada.

O código de varredura é enviado para o controlador de teclado do computador, um chip que interpreta o código de varredura e o converte em um código de caractere que o sistema operacional pode entender. O sistema operacional então decide o que fazer com o caractere, dependendo do software que está sendo usado.

5.4.5 Touchscreen

As telas sensíveis ao toque são dispositivos de entrada que permitem aos usuários interagir com os dispositivos eletrônicos diretamente, tocando na tela. Elas são amplamente utilizadas em smartphones, tablets, caixas eletrônicos, quiosques de informação, e muitos outros dispositivos.

Existem três tipos principais de tecnologias de tela sensível ao toque: capacitiva, resistiva e infravermelho.

- **Capacitiva:** As telas capacitivas funcionam aproveitando a capacidade natural do corpo humano para conduzir eletricidade. A tela é coberta com uma camada transparente de um material condutor. Quando um dedo toca a tela, ele altera o campo elétrico naquele ponto específico, permitindo que o dispositivo registre a posição e o movimento do toque. As telas capacitivas são muito precisas e podem suportar vários toques ao mesmo tempo (*multi-touch*), tornando-as ideais para gestos complexos, como pinçar para dar zoom.
- **Resistiva:** As telas resistivas são compostas por várias camadas, incluindo duas camadas condutoras separadas por um espaço de ar fino. Quando a tela é pressionada, as duas camadas condutoras entram em contato, permitindo que a eletricidade passe e o toque seja registrado. Embora as telas resistivas sejam menos sensíveis e menos precisas do que as telas capacitivas, elas têm a vantagem de funcionar com qualquer

tipo de toque, seja com um dedo, uma caneta stylus ou até mesmo um objeto pontiagudo.

- **Infravermelho:** As telas sensíveis ao toque infravermelhas funcionam projetando uma grade de luz infravermelha sobre a tela. Quando um objeto, como um dedo, interrompe a luz em um ponto específico na grade, o toque é registrado. Este tipo de tecnologia é durável e funciona bem para telas maiores, como quiosques de informação.

Um touchpad é um dispositivo de entrada semelhante a uma tela sensível ao toque, comumente encontrado em laptops. Ele permite que os usuários controlem um cursor ou ponteiro na tela, movendo o dedo sobre a superfície do touchpad.

Como as telas sensíveis ao toque, os touchpads podem ser capacitivos ou resistivos. No entanto, a maioria dos touchpads modernos usa tecnologia capacitiva, devido à sua maior precisão e capacidade de suportar gestos *multi-touch*.

Os touchpads também costumam ter botões físicos abaixo ou incorporados na superfície do touchpad, que podem ser usados para clicar, da mesma forma que os botões do mouse. Alguns touchpads também suportam gestos mais complexos, como rolagem de duas dedos, pinça para zoom e três dedos para trazer uma visão geral das janelas abertas.

Em resumo, tanto as telas sensíveis ao toque quanto os touchpads são tecnologias importantes que permitem aos usuários interagir de maneira intuitiva e direta com seus dispositivos. Cada um tem seus próprios usos e vantagens, dependendo do tipo de dispositivo e do contexto em que é usado.

5.4.6 Monitores de tela plana

Os monitores de tela plana são dispositivos de exibição finos e leves que utilizam diferentes tecnologias para exibir informações de um computador ou outro dispositivo eletrônico. Eles substituíram os monitores de tubo de raios catódicos (CRT) mais antigos, que eram volumosos e consumiam mais energia. Existem três tipos principais de monitores de tela plana: LCD (*Liquid Crystal Display*), LED (*Light Emitting Diodes*) e OLED (*Organic Light Emitting Diodes*).

- **LCD (*Liquid Crystal Display*):** Os monitores LCD funcionam manipulando a luz que passa por duas camadas de cristais líquidos. Cada pixel em uma tela LCD é composto por células de cristal líquido que são iluminadas por uma luz de fundo. Ao aplicar uma corrente elétrica a essas células, é possível controlar a quantidade de luz que passa através de cada célula para criar uma imagem. Os monitores LCD são eficientes em termos de energia e oferecem boa qualidade de imagem, mas podem ter problemas com a reprodução de cores profundas e pretos verdadeiros.
- **LED (*Light Emitting Diodes*):** Os monitores LED são na verdade um tipo de monitor LCD. Eles utilizam a mesma tecnologia de cristal líquido para criar uma imagem, mas em vez de usar uma lâmpada fluorescente para a iluminação de fundo, eles usam LEDs. Isso permite uma gama de cores mais ampla, melhores pretos e maior eficiência energética em comparação com os monitores LCD padrão. Além disso, existem dois tipos de monitores LED: diretos (onde os LEDs estão atrás da tela) e de borda (onde os LEDs estão ao redor das bordas da tela).
- **OLED (*Organic Light Emitting Diodes*):** Os monitores OLED são diferentes dos LCDs e LEDs, pois cada pixel em uma tela OLED emite sua própria luz, eliminando a necessidade de luz de fundo. Isso resulta em pretos mais profundos e uma gama de cores mais ampla do que os monitores LCD ou LED. Também é relevante comentar que os monitores OLED podem ser mais finos e leves, e podem até ser flexíveis. No entanto, eles tendem a ser mais caros e têm uma vida útil mais curta.

A estrutura típica de um monitor de tela plana inclui a seguinte:

- **Painel de exibição:** Esta é a parte do monitor onde a imagem é exibida. Dependendo do tipo de monitor, o painel de exibição pode ser composto por células de cristal líquido (LCD), LEDs ou diodos orgânicos emissores de luz (OLED).
- **Luz de fundo:** Para monitores LCD e LED, uma luz de fundo é necessária para iluminar os pixels na tela. As luzes de fundo podem ser lâmpadas fluorescentes (para LCDs) ou LEDs (para LEDs).

- Eletrônicos: Estes controlam a corrente elétrica que passa através de cada pixel, determinando assim a cor e a intensidade da luz que cada pixel emite.
- Moldura: Esta é a estrutura que envolve a tela e os componentes eletrônicos. Também pode conter botões ou controles para ajustar as configurações do monitor.
- Suporte ou Base: Isso permite que o monitor fique em pé em uma mesa ou outra superfície.

O funcionamento de um monitor de tela plana depende do tipo de tecnologia que ele usa (LCD, LED ou OLED). No entanto, em termos gerais, o processo é o seguinte:

- O computador ou outro dispositivo envia um sinal ao monitor, indicando quais pixels devem ser iluminados e em que cores.
- A corrente elétrica é aplicada a esses pixels através dos circuitos eletrônicos no monitor.
- A corrente elétrica faz com que os cristais líquidos, LEDs ou diodos orgânicos emissores de luz nos pixels emitam luz de uma cor específica.
- A luz de cada pixel se combina para formar uma imagem completa na tela.

Apesar de já termos abordado as principais informações sobre os monitores de tela plana, vale mencionar que além das tecnologias LCD, LED e OLED, existem outras menos comuns, como a Plasma e a QLED.

- Plasma: Esses monitores funcionam enchendo pequenas células com gás de plasma. Quando uma corrente elétrica é aplicada, o gás emite luz ultravioleta que faz com que os fósforos dentro de cada célula brilhem, produzindo uma imagem. Essa tecnologia, embora ofereça altos contrastes e cores vivas, consome mais energia e é mais comum em TVs de grandes dimensões do que em monitores de computador.
- QLED (*Quantum-dot Light Emitting Diodes*): Esta é uma tecnologia de exibição que usa pontos quânticos - nano-cristais semicondutores que podem emitir luz de diferentes cores. A tecnologia QLED é capaz de produzir cores mais precisas e alcançar maior brilho do que as telas OLED ou LCD. É importante notar que as TVs QLED ainda usam uma luz

de fundo, semelhante à tecnologia LED, com os pontos quânticos sendo uma camada adicional que melhora a cor.

Em relação ao funcionamento, em um nível mais detalhado, quando um sinal é enviado do computador para o monitor, o sinal é convertido em um formato que o monitor pode entender. Este processo é realizado pelo circuito de controle do monitor, que usa esta informação para determinar a cor e a intensidade da luz que cada pixel deve emitir. Este controle é feito por transistores que regulam a corrente elétrica que flui para cada pixel.

A frequência de atualização, medida em Hertz (Hz), também é um aspecto importante a considerar em um monitor. Refere-se ao número de vezes que a tela é atualizada por segundo. Uma frequência de atualização mais alta pode resultar em uma imagem mais suave e menos cintilação.

Outro conceito chave é a resolução do monitor, que é o número de pixels exibidos na tela. A resolução pode variar de HD (1280x720 pixels) a Full HD (1920x1080 pixels), Quad HD (2560x1440 pixels) e até Ultra HD ou 4K (3840x2160 pixels). Uma maior resolução permite uma imagem mais nítida e detalhada.

5.4.7 RAM de vídeos

A RAM de vídeo (VRAM), também chamada de memória de acesso aleatório de vídeo, é uma memória especial embutida na placa de vídeo do computador. Essa memória é responsável por armazenar e atualizar as informações que são exibidas na tela do monitor.

A VRAM contém um ou mais mapas de bits que representam a imagem na tela. Em um monitor com resolução de 1920 x 1080 pixels, a VRAM conteria 1.920 x 1.080 valores, um para cada pixel. Na realidade, a VRAM pode armazenar vários mapas de bits para permitir uma transição rápida entre diferentes imagens ou quadros.

Em um monitor padrão, cada pixel é representado como um valor RGB de 3 bytes, com um byte para cada intensidade de cor vermelha, verde e azul. Isso se baseia no fato de que qualquer cor pode ser obtida pela sobreposição de luzes vermelha, verde e azul.

A RAM de vídeo para um monitor com resolução de 1920 x 1080 pixels e 3 bytes por pixel requer mais de 6,2 MB para armazenar a imagem. Essa grande quantidade de dados pode demandar bastante tempo de processamento da CPU para manipular. Para resolver este problema, alguns sistemas utilizam um método chamado cor indexada.

No método de cor indexada, um número de 8 bits é usado para indicar a cor desejada. Este número é então usado como índice para uma tabela de hardware chamada paleta de cores. Esta paleta contém 256 entradas, cada uma com um valor RGB de 24 bits. Isso reduz o tamanho da memória da VRAM em dois terços, mas limita a quantidade de cores exibidas na tela ao mesmo tempo para 256.

Os monitores de vídeo com mapas de bits requerem uma grande largura de banda. Para exibir multimídia em tela cheia com todas as cores em um monitor de 1920 x 1080, são necessários 6,2 MB de dados para serem copiados para a VRAM para cada quadro. Para vídeos de movimento total, uma taxa mínima de 25 quadros por segundo é necessária, o que resulta em uma taxa de dados total de 155 MB/s. Embora isso exceda a capacidade do barramento PCI original (132 MB/s), os sistemas modernos que usam PCIe (*PCI Express*) podem lidar com essa carga com facilidade.

5.4.8 Mouses

Um mouse de computador é um dispositivo de entrada que permite ao usuário interagir com o computador movendo um cursor na tela. Ele normalmente tem pelo menos dois botões e, em muitos casos, uma roda de rolagem que também pode funcionar como um terceiro botão.

- **Movimento:** Um mouse pode detectar movimento de duas maneiras principais, através de mecanismos mecânicos ou ópticos. Em um mouse mecânico, uma bola na parte inferior do mouse rola à medida que você move o mouse. Esta bola está conectada a dois rotores que giram quando a bola se move. Um sensor óptico dentro do mouse detecta essa rotação e a converte em sinais elétricos que o computador interpreta como movimento. Já os mouses ópticos, que são mais comuns hoje em dia, usam um LED ou um laser para projetar luz na superfície abaixo do mouse. Quando o mouse é movido, a luz reflete de volta para um sensor

CMOS no mouse. Este sensor tira fotos da superfície em rápida sucessão e um DSP (Processador de Sinal Digital) no mouse analisa essas imagens para determinar a direção e a velocidade do movimento do mouse.

- **Cliques e rolagem:** Quando você clica em um botão do mouse, isso pressiona um interruptor que envia um sinal ao computador. Da mesma forma, quando você gira a roda de rolagem, ela gira um disco com fendas que interrompe um feixe de luz. Um sensor detecta essas interrupções e as converte em sinais de rolagem. Algumas rodas de rolagem também podem ser pressionadas como um botão.
- **Comunicação com o computador:** Os sinais de movimento, clique e rolagem do mouse são então enviados ao computador. Mouses com fio geralmente se conectam via USB e enviam os sinais diretamente através do cabo. Mouses sem fio podem usar tecnologia de radiofrequência (como o Bluetooth) ou infravermelho para transmitir os sinais para um receptor conectado ao computador.
- **Interpretação dos sinais:** O sistema operacional do computador tem um driver de mouse que interpreta os sinais do mouse e os converte em movimento do cursor, cliques e rolagem na tela.

5.5 Impressoras

5.5.1 Impressoras a laser

As impressoras a laser são uma das tecnologias mais populares de impressão usadas hoje em dia, especialmente em ambientes de escritório devido à sua alta velocidade, qualidade e eficiência de custos para impressões em grande volume. As etapas pelas quais a impressora laser passa para imprimir um documento são explicadas abaixo:

- **Preparação:** Quando um documento é enviado para a impressora, a impressora prepara-se para o trabalho de impressão. Dentro da impressora, um tambor fotossensível é carregado com eletricidade estática por um fio de corona ou rolo de carga primária. O tambor, que tem uma camada de material que pode conduzir eletricidade quando exposto à luz, inicialmente tem uma carga positiva.

- **Escrevendo a imagem:** A impressora então usa um raio laser para descarregar certas áreas do tambor. O laser é direcionado por um espelho móvel e "desenha" a imagem da página no tambor, ponto por ponto. As áreas do tambor atingidas pelo laser perdem sua carga elétrica, criando uma imagem eletrostática do que deve ser impresso.
- **Desenvolvimento:** O toner da impressora (que é uma espécie de tinta em pó) é carregado com uma carga elétrica oposta à carga do tambor. Quando o tambor roda, o toner é atraído para as áreas do tambor que foram descarregadas pelo laser. Isso forma uma imagem de toner no tambor.
- **Transferência:** Uma folha de papel é então passada pela impressora. A impressora aplica uma carga mais forte ao papel, atraindo o toner da imagem para o papel.
- **Fusão:** O papel com o toner é então passado por rolos de fusão aquecidos. O calor e a pressão fundem o toner ao papel, criando a impressão final.
- **Limpeza:** Finalmente, qualquer toner restante é limpo do tambor e o excesso de carga elétrica é removido. O tambor então é recarregado e está pronto para a próxima página a ser impressa.

Essas etapas acontecem muito rapidamente e podem ser repetidas várias vezes para impressões em múltiplas páginas. De fato, impressoras a laser modernas podem imprimir de 20 a 100 páginas por minuto ou mais. Além disso, o processo de impressão a laser é o mesmo para impressoras monocromáticas e coloridas, embora as impressoras coloridas repitam o processo quatro vezes - uma para cada cor de toner (ciano, magenta, amarelo e preto) usada na impressão.

5.5.2 Impressora jato de tinta

As impressoras a jato de tinta são um tipo popular de impressora que são usadas tanto para uso doméstico quanto para escritório. Elas são conhecidas por sua capacidade de imprimir em cores e produzir imagens de alta qualidade. Abaixo estão os passos pela qual uma impressora jato de tinta passa para imprimir um documento:

- **Preparação:** Quando um documento é enviado para a impressora, a impressora prepara-se para o trabalho de impressão. A página a ser impressa é alimentada na impressora a partir de uma bandeja de entrada e alinhada para iniciar o processo de impressão.
- **Aplicação da tinta:** A impressora possui um carro de impressão que contém cartuchos de tinta. Cada cartucho tem um chip eletrônico que se comunica com a impressora para garantir a cor correta da tinta no local certo. Os cartuchos de tinta costumam ter quatro cores: preto, ciano, magenta e amarelo.
- **Formação da imagem:** Dentro de cada cartucho de tinta, há uma série de minúsculas câmaras cheias de tinta. As impressoras a jato de tinta funcionam expelindo gotas microscópicas de tinta das câmaras para formar a imagem ou texto na página. Existem dois principais métodos utilizados para fazer isso:
 - Tecnologia térmica: Usada pela Canon e pela HP, esta tecnologia utiliza calor para disparar a tinta. A eletricidade é usada para aquecer um pequeno resistor que fica na câmara de tinta, o calor faz a tinta formar uma bolha que se expande até que uma gota de tinta é forçada para fora do cartucho e na página.
 - Tecnologia Piezoelétrica: Utilizada pela Epson, esta tecnologia utiliza um cristal piezoelétrico para disparar a tinta. Uma corrente elétrica é aplicada ao cristal piezoelétrico dentro da câmara de tinta, fazendo-o vibrar. Esta vibração força uma gota de tinta para fora do cartucho e na página.
- **Movimento do carro de impressão:** O carro de impressão se move para frente e para trás através da página, disparando gotas de tinta conforme ele se move. O papel é então alimentado incrementalmente para a próxima linha, um processo conhecido como "alimentação de linha", e o processo se repete até que a página inteira seja impressa.
- **Finalização:** Uma vez que a página foi totalmente impressa, é alimentada para a bandeja de saída da impressora. Enquanto isso, o carro de

impressão retorna à sua posição inicial, pronto para imprimir a próxima página.

Essas etapas são feitas de forma extremamente rápida e precisa, o que permite às impressoras a jato de tinta produzir impressões detalhadas e coloridas. No entanto, elas geralmente operam em velocidades mais lentas do que as impressoras a laser e são mais bem utilizadas para trabalhos de impressão de menor volume.

5.6 Código de caracteres

Cada computador tem um conjunto de caracteres que ele usa. O conjunto mínimo contém as 26 letras maiúsculas, as 26 letras minúsculas, os algarismos 0 a 9 e um conjunto de símbolos especiais, como espaço, sinal de menos, vírgula e retorno ao início da linha.

Para transferir esses caracteres para o computador, um número é designado a cada um, por exemplo, a = 1, b = 2, ..., z = 26, + = 27, - = 28. O mapeamento de caracteres para números inteiros é denominado código de caracteres. É essencial que computadores que se comunicam usem o mesmo código ou não conseguirão se entender. Por essa razão, foram desenvolvidos padrões.

5.6.1 ASCII

Um sistema de codificação frequentemente usado é o ASCII (Código Padrão Americano para Troca de Informações). Cada caractere ASCII é composto por 7 bits, permitindo a representação de 128 caracteres diferentes. No entanto, já que os computadores são baseados em bytes, cada caractere ASCII é armazenado em um byte separado. A Figura “Tabela ASCII” apresenta o código ASCII. Os códigos que vão de 0 a 1F (em hexadecimal) correspondem a caracteres de controle que não são visíveis na impressão. Os códigos que vão de 128 a 255 não fazem parte do conjunto original ASCII, mas foram definidos pelo IBM PC como caracteres especiais, como os emoticons, sendo que a maioria dos computadores os suporta.

Dec	Hex	Oct	Chr	Dec	Hex	Oct	HTML	Chr	Dec	Hex	Oct	HTML	Chr	Dec	Hex	Oct	HTML	Chr
0	0	000	NULL	32	20	040	 	Space	64	40	100	@	@	96	60	140	`	`
1	1	001	Start of Header	33	21	041	!	!	65	41	101	A	A	97	61	141	a	a
2	2	002	Start of Text	34	22	042	"	"	66	42	102	B	B	98	62	142	b	b
3	3	003	End of Text	35	23	043	#	#	67	43	103	C	C	99	63	143	c	c
4	4	004	End of Transmission	36	24	044	$	\$	68	44	104	D	D	100	64	144	d	d
5	5	005	Enquiry	37	25	045	%	%	69	45	105	E	E	101	65	145	e	e
6	6	006	Acknowledgment	38	26	046	&	&	70	46	106	F	F	102	66	146	f	f
7	7	007	Bell	39	27	047	'	'	71	47	107	G	G	103	67	147	g	g
8	8	010	Backspace	40	28	050	(	(	72	48	110	H	H	104	68	150	h	h
9	9	011	Horizontal Tab	41	29	051	)	)	73	49	111	I	I	105	69	151	i	i
10	A	012	Line feed	42	2A	052	*	*	74	4A	112	J	J	106	6A	152	j	j
11	B	013	Vertical Tab	43	2B	053	+	+	75	4B	113	K	K	107	6B	153	k	k
12	C	014	Form feed	44	2C	054	,	,	76	4C	114	L	L	108	6C	154	l	l
13	D	015	Carriage return	45	2D	055	-	-	77	4D	115	M	M	109	6D	155	m	m
14	E	016	Shift Out	46	2E	056	.	.	78	4E	116	N	N	110	6E	156	n	n
15	F	017	Shift In	47	2F	057	/	/	79	4F	117	O	O	111	6F	157	o	o
16	10	020	Data Link Escape	48	30	060	0	0	80	50	120	P	P	112	70	160	p	p
17	11	021	Device Control 1	49	31	061	1	1	81	51	121	Q	Q	113	71	161	q	q
18	12	022	Device Control 2	50	32	062	2	2	82	52	122	R	R	114	72	162	r	r
19	13	023	Device Control 3	51	33	063	3	3	83	53	123	S	S	115	73	163	s	s
20	14	024	Device Control 4	52	34	064	4	4	84	54	124	T	T	116	74	164	t	t
21	15	025	Negative Ack.	53	35	065	5	5	85	55	125	U	U	117	75	165	u	u
22	16	026	Synchronous idle	54	36	066	6	6	86	56	126	V	V	118	76	166	v	v
23	17	027	End of Trans. Block	55	37	067	7	7	87	57	127	W	W	119	77	167	w	w
24	18	030	Cancel	56	38	070	8	8	88	58	130	X	X	120	78	170	x	x
25	19	031	End of Medium	57	39	071	9	9	89	59	131	Y	Y	121	79	171	y	y
26	1A	032	Substitute	58	3A	072	:	:	90	5A	132	Z	Z	122	7A	172	z	z
27	1B	033	Escape	59	3B	073	;	;	91	5B	133	[	[	123	7B	173	{	{
28	1C	034	File Separator	60	3C	074	<	<	92	5C	134	\	\	124	7C	174	|	
29	1D	035	Group Separator	61	3D	075	=	=	93	5D	135	]	]	125	7D	175	}	}
30	1E	036	Record Separator	62	3E	076	>	>	94	5E	136	^	^	126	7E	176	~	~
31	1F	037	Unit Separator	63	3F	077	?	?	95	5F	137	_	_	127	7F	177		Del

Figura 30 – Tabela ASCII
Fonte: Google Imagens (2023)

Vários caracteres de controle ASCII são designados para a transmissão de dados. Por exemplo, uma mensagem poderia iniciar com o caractere SOH (Start of Header - Início do Cabeçalho), seguido pelo caractere EOT (End of Transmission - Fim da Transmissão). No entanto, na realidade, as mensagens enviadas por linhas telefônicas e redes são estruturadas de maneira distinta, fazendo com que os caracteres de controle de transmissão ASCII não sejam amplamente utilizados.

5.6.2 Unicode

A indústria de computadores, majoritariamente desenvolvida nos Estados Unidos, criou o conjunto de caracteres ASCII, eficiente para o inglês, mas com limitações para outros idiomas. Por exemplo, o francês necessita de acentos e o alemão de sinais diacríticos, enquanto línguas como o russo e árabe utilizam alfabetos completamente diferentes.

Com a expansão global da tecnologia e a demanda por softwares em diferentes idiomas, surgiu a necessidade de um novo conjunto de caracteres. Assim, foram feitas tentativas de expansão do ASCII, como o IS 646 e o IS 8859, porém essas soluções apresentavam limitações, como a impossibilidade de mistura de idiomas em uma única página de código.

Para superar esses desafios, foi criado o Unicode, que transformou cada caractere e símbolo em um valor único de 16 bits, conhecido como ponto de código. Isso simplificou a escrita de software e possibilitou a representação de praticamente todos os sistemas de escrita do mundo.

No entanto, o Unicode não resolve todos os problemas de internacionalização. Enquanto o alfabeto latino está em ordem alfabética, os ideogramas chineses não estão na ordem do dicionário, o que pode complicar a organização dos caracteres em softwares que usam esses idiomas.

Além disso, o surgimento constante de novas palavras e termos técnicos em todos os idiomas exige a adição contínua de novos pontos de código. Em 1996, o Unicode foi expandido para acomodar essas necessidades, aumentando o número total de caracteres possíveis para 1.114.112.

Ainda assim, a codificação Unicode é um trabalho em andamento, demandando estudos contínuos e decisões cuidadosas para lidar com os desafios linguísticos e culturais da comunidade global de usuários de computadores.

5.6.3 UTF-8

Embora o Unicode seja um avanço significativo em relação ao ASCII, encontrou-se limitado devido à exaustão de pontos de código e ao requisito de 16 bits para cada caractere. Para superar esses desafios, foi desenvolvido o UTF-8 (Formato de Transformação UCS - Conjunto Universal de Caracteres), que se tornou a codificação dominante na web devido à sua versatilidade.

O UTF-8 permite codificações de tamanho variável de 1 a 4 bytes, podendo representar cerca de dois bilhões de caracteres. Uma característica importante do UTF-8 é que os códigos de 0 a 127 correspondem aos caracteres ASCII, podendo ser expressos em apenas 1 byte, o que é mais eficiente.

Além disso, o UTF-8 possui um recurso de sincronização automática. Isso significa que, no caso de um erro, é possível encontrar o início do próximo caractere, facilitando a correção de erros e a continuidade do processamento de texto.

Finalmente, embora geralmente usado para codificar os 17 planos do Unicode, o UTF-8 tem capacidade para representar muitos mais pontos de código, preparando-se para acomodar possíveis novas descobertas linguísticas ou alfabetos. A figura 5-16 mostra o esquema de codificação UTF-8.

Bits	Byte 1	Byte 2	Byte 3	Byte 4	Byte 5	Byte 6
7	0ddddddd	-	-	-	-	-
11	110dddddd	1110dddd	-	-	-	-
16	1110dddd	10ddddddd	10ddddddd	-	-	-
21	11110ddd	10ddddddd	10ddddddd	10ddddddd	-	-
26	111110dd	10ddddddd	10ddddddd	10ddddddd	10ddddddd	-
31	1111110d	10ddddddd	10ddddddd	10ddddddd	10ddddddd	10ddddddd

Tabela 6 – UTF-8
Fonte: TANENBAUM; AUSTIN (2013)

CONCLUSÃO

Neste capítulo, exploramos os componentes fundamentais que constituem os sistemas de computadores, incluindo processadores, memórias e dispositivos de E/S. Aprofundamo-nos no funcionamento de um processador, discutindo seu ciclo de busca-decodificação-execução e como este pode ser otimizado por meio de pipelines ou um design superescalar para aumentar o paralelismo.

Além disso, discutimos os avanços em computação paralela e o surgimento de sistemas com múltiplos processadores, incluindo processadores matriciais, multiprocessadores e multicomputadores. Esses sistemas são capazes de lidar com conjuntos de dados mais volumosos, executando várias operações simultaneamente, o que representa um salto significativo na eficiência computacional.

Em relação às memórias, detalhamos as diferenças entre as memórias primárias e secundárias e suas funções em um sistema de computador. Abordamos a importância das caches para reduzir o tempo de acesso à memória e como códigos de correção de erros podem aumentar a confiabilidade das memórias.

Também discutimos a natureza dos dispositivos de E/S, que são vitais para transferir informações para dentro e para fora do computador. Esses dispositivos usam códigos de caracteres, principalmente ASCII, mas também Unicode e UTF-8, com este último ganhando popularidade devido ao aumento da atividade baseada na web.

Assim, vimos que a arquitetura de um computador é um campo complexo, mas fascinante, onde várias partes funcionam em conjunto para atender às demandas computacionais cada vez mais exigentes do mundo moderno. Cada componente, seja ele um processador, memória ou dispositivo de E/S, tem um papel crucial a desempenhar, contribuindo para a evolução constante da tecnologia da computação.

REFERÊNCIAS

FREETH, Tony et al. Decoding the ancient Greek astronomical calculator known as the Antikythera Mechanism. **Nature**, [S.l.], v. 444, n. 7119, p. 587-591, 2006.

HOW PRODUCTS ARE MADE. Compact disc. s. n. Disponível em: <<http://www.madehow.com/Volume-1/Compact-Disc.html>>. Acesso em: 17 jul. 2023.

IFRAH, Georges. **The Universal History of Computing**: From the Abacus to the Quantum Computer. Nova Iorque: Wiley, 2001.

TANENBAUM, Andrew Stuart; AUSTIN, Todd. **Organização Estruturada de Computadores**. 6. ed. Rio de Janeiro: Pearson, 2013.