


CLOUD SEC & IA

INTRODUCTION TO ARTIFICIAL INTELLIGENCE



10

LISTA DE FIGURAS

Figura 1 - Tin Woodman conforme ilustrado por William Wallace Denslow (1900) ...	8
Figura 2 - Cena do filme <i>O Jogo da Imitação</i> (2014).....	10
Figura 3 - Exemplo do Teste de Turing	11
Figura 4 - Representação de ELIZA feita por Norbert Landsteiner (2005)	13
Figura 5 - Jogo de xadrez entre Garry Kasparov e IBM® Deep Blue®	15
Figura 6 - Participação do computador Watson no programa “ <i>Jeopardy!</i> ”	17
Figura 7 - Siri.....	19
Figura 8 - Amazon Echo.....	21
Figura 9 - Partida de Go entre AlphaGo e Lee Sedol	23
Figura 10 - ChatGPT no navegador	27
Figura 11 - Dois gráficos gerados a partir da tabela simples	30
Figura 12 - Uma mensagem publicada no X (antigo Twitter)	33
Figura 13 - Quantidade de dados gerados pelos principais serviços em um minuto.....	37
Figura 14 - Relação dos campos de estudos sobre Inteligência Artificial com uma matriosca.....	39
Figura 15 - Estrutura de uma Rede Neural	42
Figura 16 - IBM Debater	47
Figura 17 - Lista de profissões com demanda elevada no mercado de trabalho	52

SUMÁRIO

1 INTRODUÇÃO A INTELIGÊNCIA ARTIFICIAL	4
1.1 Mas o que é a Inteligência Artificial (ou IA)?	4
1.2 História da Inteligência Artificial	7
1.2.1 Tin Woodman, o personagem do livro <i>O Mágico de Oz</i>	7
1.2.2 Alan Turing, o pai da ciência da computação	8
1.2.3 Conferência de Dartmouth, o surgimento do termo Inteligência Artificial	11
1.2.4 ELIZA, o primeiro chatbot	12
1.2.5 IBM Deep Blue	13
1.2.6 IBM Watson	15
1.2.7 Siri	18
1.2.8 Amazon Alexa	19
1.2.9 AlphaGo	21
1.2.10 OpenAI ChatGPT	24
1.3 Por que IA?	27
1.3.1 Dados estruturados	29
1.3.2 Dados não estruturados	31
1.3.3 Dados semiestruturados	34
1.3.4 Expectativa do crescimento dos dados no mundo	36
2 INTELIGÊNCIA ARTIFICIAL, <i>MACHINE LEARNING</i> , <i>DEEP LEARNING</i> E INTELIGÊNCIA ARTIFICIAL GENERATIVA	38
2.1 <i>Machine Learning</i> (ou ML)	40
2.2 <i>Deep Learning</i> (ou DL)	41
2.3 Computação Cognitiva	45
2.4 IA Generativa	47
2.5 Mercado de trabalho	50
REFERÊNCIAS	53

1 INTRODUÇÃO A INTELIGÊNCIA ARTIFICIAL

Devido ao avanço da tecnologia e ao crescimento de sua adoção por parte das empresas, muitos estudos sobre a Inteligência Artificial começaram a sair do campo das ideias para se tornarem projetos e produtos que hoje estão presentes em nosso dia a dia.

Alguma vez você já contou quantos serviços e aplicativos que você usa diariamente têm Inteligência Artificial? É bem provável que você não acerte a resposta. Isso porque a grande maioria das empresas, cada vez mais, vem adotando essa tecnologia para automatizar processos e melhorar a experiência do consumidor final. Um exemplo prático é a Netflix que utiliza a Inteligência Artificial para mostrar um frame (uma imagem extraída) de um filme ou série de acordo com o que você já assistiu na plataforma. Outro exemplo é o Magazine Luiza, que utiliza a Inteligência Artificial na Lu, uma persona virtual criada pela empresa para melhorar a experiência na comunicação com os seus consumidores, nos principais canais de comunicação (Facebook, WhatsApp, entre outros).

1.1 Mas o que é a Inteligência Artificial (ou IA)?

A Inteligência Artificial (ou de forma curta, a IA) refere-se ao desenvolvimento de sistemas de computadores ou máquinas que executam tarefas que, tipicamente, requerem inteligência humana. Isso envolve a criação de agentes inteligentes capazes de perceber seu ambiente, raciocinar sobre ele e tomar ações para atingir determinados objetivos. Em 1990, um grande inventor e futurista, Ray Kurzweil, criou uma definição sobre a Inteligência Artificial que simplifica bem a visão que o mundo tem sobre a IA nos dias de hoje. Segundo Kurzweil: “A Inteligência Artificial é a arte de criar máquinas que executam funções as quais requerem inteligência quando executadas por pessoas”.

A Inteligência Artificial visa simular e replicar as habilidades cognitivas humanas, como aprendizado, resolução de problemas, reconhecimento de padrões, compreensão da linguagem e tomada de decisões. Envolve o estudo de algoritmos,

modelos estatísticos e técnicas computacionais para permitir que máquinas exibam comportamento inteligente.

Por um lado, podemos aprender como as máquinas podem resolver problemas por meio da observação das pessoas — um campo de estudo que vem sendo pesquisado desde o começo da história da Inteligência Artificial. Por outro lado, a maioria dos estudos envolve os problemas que o mundo apresenta, e não o estudo de pessoas.

Existem dois principais tipos de IA:

- **Inteligência Artificial Geral (do inglês, *Artificial General Intelligence* — ou *General AI*):** também conhecida como Inteligência Artificial Forte. A IA Geral se refere a sistemas de Inteligência Artificial que exibem inteligência similar a humana e possui a habilidade de entender, aprender e aplicar conhecimento através de uma variedade de tarefas e domínios. Tem como foco replicar a versatilidade e adaptabilidade da inteligência humana. Atualmente não há um exemplo de um sistema verdadeiramente de IA Geral.
- **Inteligência Artificial Limitada (do inglês, *Narrow Artificial Intelligence* — ou *Narrow AI*):** também conhecida como Inteligência Artificial Fraca. A IA Limitada se refere a sistemas de Inteligência Artificial que são projetadas e desenvolvidas para executar tarefas ou funções específicas dentro de um domínio limitado. Esses sistemas são altamente especializados e se destacam em um número limitado de atividades. Eles se concentram na resolução de problemas bem definidos e não são capazes de generalizar seus conhecimentos para outros domínios ou tarefas. Exemplos de IA Limitada: assistentes de voz (como Siri, Alexa ou Google Assistant), sistemas de recomendação (usados em e-commerce, como na Amazon, em serviços de streaming, como na Netflix, em redes sociais, como no TikTok) e reconhecimento de imagens (como reconhecimento facial, detecção de objetos).

A IA Geral é capaz de realizar tarefas intelectuais no nível ou além da capacidade humana. No entanto, alcançar a verdadeira Inteligência Artificial Geral ainda é um desafio significativo e continua sendo uma área ativa de pesquisa.

Enquanto isso, a IA Limitada depende de algoritmos, dados e regras predefinidas e específicas para executar suas tarefas com eficiência. Eles não possuem inteligência geral ou capacidade de entender o contexto além de seu domínio de conhecimento.

É importante observar que, embora a IA Limitada possa ser altamente proficiente em seus domínios específicos, eles carecem da generalização e flexibilidade presentes na inteligência humana. O desenvolvimento da IA Geral apresenta desafios técnicos e éticos complexos. Por esta razão, há um debate e exploração contínuos em torno de sua viabilidade e implicações. O ChatGPT, por exemplo, não é considerado um exemplo de uma IA Geral, ou seja, o ChatGPT, assim como outros modelos de linguagem (incluindo os Large Language Model, ou LLM), é classificado como uma IA Limitada ou IA Fraca. Enquanto o ChatGPT pode gerar respostas contextualmente relevantes e coerentes, o serviço carece da compreensão, generalização e adaptabilidade mais amplas apresentadas pela inteligência humana ou pela definição pura da IA Geral. Ele opera com base em padrões e correlações estatísticas que aprendeu com grandes quantidades de dados de texto, em vez de possuir uma verdadeira compreensão ou consciência.

Nesta etapa, daremos ênfase na Inteligência Artificial Limitada pois concentra-se em tarefas especializadas em domínios específicos e é, atualmente, aplicada na prática, enquanto a Inteligência Artificial Geral ainda representa uma meta ambiciosa, ainda que próxima, para avanços futuros em aplicações em nosso cotidiano. Hoje, a aplicação mais difundida de Inteligência Artificial é com o uso de chatbots e assistentes virtuais. Um dos casos mais conhecidos é a BIA (Bradesco Inteligência Artificial), assistente virtual do Bradesco para correntistas e colaboradores do banco.

Em 2015, o Bradesco fechou um contrato de trabalho com a IBM para desenvolver a BIA — nessa época, ainda não existia um serviço de interface conversacional (base para a construção de um chatbot ou assistente virtual) em português. No ano seguinte, depois de treinar a IA com as principais dúvidas que os gerentes de agência tinham, o Bradesco disponibilizou a BIA em uma das agências do banco para que ela pudesse responder às dúvidas de seus gerentes. Com o sucesso da ferramenta na primeira agência, o banco a disponibilizou para mais agências até atingir 100%, incluindo os funcionários do HSBC, após a aquisição da operação do banco HSBC no Brasil.

Ainda no mesmo ano, em 2016, com o sucesso do projeto e sua maturidade, ao longo de milhares e milhares de interações por dia, a diretoria do banco decidiu expandir o projeto para responder às dúvidas dos clientes. Foi em 2017 que o Bradesco disponibilizou a BIA para todos os clientes. Em 2019, o número de interações com a IA do Bradesco chegou a 87 milhões, entre funcionários e clientes, e o uso dessa ferramenta expandiu-se para mais canais de comunicação, além de ter sido feita a releitura dela para criar uma versão da BIA voltada ao banco digital Next, que tem os *millenials* como público.

Além da BIA, existem diversos outros exemplos, como a Lu do Magazine Luiza, mencionada anteriormente, que abordaremos ao longo do curso para que você tenha referências do que deu certo até hoje.

E agora que você entendeu a definição com um exemplo prático, chegou a hora de dar um passo para trás a fim de compreender como surgiu a Inteligência Artificial e sua história até os dias atuais.

1.2 História da Inteligência Artificial

Antes de existirem os computadores e até mesmo o termo Inteligência Artificial, diversos matemáticos e filósofos propunham métodos e estudos que procuravam entender e simplificar a mente humana, de forma que o conhecimento fosse uma combinação de conceitos ou que o raciocínio lógico pudesse ser executado sistematicamente da mesma maneira que se resolve um sistema de equações.

1.2.1 Tin Woodman, o personagem do livro *O Mágico de Oz*

Na primeira metade do século XX, a ficção científica trouxe ao mundo o conceito de robôs artificialmente inteligentes com o personagem Tin Woodman do livro *The Wonderful Wizard of Oz* (O Maravilhoso Mágico de Oz), escrito por Lyman Frank Baum.

Tin Woodman (também chamado Tin Man ou Homem de Lata — este último é o nome utilizado na tradução para o português) é um personagem descrito como “um Homem Feito de Lata”. Por mais que ele tenha sido um humano no passado e

enfrentado uma série de acidentes que o fez substituir partes de seu corpo por lata, o personagem se assemelha bastante a um robô que, além de apresentar uma determinada inteligência, possui características “humanas” devido ao seu passado como lenhador.




Figura 1 - Tin Woodman conforme ilustrado por William Wallace Denslow (1900)
Fonte: Adaptada por FIAP (2025)

1.2.2 Alan Turing, o pai da ciência da computação

Na década de 1950, houve uma geração de cientistas, matemáticos e filósofos com o conceito de Inteligência Artificial culturalmente assimilado em suas mentes. O mais conhecido deles é Alan Turing, um matemático e cientista da computação britânico. Turing fez contribuições inovadoras que lançaram as bases para a ciência da computação moderna e a Inteligência Artificial. Nascido em 1912, Turing demonstrou habilidades matemáticas excepcionais desde cedo.

Sua contribuição mais significativa para a ciência da computação veio por meio de seu artigo de 1936 “*On Computable Numbers*”, onde ele introduziu o conceito da Máquina de Turing, um modelo matemático de computação que manipula símbolos em uma tira de fita de acordo com uma tabela de regras. Este dispositivo teórico se

tornou a base da ciência da computação e demonstrou como uma máquina poderia simular qualquer algoritmo de computador. A Máquina de Turing provou que certos problemas matemáticos são “indecidíveis”, o que significa que não podem ser resolvidos por nenhum algoritmo.

Durante a Segunda Guerra Mundial, Turing desempenhou um papel crucial em Bletchley Park, onde ajudou a quebrar o código alemão Enigma. Seu trabalho na máquina Bombe, que decodificou mensagens alemãs criptografadas, demonstrou a aplicação prática da computação mecânica e influenciou significativamente o desenvolvimento dos primeiros computadores.

Após a guerra, Turing trabalhou no projeto do ACE (Automatic Computing Engine), um dos primeiros projetos de computador de programa armazenado. Ele também fez contribuições significativas para a Inteligência Artificial, introduzindo o famoso “Teste de Turing” em seu artigo de 1950 “*Computing Machinery and Intelligence*”. Este teste propõe um método para determinar se uma máquina pode exibir comportamento inteligente indistinguível de um humano.

Turing ganhou o título de “pai da ciência da computação” porque seu trabalho teórico e prático estabeleceu os princípios fundamentais da computação moderna. Seu modelo abstrato de computação, a Máquina de Turing, continua sendo a base para entender o que os computadores podem e não podem fazer. Suas ideias sobre computadores programáveis, Aprendizado de Máquina e Inteligência Artificial estavam décadas à frente de seu tempo.

O filme “O Jogo da Imitação” (*The Imitation Game*, 2014), dirigido por Morten Tyldum, conta a biografia de Alan Turing. Vale a pena assistir, caso tenha oportunidade.



Figura 2 - Cena do filme *O Jogo da Imitação* (2014)
Fonte: Adaptada por FIAP (2025)

O Teste de Turing coloca um avaliador humano observando conversas em linguagem natural entre um humano e uma máquina, sem saber qual é qual. Se o avaliador não puder distinguir de forma confiável entre as respostas humanas e as da máquina, significa que a máquina passou no teste.

O formato original, que Turing chamou de “Jogo da Imitação”, envolvia três participantes: um interrogador, um participante humano e um computador. O interrogador se comunicaria com o humano e o computador por meio de interações somente de texto, fazendo perguntas e se envolvendo em conversas. O objetivo do computador era convencer o interrogador de que era humano, enquanto o participante humano também tentaria provar sua humanidade.

Turing previu que até o ano 2000, os computadores seriam capazes de enganar avaliadores humanos 30% do tempo durante conversas de 5 minutos. Essa previsão desencadeou décadas de debate e pesquisa em Inteligência Artificial. O teste se tornou uma referência fundamental no desenvolvimento de IA, embora também tenha enfrentado críticas por focar apenas na inteligência conversacional em vez de outros aspectos da cognição humana.

O Teste de Turing influenciou várias áreas de pesquisa, incluindo processamento de linguagem natural, aprendizado de máquina e ciência cognitiva. Ele também levantou questões filosóficas importantes sobre a natureza da

inteligência, consciência e o que significa realmente pensar. Os chatbots de IA modernos e os modelos de linguagem continuam a expandir os limites do que é possível na interação entre homem e máquina, tornando os conceitos originais de Turing cada vez mais relevantes no cenário tecnológico atual.

Além do teste em si, o trabalho de Turing nessa área ajudou a estabelecer a base para a Inteligência Artificial como um campo de estudo. Seus *insights* continuam a influenciar nossos pensamentos em relação a inteligência das máquinas e o potencial dos computadores de exibir habilidades cognitivas semelhantes às humanas. O Teste de Turing continua sendo referência nas discussões sobre capacidades e limitações da IA, mesmo que a tecnologia evolua de maneiras que o próprio Turing nunca poderia ter imaginado.




Figura 3 - Exemplo do Teste de Turing
Fonte: Adaptada por FIAP (2025)

1.2.3 Conferência de Dartmouth, o surgimento do termo Inteligência Artificial

O termo Inteligência Artificial foi utilizado pela primeira vez em 1955, na proposta de um projeto de pesquisa de verão de Dartmouth em Inteligência Artificial (no seu nome original, “*A proposal for the dartmouth summer research project on artificial intelligence*”) submetido por John McCarthy (Professor Assistente de

Matemática, Dartmouth College), Marvin Minsky (Junior Fellow em Matemática e Neurologia, Harvard University), Nathaniel Rochester (Gerente de Pesquisa de Informação, IBM) e Claude Shannon (Matemático, Bell Telephone Laboratories). De acordo com a proposta, o estudo deve prosseguir com base na conjectura de que cada aspecto do aprendizado ou qualquer outra característica da inteligência pode, em princípio, ser descrito com tanta precisão que uma máquina pode ser feita para simulá-lo.

Nessa conferência histórica (*Dartmouth Conference*), McCarthy reuniu os principais pesquisadores de várias áreas para uma discussão aberta sobre Inteligência Artificial — termo que eles escolheram utilizar para evitar destacar uma das linhas seguidas para o campo das “máquinas pensantes”. Infelizmente, a conferência ficou abaixo das expectativas de McCarthy, as pessoas iam e vinham quando bem entendiam e não chegavam a um consenso sobre os métodos padrão para o campo. Apesar disso, todos se alinharam de coração com o sentimento de que a IA era alcançável.

Mesmo assim, o estudo que foi realizado um ano após a apresentação de sua proposta (em 1956), é considerado oficialmente como o nascimento da Inteligência Artificial como campo de estudo. O evento catalisou os próximos 20 anos de pesquisa em IA.

Hoje os dicionários modernos definem que a Inteligência Artificial é um subcampo da ciência da computação e como as máquinas podem imitar a inteligência humana (se assemelhando a um humano em vez de se tornar um humano). Segundo o *Dicionário Oxford*, a Inteligência Artificial é “a teoria e o desenvolvimento de sistemas computacionais capazes de realizar tarefas que normalmente requerem inteligência humana, como percepção visual, reconhecimento de fala, tomada de decisão e tradução entre idiomas”.

1.2.4 ELIZA, o primeiro chatbot

Em 1965, no laboratório do Massachusetts Institute of Technology (MIT), o cientista da computação Joseph Weizenbaum criou o primeiro programa de computador, chamado ELIZA, para estudo de comunicação de linguagem natural

entre homem e máquina. A ideia foi criar um script para simular uma conversa entre o paciente e o psicólogo (ELIZA).

ELIZA foi projetada para imitar um terapeuta que faz perguntas abertas e até mesmo responde para continuar com o acompanhamento. A máquina lê o texto e busca por uma palavra-chave. Se a palavra é encontrada, a frase é gerada de acordo com uma regra associada à palavra-chave, caso contrário, uma observação sem conteúdo ou, sob certas condições, uma frase gerada anteriormente é usada e, então, impressa na tela.

Embora o termo “chatbot” tenha sido criado em 1994 por Michael Mauldin (inventor do primeiro verbot, Julia), a fim de descrever os programas de conversação, a ELIZA é considerada o primeiro chatbot da história da ciência da computação.

```
Welcome to

EEEEEE LL      IIII ZZZZZZZZ  AAAAA
EE      LL      II      ZZ  AA  AA
EEEEEE LL      II      ZZZ  AAAAAAA
EE      LL      II      ZZ  AA  AA
EEEEEE LLLLLL IIII ZZZZZZZZ  AA  AA

Eliza is a mock Rogerian psychotherapist.
The original program was described by Joseph Weizenbaum in 1966.
This implementation by Norbert Landsteiner 2005.

ELIZA: Is something troubling you ?
YOU:   Men are all alike.
ELIZA: What is the connection, do you suppose ?
YOU:   They're always bugging us about something or other.
ELIZA: Can you think of a specific example ?
YOU:   Well, my boyfriend made me come here.
ELIZA: Is it important to you that your boyfriend made you come here ?
YOU:   He says I'm depressed much of the time.
ELIZA: I am sorry to hear that you are depressed.
YOU:   It's true. I am unhappy.
ELIZA: Can you explain what made you unhappy ?
YOU:   █
```

Figura 4 - Representação de ELIZA feita por Norbert Landsteiner (2005)
Fonte: Adaptada por FIAP (2025)

1.2.5 IBM Deep Blue

Algumas décadas depois, em 1996, a IBM desenvolveu um computador chamado IBM® Deep Blue®. O objetivo foi construir um computador capaz de vencer o melhor jogador de xadrez do mundo. O primeiro grande teste do Deep Blue foi em fevereiro de 1996 contra o campeão Garry Kasparov, em um jogo de seis partidas na Filadélfia. Foi uma disputa clássica entre homem e máquina. O Deep Blue venceu a

primeira partida, a qual ficou marcada como a primeira vitória de uma máquina contra um campeão mundial, nos tempos regulares da partida. Mas Kasparov conseguiu virar o jogo e venceu o jogo por 4 a 2.

A equipe da IBM trabalhou no Deep Blue para melhorar e realizar uma nova partida. Eles melhoraram os bancos de dados que tratam dos finais de jogo de xadrez, criaram uma função de avaliação mais poderosa para as posições do xadrez, contrataram grandes mestres de xadrez (*Grandmasters*) adicionais para aconselhar a equipe e desenvolveram métodos para disfarçar a estratégia do computador.

O Deep Blue enfrentou novamente Garry Kasparov em maio de 1997, em Nova Iorque. A revanche foi amplamente vista como um teste simbólico para saber se os supercomputadores estavam alcançando a inteligência humana. Kasparov venceu a primeira partida. Deep Blue venceu a partida seguinte. As três partidas seguintes foram declaradas como empate. Na sexta partida, o Deep Blue venceu se tornando o primeiro sistema de computador a derrotar um atual campeão mundial sob o controle de tempo padrão do torneio.

O Deep Blue utilizava 32 processadores para executar um conjunto de cálculos coordenados e de alta velocidade em paralelo. Além disso, ele era capaz de explorar até 200 milhões de posições de xadrez possíveis por segundo, alcançando uma velocidade de processamento de 11,38 bilhões de flops (*“floating-point operations per second”* ou, em português, operações de ponto flutuante por segundo). Em comparação, o primeiro supercomputador da IBM, Stretch, introduzido em 1961, tinha uma velocidade de processamento de menos de 500 flops.

Depois da vitória contra Kasparov, o projeto Deep Blue foi aposentado e doado para o Smithsonian Museum, em Washington, D.C., nos Estados Unidos. O projeto foi uma inspiração para o desenvolvimento de novos projetos de computadores massivamente paralelos, como Blue Gene e Watson. Em 1999, a IBM aproveitou sua experiência com o Deep Blue e lançou o Deep Computing Institute, com o objetivo de aproveitar a computação avançada para solucionar problemas tecnológicos e empresariais complexos.



Figura 5 - Jogo de xadrez entre Garry Kasparov e IBM® Deep Blue®
Fonte: Wired (2025)

1.2.6 IBM Watson

A IBM esteve pesquisando por um novo desafio homem *versus* máquina desde a vitória do computador Deep Blue. Em 2006, Dr. David Ferrucci, um cientista da computação com conhecimento em Inteligência Artificial, sugeriu a ideia de desenvolver um computador capaz de vencer um humano no programa *Jeopardy!*, amplamente considerado o programa de perguntas e respostas mais desafiador da televisão.

Ferrucci pensou que o jogo de perguntas e respostas poderia expandir o limite do processamento de linguagem natural, no qual os computadores são programados para analisar e responder a palavras e frases comuns. O objetivo foi construir um computador que pudesse ir além dos limites da tecnologia para entender e interagir em linguagem natural, mas não necessariamente da mesma forma que os humanos fazem.

O cientista da computação reuniu uma equipe com mais de 24 cientistas, engenheiros e programadores para trabalhar no novo desafio. Entre os programadores designados para o projeto estava Ed Toutant, que ganhou US\$ 10.000 no *Jeopardy!* em 1989. A equipe levou cinco anos para aperfeiçoar o sistema de perguntas e respostas.

Essa disputa foi televisionada e assistida por milhões em fevereiro de 2011, o computador IBM Watson DeepQA fez história ao derrotar os dois maiores campeões de todos os tempos do programa de perguntas e respostas da TV, Brad Rutter e Ken Jennings. Os participantes do programa recebem dicas em forma de respostas e precisam responder na forma de perguntas (era muito comum responder ao jogo com “*What is...*”). Watson foi posto à prova em duas partidas de *Jeopardy!* disputadas ao longo de três dias. Watson não era perfeito e cometia erros. Na primeira partida, Watson errou a pista “*Final Jeopardy!*” na categoria Cidades dos EUA. A dica era “Seu maior aeroporto recebeu o nome de um herói da Segunda Guerra Mundial; o segundo maior, de uma batalha da Segunda Guerra Mundial”. A resposta correta era “O que é Chicago?”, mas Watson respondeu “O que é Toronto?????” com cinco pontos de interrogação indicando uma falta substancial de confiança.

Watson entrou na segunda partida empatado com Brad Rutter, mas rapidamente assumiu a liderança. O resultado final terminou com uma vitória retumbante. Watson ganhou US\$ 77.147, que foram doados a várias instituições de caridade, superando os US\$ 24.000 de Ken Jennings e os US\$ 21.600 de Brad Rutter. Após o concurso, Jennings comentou ironicamente: “Participante de um concurso de perguntas e respostas pode ser o primeiro emprego tornado redundante por Watson, mas tenho certeza de que não será o último”.

Na época, os computadores não eram bons em encontrar respostas, e os mecanismos de pesquisa não respondiam a uma pergunta. Mesmo assim, responder a uma das categorias do programa não era uma tarefa simples. A capacidade do Watson de descobrir *insights* em dados não estruturados representou um grande salto em um subconjunto de Inteligência Artificial chamado processamento de linguagem natural e um passo importante em direção a um mundo no qual máquinas inteligentes são capazes de entender e responder a perguntas cotidianas para melhorar a tomada de decisões.

O Watson original era um computador do tamanho de uma sala, consistindo em 10 racks contendo 90 servidores, com um total de 2.880 núcleos de processadores. Ele executava o software IBM DeepQA, que era usado para gerar hipóteses, reunir evidências e analisar dados. Ao longo de um período de anos, o Watson ingeriu grandes volumes de informações da Wikipédia e enciclopédias, dicionários, textos religiosos, romances, peças e livros do Projeto Gutenberg, entre outras fontes.

Desde a vitória do Watson no *Jeopardy!*, a tecnologia usada passou a ajudar organizações a prever, otimizar e automatizar processos de negócios em vários setores. Aproximadamente 70% das instituições financeiras globais e 13 dos 14 principais integradores de sistemas usam o Watson, além de empresas em diversos outros setores e indústrias ao redor do mundo.

Atualmente, o Watson oferece mais de 10 serviços diferentes, disponíveis na plataforma de nuvem pública da IBM, a IBM Cloud. Alguns desses serviços são:

- Construção de interfaces conversacionais (base dos chatbots e assistentes virtuais).
- Transcrição de voz para texto.
- Sintetizador de voz a partir de texto.
- Mecanismo de pesquisa cognitiva e análise de conteúdo.
- Construção de soluções com aprendizado de máquina e Inteligência Artificial Generativa.



Figura 6 - Participação do computador Watson no programa "Jeopardy!"

Fonte: The New York Times (2025)

1.2.7 Siri

A Siri é uma assistente pessoal inteligente e um navegador do conhecimento que usa linguagem natural para responder perguntas, fazer recomendações e executar ações delegando solicitações a um conjunto de APIs (“Application Programming Interface” ou, em português, interface de programação de aplicação). O software se adapta ao uso individual da linguagem do usuário e às preferências individuais de pesquisa com o uso contínuo, e retorna resultados que são individualizados. A Siri foi desenvolvida pela empresa SRI ao longo de um período de sete anos e depois vendida para a Apple em abril de 2010 por centenas de milhões de dólares. Ela foi um spin-off do Centro de Inteligência Artificial do SRI.

Em outubro de 2011, a Siri foi introduzida no iPhone 4S. O lançamento representa um marco significativo em aplicações práticas de Inteligência Artificial na vida cotidiana. Como um assistente virtual inteligente, demonstra várias capacidades-chave de IA por meio de suas habilidades de processamento de linguagem natural, podendo entender consultas baseadas em contexto e processar a linguagem natural em vez de exigir comandos específicos, enquanto também interpreta significado semântico, como, por exemplo, entender que “aqui” se refere à localização atual do usuário. O que a torna particularmente notável é sua inteligência contextual.

O sistema integra várias fontes de dados, incluindo informações meteorológicas, contatos e dados de localização, ao mesmo tempo em que faz conexões lógicas entre solicitações do usuário e informações disponíveis. Isso permite que ela adapte respostas com base em dados pessoais e contexto, criando uma experiência de usuário mais intuitiva.

Em termos de aplicações práticas, a Siri mostra o potencial real da IA por meio da automação de tarefas (como fazer chamadas e enviar mensagens), recuperação de informações (incluindo pesquisas na web e direções) e funções de assistência pessoal, como definir lembretes e realizar cálculos. Esta implementação demonstra como a IA pode criar interações intuitivas entre humanos e computadores, tornando a tecnologia mais acessível e útil na vida cotidiana.

Em junho de 2024, a Apple introduziu na Siri o Apple Intelligence, o sistema de inteligência pessoal para iPhone, iPad e Mac que combina modelos generativos com

o contexto pessoal para fornecer inteligência. O Apple Intelligence é a abordagem da Apple para utilizar Inteligência Artificial Generativa em conjunto com toda a tecnologia que a Siri já possuía.



Figura 7 - Siri
Fonte: The Verge (2025)

1.2.8 Amazon Alexa

A Amazon Alexa é um serviço de voz baseado em nuvem disponível em mais de 100 milhões de dispositivos. Com a Alexa se torna possível experiências naturais de voz que oferecem aos usuários uma maneira mais intuitiva de interagir com a tecnologia que eles usam todos os dias. A Alexa pode tocar sua música favorita, ler as últimas notícias, diminuir as luzes da sua sala de estar e muito mais. A Amazon oferece um conjunto de ferramentas, APIs, soluções de referência e documentação para facilitar seu uso e criação de *skills*.

Ela foi projetada para tomar a melhor ação com base em sua interpretação do objetivo do usuário. Ao contrário dos mecanismos de busca, não responde simplesmente com um conjunto de 10 links azuis que o usuário deve escolher. Em vez disso, age em nome do usuário, fazendo perguntas esclarecedoras conforme necessário. Existem várias tecnologias-chave que a fazem funcionar.

O funcionamento começa com a detecção da “palavra de ativação” que aciona o sistema para começar a ouvir as palavras faladas subsequentes do usuário. A detecção da palavra de ativação emprega tecnologia de *Deep Learning* (ou, em

português, Aprendizado Profundo) em execução no dispositivo para reconhecer a palavra de ativação que o usuário configurou. O reconhecimento automático de fala de campo distante na plataforma da Amazon Web Services (AWS) converte o áudio em texto após a palavra de ativação, além de determinar quando o usuário parou de falar com a Alexa.

Depois que o áudio falado é convertido em texto, a Alexa usa o processamento de linguagem natural para converter as palavras em uma interpretação estruturada de intenção, que pode ser usada para responder ao usuário a partir das mais de 30.000 Alexa Skills criadas por desenvolvedores próprios e terceiros. Alexa Skills são aplicativos ativados por voz que adicionam recursos ao seu dispositivo Echo. Isto é, são como voicebots/chatbots que interagem usando a voz, porém, desenvolvidos pela própria Amazon, ou por pessoas, ou por empresas terceiras, trazendo mais funcionalidades (similar aos aplicativos baixados nas lojas de aplicativo do seu smartphone, como WhatsApp, Instagram, TikTok, entre outros).

Essa interpretação estruturada é usada em combinação com diferentes formas de contexto, como com qual tipo de dispositivo o usuário está interagindo, quais são as Alexa Skills mais prováveis que podem fornecer uma resposta ou quem está falando. Esse contexto ajuda a determinar a melhor próxima ação que a Alexa deve tomar. Os resultados possíveis são responder com a melhor ação de uma habilidade ou pedir mais informações ao usuário.

A Amazon lançou a Alexa em conjunto com o dispositivo Amazon Echo em novembro de 2014. O Amazon Echo é um dispositivo alto-falante, viva-voz, integrado à Alexa. Os dispositivos Echo se conectam ao servidor da Amazon pela Internet. O lançamento do Echo e da Alexa aconteceu de forma cautelosa, oferecendo inicialmente apenas 80.000 dispositivos e vendendo-os apenas para clientes que fizeram inscrição para comprar um Echo com antecedência (aproximadamente 109.000 o fizeram). Mas a cautela da empresa provou ser desnecessária, pois o Echo foi um sucesso instantâneo. Até o final de 2016, a Amazon havia vendido mais de oito milhões de dispositivos. Até 2019, a empresa havia vendido mais de 100 milhões de dispositivos.



Figura 8 - Amazon Echo
Fonte: Amazon (2025)

1.2.9 AlphaGo

AlphaGo é um programa de computador que joga o jogo de tabuleiro Go. O programa foi desenvolvido pela DeepMind, empresa adquirida pelo Google em janeiro de 2014. Foi a primeira Inteligência Artificial a derrotar um jogador campeão mundial de Go, o grande mestre (*Grandmaster*) sul-coreano Lee Sedol em março de 2016. Isso marcou uma conquista significativa na pesquisa de IA, demonstrando um novo potencial no campo do *Machine Learning* (ou, em português, Aprendizado de Máquina). Na verdade, um aprendizado por reforço e redes neurais. O antigo jogo de tabuleiro Go, frequentemente citado por sua complexidade e profundidade estratégica, foi considerado um marco desafiador para qualquer IA dominar, devido à sua vasta gama de movimentos possíveis e estratégias intrincadas.

A partida de Go se originou na China há mais de 2.500 anos. Confúcio, pensador e filósofo chinês, escreveu sobre o jogo. Ele é considerado uma das quatro artes essenciais exigidas de qualquer verdadeiro estudioso chinês. Jogado por mais de 40 milhões de pessoas no mundo todo, suas regras são simples: os jogadores se revezam para colocar pedras pretas ou brancas em um tabuleiro, tentando capturar as pedras do oponente, ou tentando cercar o espaço vazio para fazer pontos de território. A partida é jogada principalmente por intuição e tato, e por causa de sua

beleza, sutileza e profundidade intelectual, capturou a imaginação humana por séculos.

Entretanto, por mais simples que sejam as regras, Go é um jogo de profunda complexidade. Existem inúmeras posições possíveis — número maior do que o número de átomos no universo e mais do que um googol vezes (10^{100}) maior que o xadrez.

Essa complexidade é o que torna o Go difícil para os computadores jogarem e, portanto, um desafio irresistível para pesquisadores de Inteligência Artificial, que usam partidas como um campo de testes para inventar algoritmos inteligentes e flexíveis que podem resolver problemas, às vezes de maneiras semelhantes aos humanos.

Os métodos tradicionais de IA — que constroem uma árvore de busca sobre todas as posições possíveis — não têm chance no Go. Então, quando os engenheiros da DeepMind propuseram a decifrar o Go, adotaram uma abordagem diferente. Construíram o AlphaGo, que combina uma busca avançada em árvore com Deep Neural Networks (ou, em português, Redes Neurais Profundas). Essas redes neurais pegam uma descrição do tabuleiro como uma entrada e a processam por meio de 12 camadas de rede diferentes contendo milhões de conexões semelhantes a neurônios. Uma rede neural, a “rede de políticas”, seleciona o próximo movimento a ser jogado. A outra rede neural, a “rede de valores”, prevê o vencedor da partida.

Os engenheiros treinaram as redes neurais em 30 milhões de movimentos de partidas jogadas por especialistas humanos, até que ela pudesse prever o movimento humano, pelo menos 57% das vezes (o recorde anterior antes do AlphaGo era de 44%). Mas o objetivo era vencer os melhores jogadores humanos, não apenas imitá-los. Para fazer isso, o AlphaGo aprendeu a descobrir novas estratégias para si mesmo, jogando milhares de partidas entre suas redes neurais e ajustando as conexões, usando um processo de tentativa e erro conhecido como aprendizado por reforço.

Depois de todo esse treinamento, era hora de colocar o AlphaGo à prova. Primeiro, realizaram um torneio entre o AlphaGo e os outros principais programas na vanguarda do jogo para computador. Em 500 jogos, o AlphaGo venceu todos, exceto um. Então, o próximo passo foi convidar o atual tricampeão europeu de Go, Fan Hui, um jogador profissional de elite que dedicou sua vida ao Go desde os 12 anos, para

o escritório da DeepMind em Londres para uma partida de desafio. Em uma partida a portas fechadas em outubro de 2015, o AlphaGo venceu por 5 jogos a 0. Foi a primeira vez que um programa de computador venceu um jogador profissional de Go.

AlphaGo então competiu contra o lendário jogador de Go, Lee Sedol, vencedor de 18 títulos mundiais e amplamente considerado o maior jogador daquela década. A vitória de AlphaGo por 4 a 1 em Seul, Coreia do Sul, em março de 2016, foi assistida por mais de 200 milhões de pessoas no mundo todo. Essa conquista histórica estava uma década à frente de seu tempo.

A vitória inspirou uma nova era de sistemas de IA. Foi uma prova conclusiva de que as redes neurais poderiam ser aplicadas a domínios complexos, enquanto o uso do aprendizado por reforço mostrou como as máquinas podem aprender a resolver problemas incrivelmente difíceis por si mesmas, simplesmente por tentativa e erro. Sua capacidade de olhar para frente e planejar também ainda é usada nos sistemas de IA de hoje.

Você pode assistir ao documentário *AlphaGo – The Movie*, dirigido por Greg Kohs, no canal da DeepMind no YouTube.



Figura 9 - Partida de Go entre AlphaGo e Lee Sedol
Fonte: The Guardian (2025)

1.2.10 OpenAI ChatGPT

A OpenAI desempenhou um papel fundamental na revolução da IA Generativa, impulsionando muito do progresso e adoção de modelos de linguagem grandes (LLMs), sistemas multimodais e ética da IA. Fundada em dezembro de 2015 por figuras proeminentes como Elon Musk, Sam Altman, Greg Brockman, Ilya Sutskever e outros, a OpenAI possui a missão de garantir que a Inteligência Geral Artificial (AGI) beneficie toda a humanidade.

Inicialmente, foi construída como uma organização sem fins lucrativos, mas depois fez a transição para um modelo de lucro limitado para atrair investimentos, mantendo-se comprometida com seus objetivos orientados à missão. A filosofia central da organização se concentra no desenvolvimento de AGI de forma segura e transparente, com ênfase em evitar o uso indevido e garantir que seus benefícios sejam distribuídos de forma equitativa.

Uma das contribuições mais significativas da OpenAI para a revolução da Inteligência Artificial Generativa veio por meio do desenvolvimento da série Generative Pretrained Transformer (GPT). A introdução do GPT-1, em 2018, marcou um passo significativo à frente, pois foi a primeira aplicação em larga escala com a arquitetura Transformer para aprendizado não supervisionado. Isso permitiu que o modelo fosse pré-treinado em grandes quantidades de dados de texto e ajustado para uma variedade de tarefas, como tradução de idiomas e resposta a perguntas. O GPT-1 demonstrou que um único modelo poderia executar várias tarefas com pouco ou nenhum treinamento específico para a tarefa.

O lançamento do GPT-2 em 2019 com 1,5 bilhão de parâmetros foi um divisor de águas. Ele demonstrou a capacidade do modelo de gerar texto coerente e contextualmente relevante, com base em um prompt. Esse avanço levou tanto à excitação quanto à preocupação, pois os recursos do GPT-2 levantaram questões sobre o potencial de uso indevido, como gerar notícias falsas ou informações enganosas. A decisão da OpenAI de inicialmente reter o modelo completo por precaução foi um reflexo do poder e dos riscos dos modelos generativos. Apesar dessas preocupações, o lançamento do GPT-2 acelerou significativamente o campo da IA Generativa, estimulando a pesquisa e o desenvolvimento na academia e na indústria.

Então, em 2020 foi lançado o GPT-3, levando a IA Generativa a novos patamares. Com 175 bilhões de parâmetros, o GPT-3 poderia gerar texto altamente sofisticado e cheio de nuances em uma gama sem precedentes de tarefas, desde a escrita criativa até a resolução de problemas complexos. Este modelo demonstrou que a ampliação de modelos não supervisionados levou a melhorias drásticas no desempenho. A OpenAI tornou o GPT-3 acessível por meio de uma API, permitindo que as empresas integrassem o modelo em seus próprios produtos, de chatbots a ferramentas de criação de conteúdo. A disponibilidade comercial do GPT-3 marcou o início do uso generalizado de Large Language Models (LLMs ou, em português, Grandes Modelos de Linguagem) em setores como marketing, atendimento ao cliente, saúde e entretenimento.

Em novembro de 2022, a OpenAI lançou o ChatGPT, uma IA conversacional alimentada pelo GPT-3.5 e, posteriormente, pelo GPT-4. A capacidade do ChatGPT de conversar de forma natural e humana cativou a imaginação do público. Ele podia lidar com tudo, desde responder perguntas até escrever ensaios, compor poesia e até mesmo resolver problemas complexos como codificação e debug. Este lançamento se tornou um fenômeno cultural, pois milhões de usuários em todo o mundo começaram a interagir com a IA de novas maneiras. A introdução do ChatGPT Plus pela OpenAI forneceu aos usuários acesso ao GPT-4, tornando-se um marco significativo na democratização do acesso a poderosas ferramentas de IA.

O GPT-4, lançado em 2023, representou outro salto de capacidade. Com trilhões de parâmetros, o GPT-4 era um modelo multimodal, isso significa que podia processar textos e imagens. Essa expansão permitiu uma gama mais ampla de aplicações, como gerar imagens detalhadas a partir de prompts textuais e entender tarefas complexas e multimodais. A capacidade do GPT-4 de lidar com prompts mais intrincados e fornecer respostas mais precisas e confiáveis o tornou uma ferramenta essencial para domínios especializados como Direito e Medicina. À medida que o GPT-4 se tornou amplamente disponível por meio de plataformas como o ChatGPT, ele solidificou ainda mais o lugar da IA Generativa no *mainstream*.

Além de seus modelos de linguagem, a OpenAI fez avanços no domínio visual com o lançamento do DALL-E. A primeira versão, lançada em 2021, foi capaz de gerar imagens a partir de descrições textuais, usando os princípios dos modelos baseados em Transformer com Generative Adversarial Networks (GANs ou, em português,

Redes Adversárias Generativas). Isso marcou o início de uma nova era para a IA multimodal, onde os modelos podiam entender e criar textos e imagens. O lançamento do DALL-E 2 em 2022 trouxe a geração de imagens de maior qualidade junto com recursos como *inpainting*, que permitia aos usuários editarem áreas específicas de uma imagem. Isso gerou novas possibilidades em campos criativos como arte, design e publicidade, fornecendo um novo caminho para profissionais criativos colaborarem com a IA na geração de conteúdo visual.

Juntamente com a revolução visual, a OpenAI também desenvolveu o Codex, um modelo especializado baseado no GPT-3, ajustado para auxiliar na programação. O Codex potencializa ferramentas como o GitHub Copilot, que ajuda os desenvolvedores a escreverem códigos sugerindo funções inteiras ou trechos com base em prompts de linguagem natural. Isso “virou o jogo” para a indústria de desenvolvimento de software, melhorando a produtividade para programadores novatos e experientes e diminuindo a barreira de entrada para aqueles interessados em codificação. O lançamento do Codex tornou possível que a IA se tornasse uma ferramenta indispensável no desenvolvimento de software, simplificando fluxos de trabalho e reduzindo o tempo de desenvolvimento.

À medida que os modelos da OpenAI avançam, a empresa toma medidas para comercializar sua tecnologia. Através de APIs, a OpenAI disponibiliza seus modelos poderosos para integração em aplicativos de terceiros. Isso permite que empresas de diversos setores adotem a IA Generativa para vários propósitos.




Figura 10 - ChatGPT no navegador
Fonte: The New York Times (2025)

1.3 Por que IA?

Atualmente, com a rápida evolução tecnológica, os profissionais de diversas áreas podem se beneficiar ao aprender sobre Inteligência Artificial. Por um lado, a IA deve substituir funções em empresas que podem ser automatizadas, como foi o caso da IBM que anunciou em 2023 que pausou as contratações de 7.800 vagas para automatizar com Inteligência Artificial. Por outro lado, compreender a IA permitirá que os profissionais aproveitem seu potencial para aprimorar seu trabalho, melhorar a eficiência e tomar decisões baseadas em dados. Ao se familiarizar com os conceitos de IA, os profissionais obtêm *insights* sobre como os algoritmos de IA funcionam, permitindo-lhes identificar oportunidades de automação, otimização e inovação em seus respectivos domínios. Seja em finanças, saúde, marketing ou qualquer outro campo, a IA pode oferecer ferramentas e técnicas valiosas para enfrentar desafios complexos e gerar resultados significativos.

Os profissionais precisam aprender sobre IA para se manterem à frente da curva tecnológica e permanecerem relevantes em suas áreas. A IA está transformando rapidamente as indústrias e interrompendo os modelos de negócios tradicionais. Ao obter conhecimento sobre a Inteligência Artificial, os profissionais podem se adaptar proativamente a essas mudanças e identificar oportunidades de inovação. Esses profissionais podem explorar como a IA pode melhorar os processos, otimizar a alocação de recursos e aprimorar as experiências do cliente. Além disso, entender a IA permite que os profissionais aproveitem o poder dos dados. As técnicas de IA permitem a extração de informações valiosas de grandes conjuntos de dados, permitindo a tomada de decisões baseadas em evidências e estratégias informadas. Ao alavancar ferramentas e algoritmos de IA, os profissionais podem descobrir padrões, tendências e correlações que podem não ser aparentes por meio de métodos de análise tradicionais. Essa abordagem orientada por dados, torna os profissionais mais habilitados para realizarem previsões mais precisas, identificar tendências emergentes e fazer escolhas estratégicas informadas.

Além disso, à medida que a IA se torna cada vez mais prevalente em todos os setores, os profissionais que possuem conhecimentos e habilidades em IA ganham uma vantagem competitiva no mercado de trabalho. As funções relacionadas à IA, como cientistas de dados, engenheiros de *Machine Learning* e consultores de IA, estão em alta demanda. Ao investir na educação em IA, os profissionais abrem portas para oportunidades de carreira e aumentam sua empregabilidade. A alfabetização em Inteligência Artificial permite que os profissionais falem a linguagem da IA, colaborem efetivamente com cientistas de dados e especialistas e contribuam para projetos multifuncionais envolvendo a integração da IA. Além disso, entender as implicações éticas da IA é crucial para que os profissionais naveguem pelo uso responsável da IA garantindo privacidade, justiça e responsabilidade em seu trabalho. No geral, aprender sobre IA qualifica os profissionais a abraçar o potencial das tecnologias baseadas em IA, adaptar aos avanços tecnológicos e prosperar na era digital.

O primeiro passo para aprender sobre IA é entender os três tipos de dados. São eles: dados estruturados, dados não estruturados e dados semiestruturados. Independente das suas ações na Internet, você está gerando um desses três dados. Vivemos em uma era digital em que praticamente tudo que fazemos gera dados, seja uma curtida em uma rede social ou assistir a um filme na Netflix. Esses vestígios que

deixamos na Internet por meio de nossas ações são chamados de *Digital Footprint* (ou vestígio tecnológico). Esses dados são ativos para grandes empresas, pois é a partir dos dados gerados, por exemplo, que é possível criar recomendações para os usuários. Uma série na Netflix pode ser recomendada para você, mas talvez não seja a mesma recomendada para seu amigo ou familiar. Isso ocorre porque as séries, os filmes e os documentários que cada um assiste viram dados, que são transformados, pela empresa, em recomendação. Então, cada usuário possui uma lista de recomendações para cada tipo de perfil e essas recomendações são geradas, em sua grande maioria, por modelos de *Machine Learning* (uma tecnologia dentro da Inteligência Artificial).

1.3.1 Dados estruturados

Dados estruturados referem-se ao dado que é organizado e armazenado em um formato predefinido com um *schema* ou modelo de dado bem definido. Este tipo de dados segue uma estrutura consistente e é tipicamente armazenado em bancos de dados relacionais ou planilhas. Uma simples planilha em Excel representa um exemplo de dados estruturados. Isso porque, no Excel, é possível definir o tipo de dado para cada coluna e linha. Com os dados preenchidos, você facilmente consegue gerar gráficos e relatórios para processar e analisar esses dados.

Características de dados estruturados:

- **Formato:** os dados são organizados em um formato fixo com uma estrutura clara e predefinida. Geralmente é representado no formato de tabelas com linhas e colunas, onde cada coluna corresponde a um atributo ou campo específico, e cada linha representa um registro de dados.
- **Schema:** os dados estruturados seguem um *schema* predefinido ou modelo de dados que define a estrutura, os tipos de dados e os relacionamentos entre diferentes elementos. O *schema* fornece uma forma de como os dados são organizados e permite consistência e integridade dos dados.
- **Tipos de dados:** cada atributo ou campo de um dado estruturado tem um tipo de dado definido, como um número, data, texto ou booleano. Isso permite armazenamento, indexação e consulta eficientes dos dados.

- **Relacionamentos:** dados estruturados podem capturar relacionamentos entre diferentes entidades de dados por meio de chaves primárias, chaves estrangeiras ou outras associações definidas. Esses relacionamentos permitem unir tabelas e realizar consultas complexas em vários conjuntos de dados relacionados.

Exemplos de dados estruturados:

- **Bancos de dados relacionais:** dados armazenados em tabelas com colunas e linhas fixas, gerenciados por sistemas de gerenciamento de banco de dados (DBMS) como MySQL, Oracle, ou Microsoft SQL Server.
- **Planilhas:** dados organizados em linhas e colunas usando software como Microsoft Excel ou Google Sheets.
- **Arquivos CSV (Comma-Separated Values):** arquivos de texto com dados tabular onde os valores estão separados por vírgulas.
- **Sistemas ERP (Enterprise Resource Planning):** bancos de dados que armazenam dados estruturados relacionados aos processos do negócio como vendas, inventário e finanças.




Figura 11 - Dois gráficos gerados a partir da tabela simples
Fonte: Elaborado pelo autor (2025)

Os dados estruturados são adequados para consultas, relatórios e análises usando Structured Query Language (ou SQL) ou outras ferramentas para poder processar dado tabular de forma eficiente.

1.3.2 Dados não estruturados

Dados não estruturados referem-se aos dados que não possuem um formato pré-definido ou estrutura organizada. Este tipo de dado não se encaixa perfeitamente em bancos de dados ou tabelas tradicionais, carecendo, assim, de um *schema* ou modelo consistente. Os dados não estruturados geralmente estão em sua forma bruta e não estão em conformidade com uma organização ou padrão específico.

Os dados não estruturados podem vir de várias formas, incluindo documentos de texto, e-mails, postagens de redes sociais, arquivos de áudio, imagens, vídeos, dados de sensores e muito mais. Ao contrário dos dados estruturados, que são organizados em linhas e colunas com uma estrutura bem definida, os dados não estruturados não possuem um layout ou organização fixa.

A coleta, o armazenamento e as análises realizadas com base nesses dados não são tarefas simples, mas, quando feitas corretamente, as informações que podem ser geradas a partir desse tipo de dado são valiosas.

Características de dados não estruturados:

- **Falta de organização:** dados não estruturados não possuem uma estrutura ou formato adequado. Podem estar em formato de texto, áudio, vídeo, imagens, postagens em redes sociais, e-mails, documentos, páginas na Internet ou qualquer outro dado de formato livre.
- **Formatos variados:** dados não estruturados podem existir em diversos formatos e podem não seguir um padrão consistente. Por exemplo, um conjunto de documentos podem estar armazenados em formato PDF, Word, ou texto simples. Cada um com seu próprio formato ou a falta dele.
- **Sem *schema* fixo:** dados não estruturados podem não aderir a um *schema* ou modelo de dados pré-definido. Os dados não estruturados não possuem

uma organização de campos clara e consistente nem atributos como dados estruturados.

- **Contexto e subjetividade:** dados não estruturados geralmente possuem informações subjetivas, opiniões e nuances contextuais que os tornam mais difíceis de processar e analisar automaticamente.

Exemplos de dados não estruturados:

- **Dado textual:** dados de textos não estruturados podem incluir e-mails, páginas na Internet, artigos, logs e documentos. Este tipo de dado geralmente contém sentenças, parágrafos e texto em formato livre sem uma estrutura predefinida. Por exemplo: um contrato jurídico com diferentes cláusulas, uma postagem no LinkedIn, um artigo em um blog.
- **Dados multimídia:** dados multimídia não estruturados incluem imagens, arquivos de áudio e vídeos. Esses arquivos carecem de uma estrutura específica e requerem técnicas especializadas, como visão computacional ou processamento de áudio, para extrair informações significativas. Por exemplo: arquivo de vídeo de uma câmera dentro de um frigorífico, um áudio do WhatsApp, uma foto publicada no Instagram.
- **Dados de sensor:** dados de sensor não estruturados se referem a leituras brutas ou logs gerados por vários sensores ou dispositivos de Internet das Coisas (em inglês, *Internet of Things* ou IoT). Esses dados podem consistir em leituras não formatadas, data/hora e outras informações contextuais. Por exemplo: dados enviados por um sensor em uma plantação de cana-de-açúcar, dados enviados por um sensor de vibração em uma fábrica.
- **Dados de redes sociais:** dados das plataformas e redes sociais, como postagens, comentários e conteúdos gerados, são tipicamente não estruturados. Os dados contêm textos não organizados, hashtags, menções de usuários e arquivos de mídia (foto, vídeo, gif). Por exemplo: um post do Elon Musk com uma hashtag de um cachorro ou um comentário em uma publicação no Facebook.

Como extrair valor de dados não estruturados? Imagine ter uma página com uma análise realizada com base nos comentários sobre uma casa no Airbnb. Cada

usuário deixou um comentário, positivo ou negativo, a respeito de uma ou mais características da locação (organização, limpeza, localização, recepção, entre outros). Uma análise automatizada e bem-feita em cima desses comentários pode gerar grandes valores para os donos de casas e apartamentos que alugam na plataforma, de forma que as ações tomadas serão baseadas em dados, em estatísticas, e não em intuição.

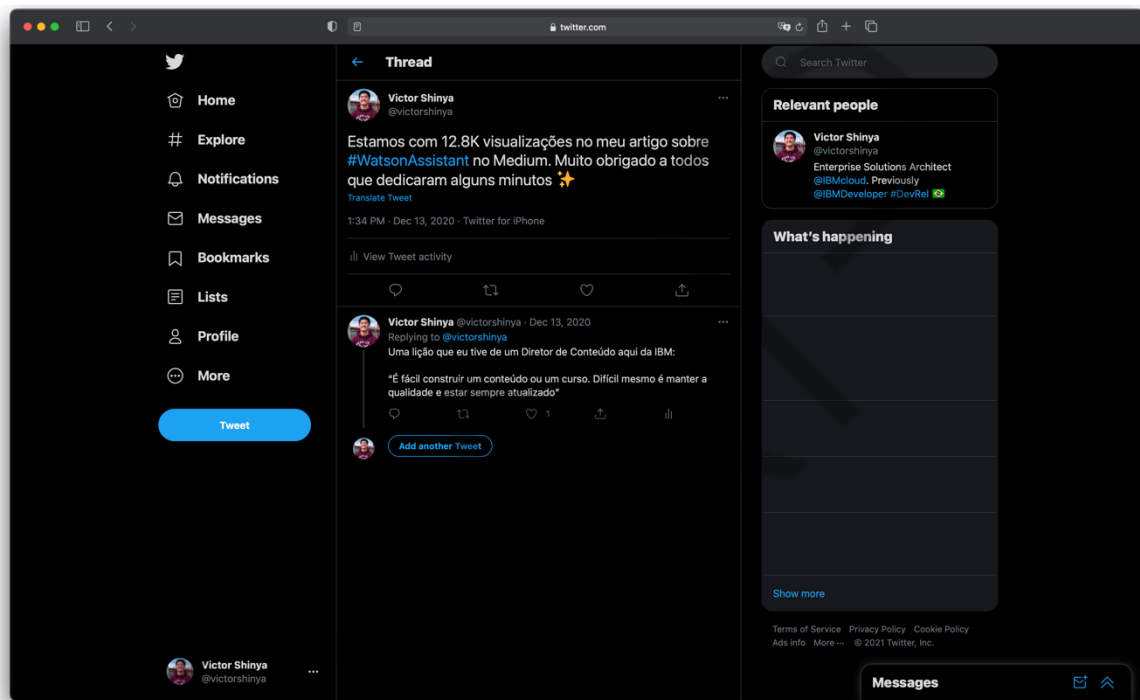


Figura 12 - Uma mensagem publicada no X (antigo Twitter)
Fonte: Elaborada pelo autor (2025)

Analisar dados não estruturados apresentam desafios únicos por conta da falta de estrutura e organização. Entretanto, com os avanços em tecnologias como Processamento de Linguagem Natural (em inglês, *Natural Language Processing* ou NLP), visão computacional e algoritmos de *machine learning*, a extração de *insights* e significado dos dados não estruturados se tornam possíveis. Pré-processamento e transformação podem ser necessárias para converter dados não estruturados em um formato estruturado ou semiestruturado para análise e integração com outros sistemas.

1.3.3 Dados semiestruturados

Dado semiestruturado é um tipo de dado que não está em conformidade com a estrutura estrita dos bancos de dados relacionais tradicionais, mas possui algum nível de organização e flexibilidade. Além de conter elementos estruturados e não estruturados, permitindo certo grau de variabilidade em seu formato e organização.

Ao contrário dos dados estruturados, que seguem um *schema* predefinido e têm um formato consistente com campos e tipos de dados fixos, os dados semiestruturados não seguem uma estrutura rígida. No entanto, geralmente contém tags, labels, ou marcadores que fornecem um nível de organização ou contexto.

Características de dados semiestruturados:

- **Flexibilidade:** dados semiestruturados exibem flexibilidade em seu formato e estrutura. Eles permitem variações na organização e representação dos elementos de dados. A ausência de *schemas* rígidos ou estruturas predefinidas permite a adição, remoção ou modificação de campos de dados conforme necessário.
- **Estrutura parcial:** dados semiestruturados contêm algum nível de estrutura ou organização. Geralmente inclui metadados, *labels* ou *tags* que fornecem contexto ou descrevem os elementos de dados. Embora não sejam tão rígidos quanto a estrutura em dados estruturados, esses elementos contribuem para uma estrutura parcial que facilita a interpretação e o processamento.
- **Representação hierárquica ou aninhada (em inglês, *Nested*):** os dados semiestruturados podem ter uma estrutura hierárquica ou aninhada. Eles permitem o agrupamento de elementos de dados relacionados, criando relacionamentos pai-filho ou representando relacionamentos complexos entre entidades. Essa representação hierárquica permite capturar semânticas e relacionamentos mais ricos nos dados.
- **Schema variável:** dados semiestruturados não possuem um *schema* fixo como os dados estruturados. Eles permitem *schemas* dinâmicos em que diferentes instâncias dos dados podem ter vários conjuntos de campos ou

atributos. Essa flexibilidade no *schema* acomoda os requisitos de dados em evolução e permite a fácil incorporação de novos elementos de dados.

- **Dados textuais e não textuais:** dados semiestruturados podem consistir em dados textuais e não textuais. Pode incluir texto de formato livre, elementos multimídia ou uma combinação de ambos. Essa característica permite a integração de diversos tipos de informações dentro de uma única entidade de dados semiestruturados.
- **Representações comuns:** dados semiestruturados são comumente representados em formatos como **XML** (*eXtensible Markup Language*), **JSON** (*JavaScript Object Notation*) ou **HTML** (*Hypertext Markup Language*). Esses formatos fornecem a flexibilidade e organização necessárias para representar dados semiestruturados de maneira eficaz, além de permitirem a inclusão de metadados, estruturas hierárquicas ou pares de chave-valor, fornecendo algum nível de estrutura e organização.

Exemplos de dados semiestruturados:

- **Documentos XML:** XML permite a representação do dado em um formato estruturado usando tags para definir elementos e atributos para fornecer informação adicional. Ele fornece uma forma flexível e extensiva para armazenar e trocar dados, comumente usados em serviços da Web e troca de documentos.
- **Arquivos JSON:** JSON é um formato de troca de dados leve que usa uma estrutura de par chave-valor. É amplamente utilizado para representar dados em APIs da Web, arquivos de configuração e bancos de dados NoSQL. O JSON fornece flexibilidade na definição de elementos de dados e permite estruturas aninhadas.
- **Arquivos de log:** arquivos de logs gerados por sistemas, aplicativos ou dispositivos geralmente têm um formato semiestruturado. Eles contêm entradas com registro de data e hora, descrições de eventos e campos de dados variáveis. Os arquivos de log são comumente usados para solução de problemas, análise de desempenho e propósitos de auditoria.

Analisar dados semiestruturados requer técnicas para gerenciar a variabilidade e flexibilidade em seu formato. Tecnologias como analisadores de XML, analisadores de JSON ou algoritmos de análise personalizados podem ser usados para extrair informações relevantes de dados semiestruturados e convertê-los em uma apresentação mais estruturada para análise e integração com outros sistemas.

1.3.4 Expectativa do crescimento dos dados no mundo

Um estudo da Seagate UK mostra que, até o final de 2025, haverá 175 zettabytes de dados gerados por mais de 6 bilhões de pessoas. Grande parte das interações com dados ocorrerá graças aos bilhões de dispositivos IoT conectados em todo o mundo, responsáveis por gerar mais de 90 ZB de dados.

Para se ter uma ideia, 1 zettabyte (1 ZB) representa 1.000^7 , isto é: 1.000.000.000.000.000.000.000 bytes. Então, se considerarmos um pendrive de 1 TB, precisaríamos de 175 bilhões de pendrives de 1 TB para armazenar os 175 ZB do estudo da Seagate UK.

Segundo o IDC, 80% dos dados no mundo serão não estruturados até o final de 2025. Ao aplicar essa porcentagem em cima dos 175 ZB de dados gerados até o mesmo ano, estima-se que 140 ZB de dados serão não estruturados.

Para materializar essa grande quantidade de dados, basta analisarmos o relatório elaborado pela empresa Domo. De acordo com a companhia, em um minuto:

- Mais de 5,9 milhões de buscas são feitas no Google.
- Mais de 231,4 milhões de e-mails são enviados.
- Mais de 1 milhão de horas de *stream* são transmitidas pelos serviços de streaming (Netflix, Prime Video, Disney+ e outros).
- Mais de 66 mil fotos são compartilhadas no Instagram.
- Mais de 347,2 mil postagens são compartilhadas no X.
- Mais de 500 horas de vídeos são carregados no YouTube.
- Mais de \$443 mil são gastos na Amazon.
- Mais de 1,1 milhão de “arrasta para o lado” são feitos no Tinder.

- US\$ 1.000.000 (1 milhão de dólares) são gastos on-line e muito mais.




Figura 13 - Quantidade de dados gerados pelos principais serviços em um minuto
 Fonte: DOMO (2022), adaptado por FIAP (2025)

Isso mostra que, a cada minuto, é gerada uma massa gigantesca de dados, os quais podem ser transformados em informação. Hoje o grande desafio das empresas é trazer mais valor com essa grande quantidade de dados. Mas como a maior parte dos dados gerados são não estruturados, ou seja, textos, imagens, vídeos e outros tipos de dados que fogem do padrão “Excel” (tabelas regulares e dados predefinidos), as empresas precisam investir em tecnologia para poder analisar cada tipo de dado.

Com essa grande massa de dados não estruturados gerados diariamente, abre-se espaço para que as empresas invistam, cada vez mais, em tecnologia e profissionais.

2 INTELIGÊNCIA ARTIFICIAL, *MACHINE LEARNING*, *DEEP LEARNING* E INTELIGÊNCIA ARTIFICIAL GENERATIVA

Dentro do campo de estudo da Inteligência Artificial, existem subcampos: *Machine Learning* (ou Aprendizado de Máquina) é um subcampo da Inteligência Artificial. *Deep Learning* (ou Aprendizagem Profunda) é um subcampo do *Machine Learning*. E *Generative Artificial Intelligence* (ou Inteligência Artificial Generativa) é um subcampo de *Deep Learning*.

- **Inteligência Artificial (IA):** IA refere-se ao campo mais amplo de criação de máquinas inteligentes que podem simular a inteligência humana e executar tarefas que normalmente requerem inteligência humana. Envolve o desenvolvimento de algoritmos e sistemas que podem perceber, raciocinar, aprender e tomar decisões. A IA abrange várias técnicas, metodologias e abordagens para imitar a inteligência humana em máquinas.
- ***Machine Learning* (ML):** ML é um subconjunto da IA que se concentra no desenvolvimento de algoritmos e modelos que permitem que os computadores aprendam com os dados e façam previsões ou executem ações sem serem explicitamente programados. Envolve o treinamento de um modelo em um determinado conjunto de dados, permitindo identificar padrões, relacionamentos e *insights*. Os algoritmos de ML aprendem iterativamente com os dados, melhorando seu desempenho com a experiência.
- ***Deep Learning* (DL):** DL é um subcampo do *Machine Learning* que se concentra especificamente em redes neurais artificiais inspiradas na estrutura e no funcionamento do cérebro humano. Os modelos de *Deep Learning*, também conhecidos como redes neurais profundas (no inglês, *Deep Neural Networks*), consistem em várias camadas de neurônios interconectados que aprendem representações hierárquicas de dados. Essas redes podem aprender automaticamente padrões e recursos complexos diretamente de dados brutos, sem a necessidade de engenharia manual de recursos.

- **Inteligência Artificial Generativa (IA Generativa):** IA Generativa é um campo especializado, dentro da Inteligência Artificial, que se concentra na criação de sistemas capazes de produzir conteúdo novo e original, aprendendo padrões de dados existentes. Sua relação com o *Deep Learning* é fundamental e intrincada, pois a IA Generativa depende principalmente de arquiteturas de redes neurais profundas para funcionar. O *Deep Learning* fornece a base e as estruturas essenciais (como GANs, VAEs e Transformers) que permitem que a IA Generativa processe e entenda padrões complexos em dados e, em seguida, use esse entendimento para gerar novo conteúdo.

Uma maneira simples de relacionar cada tecnologia é fazendo um paralelo com uma boneca russa (também conhecida como matriosca). Uma matriosca é uma série de bonecas que são colocadas umas dentro das outras, da menor (a única que não é oca) até a maior (exterior). A Inteligência Artificial é a boneca maior e representa todo o campo de estudo, e o subcampo de IA Generativa representa a menor boneca do conjunto, sendo ela a visão mais detalhada de uma IA.




Figura 14 - Relação dos campos de estudos sobre Inteligência Artificial com uma matriosca
Fonte: Elaborado pelo autor (2025), adaptado por FIAP (2025)

2.1 *Machine Learning* (ou ML)

Assim como foi dito anteriormente, *Machine Learning* é uma ramificação da Inteligência Artificial, com o foco na construção de aplicações que aprendem com os dados e cuja acuracidade melhora à medida do tempo. Os algoritmos são treinados para encontrar padrões e funcionalidades em uma grande massa de dados para possibilitar a tomada de melhores decisões e até a criação de previsões com base em dados. Assistentes virtuais (como a Lu do Magazine Luiza e a Alexa da Amazon) e plataformas de recomendação de produtos, filmes e músicas (como o YouTube, Netflix e Spotify) são alguns exemplos do uso de *Machine Learning* para melhorar a experiência do produto, além de buscarem melhorar, cada vez mais, a acuracidade de suas falas e recomendações à medida que vão analisando mais e mais interações. Além desses exemplos, podemos incluir outras tecnologias que estão utilizando *Machine Learning* para aprimorar a experiência, como os carros autônomos, que estão ganhando cada vez mais espaço no mercado de automóveis.

Existem três categorias principais de Machine Learning: *Supervised Machine Learning*, *Unsupervised Machine Learning* e *Semi-supervised Machine Learning*.

- ***Supervised Machine Learning* (ou Aprendizado de Máquina Supervisionado):** utiliza um modelo de treinamento em que você fornece os dados e os agrupa em rótulos. Um exemplo prático de quando você precisa treinar as funções de reconhecimento de um chatbot é quando você define as frases que serão usadas para que o seu robô identifique, por exemplo, uma saudação ou um agradecimento. Repare que você está agrupando os dados em um rótulo (por exemplo, saudação).
- ***Unsupervised Machine Learning* (ou Aprendizado de Máquina Não Supervisionado):** utiliza um modelo de treinamento em que você fornece uma grande quantidade de dados e os algoritmos os agruparão de acordo com algumas similaridades. Esse método visa a identificação de padrões e relacionamentos em dados que provavelmente poderiam ser perdidos, se usado o método de Aprendizado de Máquina Supervisionado, por conta da intervenção humana. Um exemplo de uso desse método é com os filtros de spam. Existem mais e-mails do que um cientista de dados poderia analisar. Então ao invés de ter um time que analisa cada e-mail e procura identificar

se é spam ou não, um algoritmo de aprendizagem não supervisionado pode analisar grandes volumes de e-mails e, por meio dos recursos e padrões que indicam spam, classifica se o e-mail recebido é ou não um spam.

- ***Semi-supervised Machine Learning* (ou *Aprendizagem Semi-supervisionada*)**: oferece um meio-termo entre o Aprendizado de Máquina Supervisionado e o Aprendizado de Máquina Não Supervisionado. Esse método permite que você utilize um pequeno conjunto de dados rotulados para orientar a classificação e o agrupamento de um conjunto de dados maior e não rotulado. Assim, ele resolve o problema de não haver dados rotulados suficientes (ou por não ter como agrupar dados suficientes) para treinar um algoritmo de aprendizagem supervisionada. Um modelo de classificação de documentos de texto é um exemplo de uso de um modelo de Aprendizagem Semi-supervisionada, isso porque é muito trabalhoso e pouco eficiente para uma pessoa realizar esse trabalho. Então, você pode inserir alguns documentos, fazer as marcações (definir os rótulos) e, depois, aplicar o algoritmo para classificar uma grande quantidade de documentos de texto, sem nenhum rótulo.

Além dos três métodos citados, existe também o *Reinforcement Machine Learning* (ou Aprendizado de Máquina por Reforço), parecido com o *Supervised Machine Learning*, porém o algoritmo não é treinado com dados de exemplo. O modelo aprende por meio de tentativa e erro. No programa de TV *Jeopardy!*, o sistema do computador Watson utilizou esse método para definir, durante a competição, se tentava dar uma resposta ou não.

2.2 Deep Learning (ou DL)

Deep Learning (ou Aprendizagem Profunda) é um subcampo do *Machine Learning* que foca na construção e treinamento de redes neurais profundas, que são redes neurais artificiais com várias camadas. Inspirado na estrutura e funcionamento do cérebro humano, o *Deep Learning* visa modelar padrões complexos e relacionamentos em dados usando uma representação hierárquica de recursos.

O termo “deep” refere-se à profundidade da rede neural, o que significa que ela possui várias camadas ocultas entre as camadas de entrada e saída. Cada camada consiste em nós interconectados (neurônios artificiais) que executam cálculos nos dados de entrada. Ao empilhar várias camadas, os modelos de *Deep Learning* podem aprender representações cada vez mais abstratas e sofisticadas dos dados.

Structure of a neural network




Figura 15 - Estrutura de uma Rede Neural
Fonte: IBM (2020), adaptado por FIAP (2025)

Os modelos de *Deep Learning* normalmente são não supervisionados ou semi-supervisionados. Modelos de aprendizado por reforço também podem ser modelos de *Deep Learning*. É importante ressaltar que certos tipos de modelos de *Deep Learning* estão impulsionando o progresso em áreas como visão computacional, processamento de linguagem natural (incluindo reconhecimento de fala) e carros autônomos.

O *Deep Learning* ganhou atenção significativa e alcançou sucesso notável em vários domínios, particularmente em áreas onde padrões complexos ou grandes quantidades de dados estão envolvidos.

Arquiteturas de rede neural e métodos de treinamento formam os elementos fundamentais dos sistemas modernos de Inteligência Artificial e *Deep Learning*. Esses

componentes trabalham juntos como o projeto e o processo de construção de um edifício, onde as arquiteturas fornecem a estrutura, e os métodos de treinamento determinam como essas estruturas aprendem e se adaptam a partir dos dados.

As arquiteturas de redes neurais são arranjos sofisticados de neurônios artificiais e conexões que imitam as capacidades de processamento de informações do cérebro humano. Essas arquiteturas vêm em várias formas, cada uma projetada para se destacar em tipos específicos de tarefas.

- **Convolutional Neural Networks (CNN, ou Redes Neurais Convolucionais):** as CNNs são arquiteturas especializadas projetadas principalmente para processar dados semelhantes a grades, especialmente imagens. Elas utilizam camadas convolucionais que varrem os dados de entrada, aplicando filtros para detectar recursos como bordas, texturas e padrões. Essas redes usam camadas de pooling para reduzir a dimensionalidade e camadas totalmente conectadas para o processamento final. As CNNs se destacam em tarefas como classificação de imagens, detecção de objetos e reconhecimento facial, devido à sua capacidade de manter relacionamentos espaciais nos dados.
- **Recurrent Neural Networks (RNN, ou Redes Neurais Recorrentes):** as RNNs são projetadas para manipular dados sequenciais mantendo um estado de memória interna. Elas processam entradas sequencialmente, com cada etapa levando em consideração a entrada atual e os estados anteriores. Essa arquitetura é particularmente eficaz para tarefas que envolvem séries temporais, texto ou quaisquer dados sequenciais. Variantes avançadas como **LSTM** (*Long Short-Term Memory*) e **GRU** (*Gated Recurrent Unit*) abordam o problema do gradiente de desaparecimento e melhoram o aprendizado de dependência de longo prazo.
- **Transformers (ou Transformadores):** as arquiteturas de *Transformers* revolucionaram o *Deep Learning* ao introduzir mecanismos de autoatenção. Diferentemente das RNNs, elas processam todos os elementos de entrada simultaneamente, ponderando seus relacionamentos entre si. O mecanismo de autoatenção permite que o modelo se concentre em partes relevantes

da entrada, independentemente de sua posição. Os Transformers se tornaram a base para modelos de linguagem modernos e são cada vez mais aplicados em visão computacional e outros domínios.

Métodos de treinamento, por outro lado, representam os procedimentos e algoritmos usados para ensinar essas redes neurais a executarem suas tarefas pretendidas. Em seu núcleo, esses métodos envolvem técnicas de otimização sofisticadas que ajustam os parâmetros da rede para minimizar os erros em suas previsões.

- ***Backpropagation* (ou *Retropropagação*):** este algoritmo fundamental permite que as redes neurais aprendam calculando gradientes da função de perda com relação a todos os pesos na rede. Ele funciona de trás para frente a partir da saída, usando a regra da cadeia para distribuir a responsabilidade do erro pelas camadas. O processo envolve propagação direta de dados, cálculo de erro e propagação reversa de gradientes, permitindo que a rede ajuste seus pesos iterativamente.
- ***Optimization Algorithms* (ou *Algoritmos de Otimização*):** diferentes otimizadores melhoram o processo de treinamento. O Adam combina os benefícios do momentum e das taxas de aprendizado adaptativo. O *Stochastic Gradient Descent* (SGD) atualiza os pesos usando pequenos lotes de dados, fornecendo efeitos de eficiência e regularização. O RMSprop adapta as taxas de aprendizado com base no histórico recente do gradiente, enquanto o AdaGrad acumula gradientes ao longo do tempo para ajustar as taxas de aprendizado por parâmetro.

O *Deep Learning* demonstrou desempenho excepcional em várias tarefas, incluindo reconhecimento de imagem e fala, processamento de linguagem natural, tradução automática, sistemas de recomendação e muito mais. Sua capacidade de aprender automaticamente representações complexas de dados brutos e lidar com padrões complexos levou a avanços significativos em aplicações de IA.

2.3 Computação Cognitiva

A Computação Cognitiva pode ser considerada como um campo interdisciplinar que engloba elementos de IA, *Machine Learning* e *Deep Learning*. O objetivo é simular processos de pensamento humano e habilidades cognitivas em máquinas, permitindo que elas percebam, raciocinem, aprendam e tomem decisões de maneira mais humana.

Enquanto a IA concentra-se amplamente na criação de máquinas inteligentes, a Computação Cognitiva enfatiza especificamente o desenvolvimento de sistemas que podem entender, interpretar e responder a dados complexos e não estruturados, como linguagem natural, imagens e entradas sensoriais.

Os sistemas de Computação Cognitiva geralmente empregam *Machine Learning* e técnicas de *Deep Learning* para processar e analisar dados, extrair *insights* significativos e tomar decisões informadas. Esses sistemas visam ir além da programação tradicional baseada em regras e aproveitar técnicas como processamento de linguagem natural, visão computacional e reconhecimento de padrões para entender e interpretar dados de maneira mais sutil e sensível ao contexto.

Um dos principais aspectos da Computação Cognitiva é a capacidade de interagir com humanos de maneira natural e intuitiva. Isso envolve técnicas como análise de sentimentos, reconhecimento de emoções e geração de linguagem natural para permitir que as máquinas entendam as emoções humanas, se comuniquem de maneira eficaz e forneçam respostas personalizadas.

Os sistemas de Computação Cognitiva são projetados para aprender e se adaptar continuamente com base no feedback e em novas informações melhorando seu desempenho ao longo do tempo. Eles podem ser utilizados em vários domínios, como saúde, finanças, atendimento ao cliente e educação, onde são necessárias análises complexas de dados e raciocínio semelhante ao humano.

Em resumo, a Computação Cognitiva integra IA, *Machine Learning* e técnicas de *Deep Learning* para criar sistemas que podem imitar os processos do pensamento humano e interagir com os humanos de maneira mais inteligente e natural. O objetivo é preencher a lacuna entre cognição humana e a inteligência da máquina, permitindo

que as máquinas entendam, aprendam e tomem decisões em ambientes complexos e não estruturados.

Parece um episódio de *Black Mirror*: estamos caminhando na direção de conseguir recriar uma pessoa digitalmente, de acordo com a Microsoft.

A Microsoft registrou uma patente, em 2017, em que apresenta sistemas e métodos para criar o chatbot de uma pessoa. Para isso, a empresa utilizaria dados das redes sociais (como fotos, vídeos, arquivo de áudio, mensagens, entre outros) para reproduzir a personalidade e utilizá-la para treinar o chatbot. Além disso, também seria possível reproduzir um modelo 2D ou 3D da pessoa a partir das imagens, fotos e vídeos.

Se olharmos para 15 anos atrás, podemos perceber que a tecnologia necessária para trabalhar com Computação Cognitiva não era de fácil acesso e muito menos de graça. Naquela época era comum ter os dados em mãos e não contar com uma ferramenta ou serviço que permitisse treinar um robô para executar uma tarefa considerada simples, como ler uma pergunta e respondê-la (isso envolve processamento de linguagem natural) ou identificar objetos em uma imagem.

Com o advento das nuvens públicas, como *Microsoft Azure*, *Amazon Web Services*, *Google Cloud Platform*, *IBM Cloud* e outras, muitos serviços de Inteligência Artificial e Computação Cognitiva foram disponibilizados para o consumo no modelo “as-a-Service” (pague somente o que foi consumido). A IBM tem investido bastante no Watson desde o sucesso de sua aparição em *Jeopardy!*, para disponibilizar suas capacidades cognitivas em formato de serviço.

Se uma empresa necessita criar um assistente virtual, no qual é treinado para atender seus clientes nas redes sociais, ela precisará de uma conta na *IBM Cloud* e utilizará o *watsonx Assistant*, serviço de interface conversacional (também conhecido por ser a base de chatbots e assistentes virtuais), para treinar com os principais assuntos. O assistente virtual entenderá e definirá as respostas para cada tipo de pergunta. E, uma vez treinado, o assistente já estará preparado para atender os clientes dessa empresa.

Podemos ir além. Com o serviço de *watsonx Assistant*, temos a capacidade de processamento de linguagem natural (NLP) para construir um assistente virtual ou um chatbot. Caso queiramos expandir a sua capacidade, basta integrar com mais dois

serviços: *Speech to Text* (STT) e *Text to Speech* (TTS), a fim de adicionar a capacidade de transformar a fala do usuário em texto e transformar o texto do chatbot em fala, respectivamente. Assim, o chatbot consegue “ouvir” e “falar”.

Um exemplo prático: o laboratório de pesquisa da IBM, *IBM Research*, desenvolveu um projeto chamado Project Debater, revelado ao público em 2019. O primeiro sistema de IA que consegue debater com humanos sobre assuntos complexos. A IA entende todo o cenário do debate e até as falas dos participantes, transforma em texto e analisa essa grande massa de informações com sua base de dados para construir uma resposta bem-feita e falar com clareza e propósito, para rebater o adversário. A ideia do projeto é ajudar as pessoas a raciocinarem, apresentar argumentos convincentes e baseados em evidências, limitando a influência da emoção, do preconceito ou da ambiguidade.



Figura 16 - IBM Debater
Fonte: IBM (2025)

2.4 IA Generativa

IA Generativa se refere a um tipo de inteligência artificial que pode criar ou gerar novos conteúdos, como imagens, textos, músicas ou até mesmo vídeos. É como ensinar um computador a ser criativo e produzir material original.

Em vez de serem explicitamente programados com regras específicas, os modelos de IA Generativa são treinados em grandes quantidades de dados e aprendem padrões e relacionamentos dentro desses dados. Esses modelos podem gerar um novo conteúdo com estilo ou estrutura semelhante aos dados nos quais foram treinados.

Por exemplo, digamos que você tenha um modelo de IA Generativa treinado em um conjunto de dados de imagens de gatos. Quando você insere uma entrada aleatória, ele pode criar novas imagens de gatos que nunca viu antes, com base no que aprendeu com os dados de treinamento. Ele pode gerar diferentes raças de gatos, cores, poses e até mesmo imaginar características felinas novas e únicas.

Os modelos de IA Generativa são frequentemente usados em várias aplicações criativas, como arte, composição musical e narrativa. Eles também podem ser usados em aplicações práticas, como síntese de dados, onde podem gerar novos dados realistas para complementar conjuntos de dados existentes para modelos de aprendizado de máquina de treinamento.

No entanto, é importante observar que os modelos de IA Generativa não são perfeitos e, às vezes, podem gerar conteúdo irreal, estranho ou tendencioso. É crucial entender as limitações e considerações éticas ao trabalhar com IA Generativa.

Os principais conceitos da IA Generativa giram em torno da compreensão dos principais componentes e técnicas usadas na construção de modelos generativos. Aqui estão alguns dos conceitos fundamentais:

- **Modelos generativos:** modelos generativos são algoritmos ou modelos que aprendem a gerar novas amostras de dados semelhantes aos dados de treinamento aos quais foram expostos. Esses modelos capturam a distribuição subjacente dos dados de treinamento e podem gerar novas amostras que exibem características semelhantes.
- **Dados de treinamento:** os modelos generativos dependem de grandes quantidades de dados de treinamento para aprender e capturar os padrões e estruturas presentes nos dados. A qualidade e a diversidade dos dados de treinamento desempenham um papel importante no desempenho e na criatividade do modelo generativo.

- **Redes neurais:** muitos modelos generativos, como *Variational Autoencoders* (VAEs) e *Generative Adversarial Networks* (GANs), utilizam redes neurais como sua arquitetura subjacente. As redes neurais são compostas por nós ou neurônios interconectados que realizam cálculos, permitindo que o modelo aprenda representações complexas e gere novos dados.
- **Espaço latente:** os modelos generativos geralmente aprendem uma representação comprimida dos dados de treinamento conhecida como espaço latente. Esse espaço latente captura a estrutura subjacente dos dados e permite que o modelo gere novas amostras por amostragem desse espaço. Ele representa uma representação de dimensão inferior dos dados originais.
- ***Variational Autoencoders* (VAEs):** os VAEs são modelos generativos que combinam os princípios de *autoencoders* e modelagem probabilística. Eles visam aprender uma representação comprimida dos dados de entrada e gerar novas amostras por amostragem de um espaço latente aprendido. Além disso, são frequentemente usados para tarefas como geração de imagens e síntese de dados.
- ***Generative Adversarial Networks* (GANs):** GANs consistem em duas redes neurais: um gerador e um discriminador. A rede geradora gera novas amostras, enquanto a rede discriminadora tenta distinguir entre amostras reais e geradas. As duas redes são treinadas juntas em um cenário competitivo, onde o gerador visa enganar o discriminador, e o discriminador visa tornar-se melhor em distinguir amostras reais de amostras geradas. As GANs são amplamente utilizadas para tarefas como geração de imagens e vídeos.
- ***Reinforcement Learning*:** o Aprendizado por Reforço pode ser combinado com modelos generativos para criar sistemas de IA que podem aprender a gerar conteúdo com base em sinais de recompensa. Ao formular o processo de geração como um problema de tomada de decisão sequencial, o Aprendizado por Reforço pode guiar o modelo generativo para produzir os

resultados desejados, fornecendo feedback na forma de recompensas ou penalidades.

Esses conceitos fornecem uma compreensão fundamental da IA Generativa e suas técnicas subjacentes. Explorar cada conceito com mais detalhes pode ajudá-lo a obter uma compreensão mais profunda do campo e de suas aplicações práticas.

Em resumo, a IA Generativa é um tipo de IA que pode criar novos conteúdos com base nos padrões que aprendeu com os dados existentes. É como ensinar um computador a ser criativo e criar material original, sejam imagens, texto, música ou mais.

2.5 Mercado de trabalho

Ao resumir em uma visão futurística o tema Inteligência Artificial, podemos ser levados a certas características que são bastante reforçadas pelos conceitos que vemos em filmes. Somos levados a pensar que as máquinas poderão controlar o mundo em que vivemos e buscarão exterminar a raça humana (como é descrito nos filmes *Exterminador do Futuro* ou *Eu, Robô*), ou que elas serão o único ser no planeta Terra (como é descrito no filme *Wall-E*), ou que as máquinas substituirão um ente falecido (como é descrito na série *The Black Mirror*, no episódio “Volto já”, da segunda temporada).

De fato, muitos filmes e séries remetem a uma visão bem pessimista do futuro da Inteligência Artificial. Entretanto, se analisarmos o mercado de trabalho nos últimos anos, podemos observar que a grande preocupação, na atual era digital, é com a substituição da mão de obra de diversos setores por máquinas e por sistemas com Inteligência Artificial. Isso acontece porque muitas profissões não requerem um pensamento criativo para realizar o trabalho. Um atendente de telemarketing, por exemplo, que segue diversos protocolos, poderá ser substituído por um voicebot (um chatbot, com capacidade de fala e de escuta, integrado a uma IA para processar as falas e responder devidamente). Isso porque os protocolos de atendimento seguem uma estrutura de árvore de decisão, ferramenta base para um chatbot.

Além do exemplo de um atendente de telemarketing, podemos visualizar outras profissões que podem sofrer com o avanço da IA, como:

- Uma recepcionista de hotel pode ser substituída por um assistente virtual que poderá realizar as principais atividades, como: realizar check-in e checkout, indicar onde fica a academia do hotel, recomendar os principais pontos turísticos e restaurantes e, quando bem integrado aos sistemas do hotel, poderá preparar o quarto do hóspede e deixá-lo na temperatura ideal, entre outras funções.
- Um operador de caixa em um supermercado pode ser substituído por um caixa com *self-checkout*. Nos EUA, já é comum encontrar supermercados com caixas em que você passa as compras e faz o pagamento sem a necessidade de atendimento humano. A Amazon lançou, em 2018, uma rede de lojas de conveniência em que você pega os itens nas prateleiras e estes automaticamente são inseridos no seu carrinho de compra, dentro do app. Ao sair da loja, o pagamento é realizado automaticamente no seu cartão de crédito. A empresa utiliza IA para identificar cada cliente que está na loja e cada produto que é retirado da prateleira, relacionando uma informação com a outra para que o produto seja adicionado no carrinho de compra do cliente.
- E até um entregador de comida está sujeito a ser substituído por Inteligência Artificial. Ao invés da comida ser entregue por uma pessoa, essa operação poderá ser realizada por meio de drones. Aqui no Brasil, o iFood já recebeu autorização da Anac (Agência Nacional de Aviação Civil) para realizar testes de entrega de comida por meio de drone. Futuramente, será possível realizar essa operação 100% automatizada por meio de uma IA.

Há um site chamado "*Will Robots Take my Job?*", que permite realizar busca por uma profissão e ele aponta a probabilidade de a profissão ser substituída por um robô. Um desenvolvedor de software, por exemplo, tem 4% de chance de ser substituído e com o nível de risco de automação considerado como "totalmente seguro", enquanto um atendente de telemarketing tem 99% de chance de ser substituído e com o nível de risco de automação considerado como "você está condenado". O site é um bom indicador de que muitas profissões podem ser substituídas por uma IA.

Por outro lado, existem estudos que indicam que, com a automação de algumas profissões, certas áreas, como a de Tecnologia, terão mais procura por profissionais. Segundo o relatório “*The Future of Jobs 2020*”, do World Economic Forum (WEF), até o final de 2025, 85 milhões de empregos podem ser substituídos, enquanto espera-se que 97 milhões de novas posições surjam e estejam mais adaptadas à nova realidade. No mesmo relatório, ao filtrar por países e selecionar o Brasil, identificamos que a profissão com a maior demanda é a de “*AI and Machine Learning Specialists*” (especialistas em Inteligência Artificial e *Machine Learning*).

Emerging and redundant job roles

Role identified as being in high demand or increasingly redundant within their organization, ordered by frequency




Figura 17 - Lista de profissões com demanda elevada no mercado de trabalho
Fonte: World Economic Forum (2025)

Embora existam certos aspectos de um trabalho que estão suscetíveis de serem automatizados, a intervenção humana não pode ser substituída.

As máquinas são ótimas para executar uma tarefa específica repetidamente, com um alto nível de precisão e consistência. E essas características são fortes indicadores de que a IA assumirá uma variedade específica de tarefas e profissões. Mas, para ter uma máquina ativa, é necessário que alguém a ensine.

REFERÊNCIAS

A COMPUTER Called Watson. **Computer History Museum**, 2011. Disponível em: <<https://computerhistory.org/events/computer-called-watson-ibm-researchs/>>. Acesso em: 25 fev. 2025.

APPLE Launches iPhone 4S, iOS 5 & iCloud. **Apple**, 04 de outubro de 2011. Disponível em: <<https://www.apple.com/newsroom/2011/10/04Apple-Launches-iPhone-4S-iOS-5-iCloud/>>. Acesso em: 10 jan. 2025.

CREATING a conversational chat bot of a specific person. **United States Patent and Trademark Office**, 2020. Disponível em: <<https://portal.unifiedpatents.com/patents/patent/US-10853717-B2>>. Acesso em: 25 fev. 2025.

DENNING, Steve. How To Create An Innovative Culture: The Extraordinary Case Of SRI. **Forbes**, 30 de novembro de 2015. Disponível em: <<https://www.forbes.com/sites/stevedenning/2015/11/30/how-to-create-an-innovative-culture-the-extraordinary-case-of-sri>>. Acesso em: 20 fev. 2025.

GOOGLE DeepMind: AlphaGo. **DeepMind**, 2025. Disponível em: <<https://deepmind.google/research/breakthroughs/alphago/>>. Acesso em: 20 fev. 2025.

HASSABIS, Demis. AlphaGo: using machine learning to master the ancient game of Go. **Blog Google**, 27 de janeiro de 2016. Disponível em: <<https://blog.google/technology/ai/alphago-machine-learning-game-go/>>. Acesso em: 20 fev. 2025.

HOW our scientists are making Alexa smarter. **Amazon**, 29 de março de 2018. Disponível em: <<https://www.aboutamazon.com/news/devices/how-our-scientists-are-making-alexa-smarter>>. Acesso em: 20 fev. 2025.

IBM History: Deep Blue. **IBM**, 2025. Disponível em: <<https://www.ibm.com/history/deep-blue>>. Acesso em: 20 fev. 2025.

IBM History: Watson, 'Jeopardy!' champion. **IBM**, 2025. Disponível em: <<https://www.ibm.com/history/watson-jeopardy>>. Acesso em: 20 fev. 2025.

INTRODUCING Apple Intelligence, the personal intelligence system that puts powerful generative models at the core of iPhone, iPad, and Mac. **Apple**, 10 de junho de 2024. Disponível em: <<https://www.apple.com/newsroom/2024/06/introducing-apple-intelligence-for-iphone-ipad-and-mac/>>. Acesso em: 20 fev. 2025.

McCARTHY, J. et al. A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence. **Stanford University**, 30 de agosto de 1955. Disponível em: <<http://www-formal.stanford.edu/jmc/history/dartmouth/dartmouth.html>>. Acesso em: 20 fev. 2025.

TURING, A. M. Computing Machinery and Intelligence. **University of Maryland, Baltimore County**, 1955. Disponível em: <<https://www.csee.umbc.edu/courses/471/papers/turing.pdf>>. Acesso em: 26 fev. 2025.

WEIZENBAUM, Joseph. Computational Linguistics: ELIZA — A Computer Program For the Study of Natural Language Communication Between Man And Machine. **Stanford University**, 1966. Disponível em: <<https://web.stanford.edu/class/linguist238/p36-weizenbaum.pdf>>. Acesso em: 26 fev. 2025.

WORLD ECONOMIC FORUM. The Future of Jobs Report. **World Economic Forum**, 20 de outubro de 2020. Disponível em: <<https://www.weforum.org/reports/the-future-of-jobs-report-2020>>. Acesso em: 20 fev. 2025.