

CLOUD SEC & IA

PYTHON TO MACHINE LEARNING



14

LISTA DE FIGURAS

Figura 1 – Ecossistema de dados	7
Figura 2 – Processo de <i>Machine Learning</i>	10
Figura 3 – Resultados do resumo das estatísticas descritivas	12
Figura 4 – Resultados teste de hipótese	15
Figura 5 – Resultados correlação	15
Figura 6 – Resultados regressão	16
Figura 7 – Resultados <i>Kmeans</i>	18
Figura 8 – Resultados <i>boxplot</i>	18

LISTA DE QUADROS

Quadro 1 – Principais módulos <i>python</i> para <i>Machine Learning</i>	9
Quadro 2 – Técnicas de análises	10

EMENDAS

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 – Importar módulos iniciais e dados.....	12
Código-fonte 2 – Resumo estatísticas descritivas.....	12
Código-fonte 3 – Exemplos códigos probabilidade	13
Código-fonte 4 – Exemplo derivadas no python.....	13
Código-fonte 5 – Exemplo amostragem.....	14
Código-fonte 6 – Exemplo teste de hipótese.....	14
Código-fonte 7 – Exemplo correlação	15
Código-fonte 8 – Exemplo regressão linear	16
Código-fonte 9 – Exemplo <i>KMeans</i>	17
Código-fonte 10 – Exemplo <i>boxplot</i>	18

SUMÁRIO

BIBLIOTECAS PYTHON PARA MACHINE LEARNING	6
1 INTRODUÇÃO	6
2 FERRAMENTAS GERAIS A SEREM UTILIZADAS	8
3 TÉCNICAS DE ANÁLISE A SEREM ABORDADAS	9
4 FERRAMENTAS DE ANÁLISE DESCRITIVA E TESTES DE HIPÓTESES	11
4.1 Ferramentas de estatística descritiva	11
4.2 Ferramentas de probabilidade	12
4.3 Ferramentas de Cálculo	13
4.4 Ferramentas de Amostragem	14
4.5 Ferramentas de Testes de hipóteses	14
5 FERRAMENTAS DE PREPARAÇÃO DE DADOS E <i>MACHINE LEARNING</i>	15
5.1 Ferramentas de correlação e associação	15
5.2 Ferramentas de análise de regressão e séries temporais	16
5.3 Ferramentas de análise multivariada de dados	17
5.4 Ferramentas de limpeza e normalização de dados	18
REFERÊNCIAS	19

BIBLIOTECAS PYTHON PARA MACHINE LEARNING

1 INTRODUÇÃO

O objetivo deste texto é discorrer sobre as principais ferramentas para análise de dados utilizando-se da linguagem *python* para facilitar o processo de obter informações por meio dos dados. Iremos apresentar uma visão global dos principais módulos e funções além dos conceitos básicos sobre as técnicas utilizadas em *Data Science e Machine Learning*.

Antes de apresentar as ferramentas, vamos conhecer algumas características desse contexto, começando pelo ambiente de dados que é o espaço onde você encontrará as ferramentas de hardware e software para colocar suas demandas e ideias em prática. Neste capítulo iremos abordar os seguintes temas gerais de ambiente de dados como: Ecossistema de dados e Ferramentas gerais para análise de dados, ciência de dados e *Machine Learning*.

Conforme Oliveira e Lóscio (2018) um ecossistema de dados é um sistema baseado em dados em que diversos indivíduos geram uma complexa troca de informações. Ecossistemas de dados são utilizados para coletar, colecionar, armazenar, analisar, transformar e processar dados e fornecem às empresas, instituições e pessoas dados nos quais elas necessitam para compreender seus desafios e tomar melhores decisões em diferentes áreas como finanças, marketing, operações, gestão pública entre outras.

Este ambiente pode ser decomposto em quatro componentes: **Recursos, Funções, Atores e Relacionamentos**. Na figura “Ecossistema de dados” temos um resumo sobre como funciona este ambiente.



Figura 1 – Ecosistema de dados
Fonte: Elaborado pelo autor (2021), adaptado por FIAP (2023)

Os **Recursos** representam os conjuntos de dados, as ferramentas e infraestrutura de processamento dos dados que os atores podem utilizar. Os recursos utilizados tanto podem ser propostos para consumo quanto para produção (tratamento) dos dados; podendo ser restritos pelas licenças. Neste caso, algumas empresas podem adotar softwares com licença paga ou livre.

As **Funções** representam o conjunto de atividades desempenhadas pelos atores. Estas atividades podem ser resumidas em três tipos gerais: **Produção**, **Consumo** e **Intermediação**. As atividades de **Produção** podem ser de extração, preparação, publicação e manutenção dos dados. Acessos, processamentos e análises podem vistas como atividades de **Consumo**. As funções de **Intermediação** são aquelas voltadas a criação de produtos/soluções por meio dos dados, como aplicativos ou API's.

Os **Atores** são os indivíduos que atuam no ecossistema. Deste modo, caso um indivíduo possa assumir alguma das funções de produção, consumo ou intermediação, estará sendo um ator presente no ecossistema de dados. Alguns dos atores que coabitam neste ambiente são engenheiros de dados, cientistas de dados, engenheiros de *Machine Learning*, analistas de bancos de dados, administradores de banco de dados e especialistas em segurança de dados.

Relacionamentos é o último componente; neste caso, representa todas as interações existentes no Ecosistema de Dados. Sendo que tais relacionamentos não estão somente restringidos aos atores, mas também como os recursos podem se

interligar; como, por exemplo, a relação entre o banco de dados, os programas de extração, as API's e as ferramentas analíticas.

Esta decomposição do ecossistema de dados é uma representação global de como as inúmeras empresas no mercado podem organizar suas arquiteturas para preparação, tratamentos e análise.

2 FERRAMENTAS GERAIS A SEREM UTILIZADAS

Para realizar uma análise de dados, como primeiro passo, busca-se entender o problema do negócio e o resultado esperado do projeto. Após a definição dos objetivos, quais tipos de dados, formatos e fontes são necessários para atingir as metas traçadas. Após objetivos e dados escolhidos, buscam-se os dados nos bancos, aplica-se algum processo de transformação para garantir a qualidade (formatação, limpeza de inconsistência, erros).

Após todo processo de correção, finalmente as análises são realizadas com objetivo de responder as questões de negócios levantadas. Sendo que uma das formas mais fáceis de apresentar tais resultados é por meio da visualização dos dados.

Entre o processo de responder as questões de negócios e apresentar os resultados por meio de visualização. Pode-se levantar hipóteses estatísticas necessárias e estimar algum modelo para ajustar os dados obtidos (modelo econométricos, estatísticos, *machine learning*).

Após avaliar a qualidade do modelo estimado, torna-se necessário buscar melhorias no modelo, seja adicionar uma nova variável ou testar novas interações de ajuste dos algoritmos de aprendizagem.

Existem uma gama de ferramentas para processar e analisar os dados, praticamente existe um verdadeiro ecossistema de ferramentas em que cientistas de dados podem utilizar. No Quadro “Principais módulos *python* para *Machine Learning*” podemos resumir algumas destas ferramentas.

Módulo	Descrição
numpy	Numpy é um acrônimo para <i>Numerical Python</i> , módulo fundamental para análise de dados e computação científica. Principais funções a serem utilizadas: min, max, mean, median, mode, quantile .
pandas	Pandas é um acrônimo para <i>Python Data Analysis Library</i> . É um pacote poderoso e flexível para utilização em análise de dados. O Pandas será bastante utilizado para o tratamento dos dataframes .
sympy	Sympy é uma biblioteca voltada a matemática simbólica no <i>python</i> . Esta ferramenta é utilizada para estudos de limites, derivadas e integrais. Algumas funções: limit, diff e integrate .
scipy	Ferramenta proposta para auxiliar nos problemas gerais de cálculo, probabilidade e testes de hipóteses. Principais funções que utilizaremos: binom, poisson, expon, norm, t, chi2, f .
statsmodels	O statsmodels é um módulo voltado para aplicação de vários modelos estatísticos. A principal função que utilizaremos será a OLS .
sklearn	O scikit-learn é uma ferramenta voltado para análise preditiva. Utilizaremos este módulo para aplicar as funções LinearRegression, PCA e Kmeans .

Quadro 1 – Principais módulos *python* para *Machine Learning*.
Fonte: Elaborado pelo autor (2021)

3 TÉCNICAS DE ANÁLISE A SEREM ABORDADAS

Diversas técnicas de análises serão apresentadas. Contudo, elas não podem ser limitadas ao Quadro apresentado “Técnicas de análises”, existem ainda uma gama de outras técnicas que o aluno pode buscar aprender. Estas técnicas escolhidas foram selecionadas por serem as mais utilizadas no mercado. Vale ressaltar que todas elas serão bastante exploradas com o uso do *python*.

Análises	Objetivos
Análise Descritiva	Entender o comportamento geral dos dados
Testes de hipóteses	Verificar uma afirmação sobre os dados
Análise correlação/associação	Análises voltadas a verificar a relação entre duas variáveis
Regressão linear	Ajustar o modelo para explicar alguma variável objetivo traçado pelo negócio
Análise de séries temporais	Projetar o histórico de vendas ou faturamento para o próximo período
Análise de componentes principais	Agrupar atributos de forma a reduzir a dimensão necessária para ser explicada
Análise de conglomerados (<i>cluster</i>)	Agrupar indivíduos conforme atributos selecionados

Quadro 2 – Técnicas de análises.
Fonte: Elaborado pelo autor (2021)

As técnicas apresentadas são constantemente utilizadas no âmbito do *Machine Learning*. O foco desta área é fazer com que um programa de computador aprenda com uma determinada experiência “E” de acordo com algumas tarefas “T” conforme uma medida de performance “P”.

O processo de aprendizagem ocorrerá após medir a performance P e perceber que a máquina realizou melhor a tarefa T. Isso ocorreu porque as experiências E foram significativas no processo. Na Figura “Processo de *Machine Learning*” é possível observar este processo de forma detalhada.




Figura 2 – Processo de *Machine Learning*
Fonte: Elaborado pelo autor (2021).

Os algoritmos utilizados para realizar este processo são construídos a partir de técnicas supervisionadas e não supervisionadas. As técnicas supervisionadas utilizam inputs de entrada para gerar outputs que são avaliados automaticamente para verificar se o erro para realizar alguma determinada tarefa está diminuindo ou aumentando.

Diante disto, as técnicas supervisionadas possuem principal interesse em realizar previsões a respeito dos dados. No caso das técnicas não supervisionadas, somente os *inputs* de entrada são utilizados para o processo de aprendizagem. Deste modo, não há um *output* para ser avaliado, mas as saídas são utilizadas para descobrir algum padrão ou subgrupos nos dados.

Nos próximos tópicos iremos resumir algumas das técnicas/ferramentas a serem utilizadas. Em relação a análise descritiva, apresentaremos ferramentas

relacionadas a estatística descritiva, probabilidade, amostragem e testes de hipóteses.

Entre as técnicas supervisionadas que serão estudadas estão: correlação, associação, regressão linear e séries temporais. Quanto as não supervisionadas (aqui estamos chamando de análise multivariada de dados): análise de componentes principais e análise de conglomerados (*clusters*). Por fim, apresentaremos alguns métodos para limpeza e normalização de dados. Todos os exemplos serão apresentados utilizando-se as principais ferramentas em *python*.

4 FERRAMENTAS DE ANÁLISE DESCRITIVA E TESTES DE HIPÓTESES

Neste momento, o objetivo é o primeiro contato com a ferramenta (*Google Colaboratory - Colab*), importação dos dados, módulos e aplicação genérica de algumas de nossas funções.

4.1 Ferramentas de estatística descritiva

Conforme foi apresentado no Quadro “Principais módulos *python* para *Machine Learning*”, as ferramentas *numpy* e *pandas* são fundamentais para desenvolver aplicações de estatística descritiva. Vamos apresentar alguns exemplos, por enquanto, somente deve-se testar os códigos.

Neste primeiro exemplo, iremos apresentar como carregar módulos/bibliotecas, como carregar os dados e, por último, obter estatísticas descritivas de mínimo, máximo, média e desvio padrão.

Para começar as análises, precisamos iniciar o Google Colab ao digitar no navegador (Chrome ou Firefox, por exemplo) <https://colab.research.google.com/> e selecionar a opção “Novo notebook” será aberto um arquivo *.ipynb*. Agora podemos carregar os seguintes dados no colab: *dados_1997_2011_paises_csv.csv*. Uma vez que os dados foram carregados, digitar o código fonte “importar módulos iniciais e dados” na tela do colab.

```
# módulos
import numpy as np
import pandas as pd
import sympy as sp

# dados
df_dados_países = pd.read_csv('dados_1997_2011_países_csv.csv',
                               sep = ';',
                               encoding='latin1',
                               decimal=',')
```

Código-fonte 1 – Importar módulos iniciais e dados
Fonte: Elaborado pelo autor (2021)

Para obter as estatísticas de mínimo, máximo, média e desvio padrão, digitar o código-fonte “resumo estatísticas descritivas”.

```
# estatísticas descritivas
df_dados_países.groupby('país') \
    .agg(min_idh = pd.NamedAgg('idh', 'min'),
         max_idh = pd.NamedAgg('idh', 'max'),
         media_idh = pd.NamedAgg('idh', 'mean'),
         mediana_idh = pd.NamedAgg('idh', 'median'),
         desvio_padrao_idh = pd.NamedAgg('idh', 'std'))
```

Código-fonte 2 – Resumo estatísticas descritivas
Fonte: Elaborado pelo autor (2021)

Após a execução do código, será possível ver o resultado apresentado na figura “Resultados do resumo das estatísticas descritivas”.

	min_idh	max_idh	media_idh	mediana_idh	desvio_padrao_idh
país					
Alemanha	0.8466	0.9050	0.882880	0.8888	0.020187
Austrália	0.8958	0.9290	0.914507	0.9156	0.010485
Brasil	0.6464	0.7180	0.684653	0.6866	0.022727
Bélgica	0.8628	0.8860	0.876107	0.8754	0.006401
Canadá	0.8736	0.9080	0.890480	0.8894	0.011899

Figura 3 – Resultados do resumo das estatísticas descritivas
Fonte: Elaborado pelo autor (2021).

4.2 Ferramentas de probabilidade

Conforme foi apresentado no Quadro “Principais módulos *python* para *Machine Learning*”, a ferramenta *scipy* será fundamental para entender as aplicações voltadas a probabilidade.

No código fonte “Exemplos códigos probabilidade” iremos examinar as seguintes funções: **binom**, **poisson**, **norm**. Após executar os códigos, teremos os seguintes resultados: 0,00639, 0,2706 e 0,0469.

```
# modulos
from scipy.stats import binom, poisson, norm

# binomial
n = 5
p = 0.8
binom.pmf(k=1, n = n, p = p)

# poisson
mu = 2
poisson.pmf(k=1, mu=mu)

# normal
media = 30
desvio_padrao = 6
norm.pdf(x = 25, loc = media, scale = desvio_padrao)
```

Código-fonte 3 – Exemplos códigos probabilidade
Fonte: Elaborado pelo autor (2021)

4.3 Ferramentas de Cálculo

Por meio do python, podemos realizar diversos estudos para a área de cálculo. A biblioteca sympy pode ser utilizada desde análise de funções, estudo de limites a obtenção de derivadas e integrais.

No código fonte “Exemplo derivadas no python”, podemos observar a aplicação das funções Symbol e diff. A primeira (Symbol) transforma a variável x em um símbolo e a segunda (diff) apresenta a derivada da função f.

```
# derivadas
x = sp.Symbol('x')
f = x**2
sp.diff(f)
```

Código-fonte 4 – Exemplo derivadas no python
Fonte: Elaborado pelo autor (2021)

4.4 Ferramentas de Amostragem

Para o caso da necessidade de retirar amostras dos dados ou aplicar alguma pesquisa de levantamento, seja nas ruas (*face-to-face*) ou *online* (e-mail, website), as ferramentas em *python* para amostragens são importantes.

No código fonte “Exemplo amostragem” podemos utilizar a função ***sample*** para retirar uma amostra de 50 linhas. Será possível observar o resultado (50,8) informando que o *dataframe* *df_amostra* tem 50 linhas e 8 colunas.

```
# amostragem
df_amostra = df_dados_países.sample(n=50)
df_amostra.shape
```

Código-fonte 5 – Exemplo amostragem
Fonte: Elaborado pelo autor (2021)

4.5 Ferramentas de Testes de hipóteses

Algo comum durante um processo de pesquisa é realizar diversos questionamentos sobre os dados. Estas perguntas podem ser transformadas em afirmações que poderão ser testadas. Diante disto, os procedimentos de testes de hipóteses serão importantes para realizar esta atividade.

Vamos conhecer a seguinte função do *scipy*: ***ttest_1samp***. No código-fonte “Exemplo teste de hipótese” temos um exemplo de como podemos utilizar estas funções.

```
# importar modulo
from scipy import stats as st

# separar dados
dados_brasil = df_dados_países[df_dados_países['país'] == 'Brasil']

# testar hipótese
st.ttest_1samp(a=dados_brasil['idh'], popmean=0.5)
```

Código-fonte 6 – Exemplo teste de hipótese
Fonte: Elaborado pelo autor (2021)

Será possível observar resultados similares a figura “Resultados teste de hipótese”.

```
Ttest_1sampResult(statistic=31.467547309127102, pvalue=2.1573861411421064e-14)
```

Figura 4 – Resultados teste de hipótese
 Fonte: Elaborado pelo autor (2021).

5 FERRAMENTAS DE PREPARAÇÃO DE DADOS E MACHINE LEARNING

5.1 Ferramentas de correlação e associação

Após entender os aspectos básicos dos dados, poderemos iniciar os assuntos relacionados ao tema de *Machine Learning*.

Uma tarefa inicial em análise de dados é verificar o comportamento de duas variáveis (colunas) de forma conjunta; nestes casos, as análises de associação e correlação serão fundamentais. Apresentaremos um exemplo simples com a função **corr**.

No código fonte “Exemplo correlação”, verificamos como as variáveis IDH, Nível de corrupção (corrupção_indice), Nível de competitividade (competitividade_indice) e Nível de globalização (globalização_indice) estão inter-relacionados. O resultado será uma matriz contendo todos os valores da diagonal iguais a 1.

```
# correlacao
cols = ['idh', 'corrupcao_indice', 'competitividade_indice', 'globalizacao_indice']
df_dados_paises[cols].corr()
```

Código-fonte 7 – Exemplo correlação
 Fonte: Elaborado pelo autor (2021)

Podemos observar resultados similares na figura “Resultados correlação”.

	idh	corrupcao_indice	competitividade_indice	globalizacao_indice
idh	1.000000	0.742528	0.576736	0.807371
corrupcao_indice	0.742528	1.000000	0.753907	0.807345
competitividade_indice	0.576736	0.753907	1.000000	0.580710
globalizacao_indice	0.807371	0.807345	0.580710	1.000000

Figura 5 – Resultados correlação
 Fonte: Elaborado pelo autor (2021).

5.2 Ferramentas de análise de regressão e séries temporais

Apesar do coeficiente de correlação ser bastante informativo para analisar o relacionamento entre duas variáveis, correlação não implica causalidade. Para os casos em que seja necessário analisar se uma variável influencia/causa em alguma outra, podemos utilizar as ferramentas de análise de regressão e séries temporais. Estas técnicas fazem parte do grupo denominado de “Técnicas de *Machine Learning* Supervisionadas”. No exemplo a seguir apresentaremos a função **OLS** do módulo *statsmodels*.

Esta função é uma das ferramentas que utilizamos para treinar o algoritmo de regressão linear. Esta técnica busca prever uma variável “y” dado um conjunto de variáveis “X”. No código fonte “Exemplo regressão linear”, estamos treinando um algoritmo para explicar “IDH” utilizando as variáveis “corrupção_indice”, “competitividade_indice” e “globalização_indice”.

Diversos índices são apresentados após a última linha do código. O significado e interpretação destes valores serão detalhados no capítulo voltado a análise de regressão.

```
# carregar modulos
import statsmodels.formula.api as sm
# treinar algoritmo
modelo_regressao = sm.ols(formula = 'idh ~ corrupcao_indice + competitividade_indice + globalizacao_indice', data= df_dados_paises).fit()
# ver resultados
modelo_regressao.summary()
```

Código-fonte 8 – Exemplo regressão linear

Fonte: Elaborado pelo autor (2021)

Podemos observar resultados similares na figura “Resultados regressão”.

OLS Regression Results			
Dep. Variable:	idh	R-squared:	0.678
Model:	OLS	Adj. R-squared:	0.675
Method:	Least Squares	F-statistic:	197.3
Date:	Tue, 30 Nov 2021	Prob (F-statistic):	7.53e-69
Time:	01:27:37	Log-Likelihood:	365.76
No. Observations:	285	AIC:	-723.5
Df Residuals:	281	BIC:	-708.9
Df Model:	3		

Figura 6 – Resultados regressão

Fonte: Elaborado pelo autor (2021).

5.3 Ferramentas de análise multivariada de dados

As técnicas que abordaremos neste tópico fazem parte do grupo de “Técnicas de *Machine Learning* Não Supervisionadas”. A respeito destas técnicas, abordaremos a análise de componentes principais e análise de conglomerados (*cluster*).

No código fonte “Exemplo *Kmeans*” a iremos realizar de forma rápida uma análise de *cluster* utilizando a função ***KMeans***. Neste caso, vamos resumir parte dos dados, instanciar a função e depois adicionar uma nova coluna associando qual o devido *cluster* de determinado país.

```
# carregar modulo
from sklearn.cluster import KMeans

# estatísticas descritivas
dados_resumo = df_dados_paises.groupby('pais') \
    .agg(media_corrupcao = pd.NamedAgg('corr
upcao_indice', 'mean'),
        media_competitividade = pd.NamedAgg
('competitividade_indice', 'mean'),
        media_globalizacao = pd.NamedAgg('g
lobalizacao_indice', 'mean')) \
    .reset_index()

# instanciar algoritmo
kmeans = KMeans(init="random",
                 n_clusters=3,
                 n_init=10,
                 max_iter=300,
                 random_state=42)

# aplicar o algoritmo nos dados
kmeans.fit(dados_resumo[['media_corrupcao', 'media_competitividade', '
media_globalizacao']])

# associar os clusters aos paises
dados_resumo['cluster'] = kmeans.labels_

# verificar resultados
dados_resumo.head()
```

Código-fonte 9 – Exemplo *KMeans*

Fonte: Elaborado pelo autor (2021)

Podemos observar resultados similares na figura “Resultados *Kmeans*”.

país	media_corrupcao	media_competitividade	media_globalizacao	cluster
Alemanha	79.066667	74.262667	84.034138	2
Austrália	86.800000	80.448667	81.790126	2
Brasil	36.533333	49.568000	59.332414	1
Bélgica	67.200000	69.065333	92.173351	0
Canadá	88.466667	81.897333	87.087049	2

Figura 7 – Resultados *Kmeans*
 Fonte: Elaborado pelo autor (2021)

5.4 Ferramentas de limpeza e normalização de dados

Durante os processos de aplicação dos algoritmos, percebemos possíveis problemas nos dados. Por exemplo, dados com características fora do padrão (*outliers*) ou a ausência dos dados (*missing values*).

No código fonte “Exemplo *boxplot*”, mostramos como é possível, através de um gráfico, detectar dados fora do padrão esperado (*outliers*).

```
# estatísticas descritivas
dados_resumo = df_dados_paises.groupby('país') \
    .agg(media_pib = pd.NamedAgg('pib', 'median')) \
    .reset_index()

# boxplot
dados_resumo[['media_pib']].boxplot()
```

Código-fonte 10 – Exemplo *boxplot*
 Fonte: Elaborado pelo autor (2021)

Podemos observar resultados similares na figura “Resultados *boxplot*”.




Figura 8 – Resultados *boxplot*
 Fonte: Elaborado pelo autor (2021).

REFERÊNCIAS

OLIVEIRA, M. Y., LÓSCIO, B. F. *What is data ecosystem*. **Association for Computing Machinery**. 18. 2018. Disponível em: <<https://doi.org/10.1145/3209281.3209335>>. Acesso em: 09 nov. 2021.

EMAP